UNIVERSIDAD INTERNACIONAL DE LA RIOJA (UNIR) · ESCUELA SUPERIOR DE INGENIERÍA Y TECNOLOGÍA

Compendio Maestro Oficial de Exámenes Resueltos

Máster Universitario en Inteligencia Artificial · Guía de resolución analítica, justificación conceptual rigurosa y prevención de trampas de examen para las convocatorias ordinaria y extraordinaria.

📚 5 Asignaturas Troncales

🎯 36 Cuestiones Oficiales de Test (TAA)

⚙️ 26 Ejercicios de Cálculo y Casos de Análisis

✅ 100% Cobertura de Temarios Oficiales

🎓 Calificación de Referencia: 10.0 / 10

1. Técnicas de Aprendizaje Automático (TAA)

Docente de referencia: Prof.ª María Flores Ceballos · **Estructura oficial de examen:** Test (3 pts: +0.75 acierto, -0.25 error), Ejercicios de cálculo (3 pts) y Casos de análisis práctico (4 pts).

TAA | Tema 1: Introducción al Aprendizaje Automático | Test Oficial · Pregunta 1 | +0.75 pts / -0.25 pts

1. ¿Cuál de las siguientes afirmaciones describe correctamente el aprendizaje automático?

A Se basa únicamente en reglas programadas manualmente por expertos.

B Permite que los algoritmos aprendan patrones a partir de datos para generalizar comportamientos. ✓ RESPUESTA CORRECTA

C Solo trabaja con datos no estructurados como imágenes o audio.

D No requiere datos previos para realizar predicciones.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El Aprendizaje Automático (Machine Learning) se define formalmente como la rama de la Inteligencia Artificial cuyo propósito es permitir que los sistemas computacionales identifiquen patrones, relaciones y regularidades subyacentes a partir de datos empíricos de entrenamiento, generalizando dicho conocimiento para formular predicciones precisas o tomar decisiones sobre observaciones futuras no vistas previamente (Mitchell, 1997; Diapositivas Tema 1, pág. 4). A diferencia de los sistemas expertos clásicos, no requiere codificación explícita de reglas deterministas.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A confunde el aprendizaje automático con los sistemas expertos basados en reglas manuales rígidas (IA simbólica clásica). Distractor C restringe falsamente el aprendizaje automático a datos no estructurados, cuando históricamente la gran mayoría de problemas se abordan con datos estructurados tabulares. Distractor D es absurdo, pues el aprendizaje automático requiere intrínsecamente datos previos para el ajuste empírico.

TAA | Tema 1: Introducción al Aprendizaje Automático | Test Oficial · Pregunta 2 | +0.75 pts / -0.25 pts

2. En el aprendizaje supervisado, ¿qué caracteriza a un conjunto de datos etiquetado?

A Contiene únicamente variables de entrada sin salidas.

B Incluye datos sin ningún tipo de estructura.

C Cada ejemplo de entrada está asociado a una salida conocida. ✓ RESPUESTA CORRECTA

D Solo puede utilizarse en problemas de clasificación.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

En el paradigma de aprendizaje supervisado, el conjunto de entrenamiento se compone de pares ordenados (x_i, y_i), donde cada vector de características de entrada x_i está emparejado unívocamente con su correspondiente etiqueta o variable objetivo conocida y_i (ground truth) (Diapositivas Tema 1, pág. 9). El algoritmo busca aprender una función f: X -> Y que mapee las entradas en las salidas.

⚠ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A describe variables independientes sin target. Distractor B confunde el aprendizaje supervisado con datos desestructurados o ruido. Distractor D comete el error habitual de limitar el aprendizaje supervisado a la clasificación, olvidando que la regresión (predicción de variable continua) es igualmente supervisada.

TAA | Tema 1: Introducción al Aprendizaje Automático | Test Oficial · Pregunta 3 | +0.75 pts / -0.25 pts

3. ¿Qué objetivo principal tiene un modelo de aprendizaje supervisado?

A Memorizar todos los datos de entrenamiento.

B Minimizar el error solo en los datos de entrenamiento.

C Generalizar correctamente sobre datos nuevos no observados. ✓ RESPUESTA CORRECTA

D Trabajar únicamente con datos sin etiquetas.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El objetivo fundamental del aprendizaje supervisado es maximizar la capacidad de generalización del modelo sobre datos nuevos, no observados durante la fase de optimización o ajuste (Diapositivas Tema 1, pág. 12). Un modelo que únicamente minimiza el error empírico sobre los datos de entrenamiento corre el riesgo de sobreajustar.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A confunde aprendizaje con memorización estricta (overfitting extremo o lookup table). Distractor B ignora el dilema sesgo-varianza, pues un error cero en entrenamiento suele asociarse a nula capacidad predictiva externa. Distractor D confunde supervisado con no supervisado.

TAA | Tema 1: Introducción al Aprendizaje Automático | Test Oficial · Pregunta 4 | +0.75 pts / -0.25 pts

4. ¿Cuál de las siguientes afirmaciones sobre el overfitting es correcta?

A Ocurre cuando el modelo es demasiado simple.

B Implica un buen rendimiento tanto en entrenamiento como en test.

C Se produce cuando el modelo se ajusta excesivamente a los datos de entrenamiento. ✓ RESPUESTA CORRECTA

D Es un problema exclusivo de modelos lineales.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El sobreajuste (overfitting) se define formalmente como el fenómeno patológico donde un modelo excesivamente complejo aprende y memoriza el ruido estadístico y las fluctuaciones espurias del conjunto de entrenamiento en lugar de captar el patrón subyacente de la población (Diapositivas Tema 1, pág. 16). Se caracteriza por un error empírico de entrenamiento sumamente bajo, pero un error de generalización en test muy elevado.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A describe el underfitting (subajuste por excesiva simplicidad). Distractor B describe un modelo óptimo bien regularizado. Distractor D limita erróneamente el overfitting a modelos lineales, cuando en realidad ocurre con mucha mayor severidad en modelos de alta capacidad no lineales (árboles profundos, redes neuronales).

TAA | Tema 1: Introducción al Aprendizaje Automático | Test Oficial · Pregunta 5 | +0.75 pts / -0.25 pts

5. ¿Cuál es la función principal del conjunto de test en aprendizaje automático?

A Ajustar los hiperparámetros del modelo durante el entrenamiento.

B Entrenar el modelo con nuevos datos.

C Evaluar el rendimiento del modelo en datos no utilizados en el entrenamiento. ✓ RESPUESTA CORRECTA

D Reducir la dimensionalidad de los datos.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El conjunto de test (o prueba independiente) tiene como única finalidad proporcionar una estimación imparcial (unbiased) del rendimiento, error de generalización y comportamiento del modelo final frente a observaciones completamente inéditas, que jamás intervinieron en la fase de entrenamiento ni en la selección de hiperparámetros (Diapositivas Tema 1, pág. 21).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A describe la función del conjunto de validación (validation set), no de test. Utilizar test para ajustar hiperparámetros incurre en la grave falta de fuga de datos (data leakage). Distractor B confunde el conjunto de test con el de entrenamiento. Distractor D lo confunde con técnicas de reducción de dimensionalidad como PCA.

TAA | Tema 2: Análisis Descriptivo y Exploratorio de Datos (EDA) | Test Oficial · Pregunta 6 | +0.75 pts / -0.25 pts

6. ¿Cuál es la principal utilidad de un histograma en el análisis exploratorio de datos?

A Representar relaciones entre dos variables categóricas.

B Mostrar la distribución de frecuencia de una variable numérica. ✓ RESPUESTA CORRECTA

C Identificar correlaciones lineales entre variables.

D Clasificar los datos en categorías ordenadas.

📘 **JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)**

El histograma es la herramienta gráfica univariante fundamental para estimar y visualizar la función de densidad de probabilidad empírica y la distribución de frecuencias de una variable numérica continua o discreta, agrupando sus valores en intervalos contiguos (bins) (Diapositivas Tema 2, pág. 11). Permite evaluar asimetría (skewness), curtosis, bimodalidad y dispersión.

⚠️ **TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO**

Distractor A corresponde a gráficos de barras apiladas o tablas de contingencia para datos categóricos. Distractor C corresponde al diagrama de dispersión (scatter plot). Distractor D se refiere a esquemas de discretización o clustering.

TAA | Tema 2: Análisis Descriptivo y Exploratorio de Datos (EDA) | Test Oficial · Pregunta 7 | +0.75 pts / -0.25 pts

7. ¿Cuál de las siguientes afirmaciones sobre el rango intercuartílico (RIC) es correcta?

A Es la diferencia entre el valor máximo y el mínimo del conjunto de datos.

B Representa el 100 % de los datos de la distribución.

C Es la diferencia entre el tercer cuartil y el primer cuartil. ✓ RESPUESTA CORRECTA

D Es sensible a los valores atípicos.

📘 **JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)**

El Rango Intercuartílico (RIC o IQR) se define rigurosamente como la diferencia matemática entre el tercer cuartil (percentil 75) y el primer cuartil (percentil 25): RIC = Q3 - Q1 (Diapositivas Tema 2, pág. 18). Engloba exactamente el 50% central de las observaciones y es un estadístico no paramétrico sumamente robusto ante la presencia de valores atípicos (outliers).

⚠️ **TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO**

Distractor A describe el rango total (R = Max - Min). Distractor B afirma erróneamente que abarca el 100% de la distribución (abarca el 50%). Distractor D es falso de raíz: el RIC es precisamente insensible y robusto ante outliers, a diferencia de la desviación típica.

TAA | Tema 2: Análisis Descriptivo y Exploratorio de Datos (EDA) | Test Oficial · Pregunta 8 | +0.75 pts / -0.25 pts

8. ¿Qué indica un coeficiente de correlación de Pearson cercano a 0?

A Existe una relación lineal positiva fuerte.

B Existe una relación lineal negativa fuerte.

C No existe relación lineal entre las variables. ✓ RESPUESTA CORRECTA

D Existe una relación causal directa entre variables.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El coeficiente de correlación lineal de Pearson (r) cuantifica la fuerza y dirección de una relación estrictamente lineal entre dos variables numéricas continuas en el intervalo [-1, +1] (Diapositivas Tema 2, pág. 25). Un valor r ≈ 0 evidencia la ausencia de covariación lineal; no obstante, puede existir una relación determinista no lineal fuerte (como cuadrática o sinusoidal).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor C es correcto. Distractor A implicaría r ≈ +1. Distractor B implicaría r ≈ -1. Distractor D incurre en la clásica falacia estadística de confundir correlación con causalidad ('correlation does not imply causation').

TAA | Tema 2: Análisis Descriptivo y Exploratorio de Datos (EDA) | Test Oficial · Pregunta 9 | +0.75 pts / -0.25 pts

9. ¿Cuál es la principal razón para eliminar atributos redundantes en un conjunto de datos?

A Reducir el tamaño del dataset sin afectar al modelo.

B Evitar información duplicada que no aporta valor y puede degradar el rendimiento del modelo. ✓ RESPUESTA CORRECTA

C Mejorar únicamente la visualización de los datos.

D Garantizar que todas las variables sean categóricas.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

La eliminación de atributos redundantes o fuertemente colineales evita la duplicación de información que no añade capacidad predictiva y previene problemas críticos como la multicolinealidad, la inestabilidad en la estimación de coeficientes (en modelos lineales/regresión logística), el aumento innecesario del coste computacional y la degradación del rendimiento por la maldición de la dimensionalidad (Diapositivas Tema 2, pág. 32).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A es inexacto y engañoso al afirmar que se hace simplemente por 'reducir tamaño sin afectar'. Distractor C limita erróneamente el beneficio a la visualización. Distractor D es absurdo, pues la redundancia afecta tanto a variables numéricas como categóricas.

TAA | Tema 3: Datos Ausentes y Normalización | Test Oficial · Pregunta 10 | +0.75 pts / -0.25 pts

10. ¿Cuál de las siguientes afirmaciones sobre los valores ausentes es correcta?

A. No afectan al rendimiento de los modelos de aprendizaje automático.

B. Pueden ignorarse sin consecuencias en el análisis.

C. Pueden introducir sesgos y afectar a la calidad de los resultados si no se manejan correctamente. ✓ RESPUESTA CORRECTA

D. Solo aparecen en datasets pequeños.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

La presencia de valores ausentes (missing values: MCAR, MAR o MNAR) en una base de datos puede introducir sesgos sistemáticos sustanciales, distorsionar las estimaciones estadísticas poblacionales y degradar la calidad y convergencia de los modelos de aprendizaje automático si no se gestionan rigurosamente mediante imputación fundamentada (media, mediana, KNN, MICE) o eliminación justificada (Diapositivas Tema 3, pág. 8).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A y B afirman falsamente que no tienen impacto o que pueden ignorarse, cuando la inmensa mayoría de algoritmos en scikit-learn arrojan excepciones ante NaNs. Distractor D asume erróneamente que solo ocurren en datasets pequeños.

TAA | Tema 3: Datos Ausentes y Normalización | Test Oficial · Pregunta 11 | +0.75 pts / -0.25 pts

11. ¿Qué caracteriza a la normalización z-score?

A Escala los valores entre 0 y 1.

B Transforma los datos para que tengan media 0 y desviación estándar 1. ✓ RESPUESTA CORRECTA

C Elimina valores atípicos automáticamente.

D Solo se aplica a variables categóricas.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

La estandarización o normalización z-score transforma una variable continua x restándole su media empírica (mu) y dividiendo el resultado entre su desviación estándar (sigma): z = (x - mu) / sigma (Diapositivas Tema 3, pág. 19). Como resultado matemático riguroso, la variable resultante posee exactamente una media igual a 0 y una desviación típica igual a 1.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A describe la normalización Min-Max (escala [0, 1]). Distractor C asume falsamente que el z-score elimina outliers automáticamente; en realidad no los elimina, simplemente los desplaza conservando su magnitud relativa. Distractor D limita la normalización a categóricas, cuando es exclusiva de cuantitativas.

TAA | Tema 4: Regresión y Evaluación de Algoritmos de Regresión | Test Oficial · Pregunta 12 | +0.75 pts / -0.25 pts

12. ¿Cuál es el objetivo principal de los algoritmos de regresión en aprendizaje automático? (Respuesta corta)

Respuesta Oficial: Respuesta correcta: Predecir valores numéricos continuos a partir de ✓ CORRECTA

📘 **JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)**

El objetivo primordial de los algoritmos de regresión es modelar la relación matemática y estadística funcional existente entre un conjunto de variables predictoras o independientes (X) y una variable dependiente u objetivo continua (Y) con el fin de predecir valores numéricos cuantitativos reales para nuevas instancias no observadas (Diapositivas Tema 4, pág. 6).

⚠️ **TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO**

Confundir regresión con clasificación: si el objetivo fuera predecir una clase discreta o pertenencia a una categoría, estaríamos en un problema de clasificación, no de regresión.

TAA | Tema 4: Regresión y Evaluación de Algoritmos de Regresión | Test Oficial · Pregunta 13 | +0.75 pts / -0.25 pts

13. ¿Cuál de las siguientes afirmaciones describe correctamente el RMSE?

A Es la suma de los errores absolutos.

B Es la raíz cuadrada del error cuadrático medio y mantiene las unidades originales. ✓ RESPUESTA CORRECTA

C No penaliza errores grandes.

D Solo se aplica a variables categóricas.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El RMSE (Root Mean Squared Error o Raíz del Error Cuadrático Medio) se define formalmente como RMSE = sqrt((1/N) * sum (y_i - y_hat_i)^2) (Diapositivas Tema 4, pág. 14). Al aplicar la raíz cuadrada sobre el MSE, posee la enorme ventaja práctica de retornar la métrica a las mismas unidades físicas originales que la variable objetivo evaluada.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A corresponde al MAE (Mean Absolute Error). Distractor C es falso: debido a la elevación cuadrática del error, el RMSE penaliza de forma desproporcionadamente severa los errores grandes o desviaciones atípicas. Distractor D es falso porque solo aplica a variables numéricas continuas.

TAA | Tema 4: Regresión y Evaluación de Algoritmos de Regresión | Test Oficial · Pregunta 14 | +0.75 pts / -0.25 pts

14. ¿Qué implica un alto valor de varianza en un modelo de regresión?

A El modelo es demasiado simple y no capta la estructura de los datos.

B El modelo generaliza perfectamente en datos nuevos.

C El modelo es muy sensible a las variaciones del conjunto de entrenamiento (sobreajuste). ✓ RESPUESTA CORRECTA

D El modelo no depende de los datos de entrada.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

En el marco del compromiso entre sesgo y varianza (Bias-Variance Tradeoff), una alta varianza denota que el modelo es excesivamente flexible y sensible a pequeñas fluctuaciones o ruido aleatorio del conjunto de datos de entrenamiento particular utilizado (Diapositivas Tema 4, pág. 22). Esto implica un sobreajuste severo: predicciones inestables y baja capacidad de generalización.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A describe un modelo con alto sesgo (subajuste o underfitting). Distractor B confunde alta varianza con capacidad perfecta de generalización, cuando es exactamente lo opuesto. Distractor D es inconsistente con la definición de aprendizaje inductivo.

TAA | Tema 5: Evaluación de Algoritmos de Clasificación | Test Oficial · Pregunta 15 | +0.75 pts / -0.25 pts

15. Cuál es el objetivo principal de los algoritmos de clasificación en aprendizaje automático?

A Predecir valores numéricos continuos.

B Asignar una etiqueta o categoría a una instancia. ✓ RESPUESTA CORRECTA

C Reducir la dimensionalidad de los datos.

D Calcular la varianza de las variables.

📘 **JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)**

A diferencia de la regresión, el objetivo sustantivo de los algoritmos de clasificación en aprendizaje automático es asignar a cada instancia o vector de entrada una etiqueta, clase cualitativa o categoría cualitativa discreta perteneciente a un conjunto predefinido de clases posibles (clasificación binaria o multiclase) (Diapositivas Tema 5, pág. 5).

⚠️ **TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO**

Distractor A define la regresión. Distractor C define técnicas de reducción de dimensionalidad o extracción de características (PCA, t-SNE). Distractor D corresponde al cálculo de un estadístico descriptivo univariante.

TAA | Tema 5: Evaluación de Algoritmos de Clasificación | Test Oficial · Pregunta 16 | +0.75 pts / -0.25 pts

16. ¿Para qué se utiliza la matriz de confusión en modelos de clasificación?

A Para calcular la media de los errores.

B Para visualizar la correlación entre variables.

C Para organizar las predicciones en función de los valores reales y analizar aciertos y errores. ✓ RESPUESTA CORRECTA

D Para normalizar los datos antes del entrenamiento.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

La matriz de confusión es una tabla estructurada de contingencia de dimensión C x C (donde C es el número de clases) que cruza sistemáticamente las etiquetas verdaderas reales de las instancias con las etiquetas predichas por el clasificador (Diapositivas Tema 5, pág. 10). Permite desagregar con precisión los Verdaderos Positivos (TP), Verdaderos Negativos (TN), Falsos Positivos (FP) y Falsos Negativos (FN).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A describe el error medio de regresión. Distractor B describe la matriz de correlación o covarianzas. Distractor D confunde una herramienta de evaluación con un paso de preprocesamiento.

TAA | Tema 5: Evaluación de Algoritmos de Clasificación | Test Oficial · Pregunta 17 | +0.75 pts / -0.25 pts

17. ¿Qué indica un alto valor de recall en un modelo de clasificación?

A Que el modelo predice correctamente los ejemplos negativos.

B Que el modelo captura un alto porcentaje de ejemplos positivos. ✓ RESPUESTA CORRECTA

C Que el modelo minimiza los falsos positivos.

D Que el modelo tiene la menor varianza posible.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El Recall (también denominado Sensibilidad o Tasa de Verdaderos Positivos) se calcula como Recall = TP / (TP + FN) (Diapositivas Tema 5, pág. 14). Un valor elevado de recall indica que el modelo es sumamente eficaz para capturar e identificar la gran mayoría de las instancias verdaderamente positivas de la población, minimizando la omisión de falsos negativos.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A se refiere a la Especificidad (True Negative Rate = TN / (TN + FP)). Distractor C se refiere a la Precisión (Precision = TP / (TP + FP)). Distractor D confunde una métrica de clasificación con el concepto de varianza del modelo.

TAA | Tema 6: Árboles de Decisión (CART) | Test Oficial · Pregunta 18 | +0.75 pts / -0.25 pts

18. ¿Cuál es el objetivo principal del criterio de división en un árbol de decisión?

A Maximizar el número de nodos del árbol.

B Reducir la profundidad del árbol.

C Seleccionar la variable que mejor separa las clases (máxima ganancia de información o mínima impureza). ✓ RESPUESTA CORRECTA

D Aumentar el número de variables predictoras.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

En cada nodo interno de un árbol de decisión, el criterio de división (split criterion) evalúa exhaustivamente todas las variables predictoras y todos sus posibles umbrales de corte con el fin de seleccionar aquella partición que maximice la pureza resultante de los nodos hijos (Diapositivas Tema 6, pág. 12). Esto se cuantifica analíticamente mediante la maximización de la Ganancia de Información o la minimización del índice de Impureza de Gini / Entropía.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A busca maximizar nodos, lo cual incrementa el sobreajuste. Distractor B confunde el criterio de división con la poda o regularización. Distractor D es absurdo, pues el criterio de división divide una variable a la vez, no aumenta el número de variables.

TAA | Tema 6: Árboles de Decisión (CART) | Test Oficial · Pregunta 19 | +0.75 pts / -0.25 pts

19. ¿Qué problema intenta resolver la poda en los árboles de decisión?

A La falta de interpretabilidad.

B El desbalanceo de datos.

C El sobreajuste del modelo. ✓ RESPUESTA CORRECTA

D La falta de variables numéricas.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

La poda (pruning, tanto pre-pruning como post-pruning como Cost-Complexity Pruning) tiene como cometido explícito recortar ramas redundantes o excesivamente específicas que se ajustan al ruido estadístico del conjunto de entrenamiento, reduciendo la complejidad estructural del árbol para mitigar drásticamente el sobreajuste (overfitting) y optimizar su capacidad de generalización (Diapositivas Tema 6, pág. 21).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A: los árboles no podados son interpretables pero sobreajustan. Distractor B: la poda no corrige el desbalanceo de clases (eso se trata con ponderación de clases o remuestreo SMOTE). Distractor D: los árboles manejan variables numéricas nativamente.

TAA | Tema 6: Árboles de Decisión (CART) | Test Oficial · Pregunta 20 | +0.75 pts / -0.25 pts

20. ¿Cuál de las siguientes características describe mejor a los árboles de decisión?

A Solo funcionan con variables numéricas.

B Requieren suposiciones de linealidad estrictas.

C Son modelos fáciles de interpretar que pueden manejar variables categóricas y numéricas. ✓ RESPUESTA CORRECTA

D Siempre producen modelos óptimos globales.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

Los árboles de decisión son modelos intrínsecamente no paramétricos e interpretables ('cajas blancas') con alta capacidad representativa, caracterizados por su versatilidad para admitir y procesar de forma nativa tanto variables continuas numéricas como variables categóricas o discretas sin requerir supuestos previos de linealidad ni transformaciones de escala (Diapositivas Tema 6, pág. 28; Breiman et al., 1984).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A y B son rotundamente falsos: no requieren linealidad y operan con categóricas y numéricas. Distractor D es falso: los algoritmos estándar (CART, ID3, C4.5) son heurísticas voraces (greedy) paso a paso que no garantizan encontrar el árbol globalmente óptimo (problema NP-completo).

TAA | Tema 7: Máquinas de Vectores de Soporte (SVM) | Test Oficial · Pregunta 21 | +0.75 pts / -0.25 pts

21. ¿Cuál es el objetivo principal de una máquina de vectores de soporte (SVM)?

A Minimizar la varianza del modelo.

B Encontrar el hiperplano que maximiza el margen entre clases. ✓ RESPUESTA CORRECTA

C Ajustar una regresión lineal simple.

D Reducir la dimensionalidad del dataset.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El principio matemático fundacional de las Máquinas de Vectores de Soporte (SVM) en clasificación lineal separable o cuasi-separable es encontrar el hiperplano óptimo de separación $w^T x + b = 0$ que maximiza el margen geométrico bidireccional ($2 / ||w||$) entre las instancias de clases opuestas más próximas (Diapositivas Tema 7, pág. 8; Vapnik, 1995). La maximización del margen minimiza la cota superior del error de generalización según la teoría de Vapnik-Chervonenkis (VC).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A confunde el objetivo formal de optimización con una consecuencia colateral. Distractor C confunde SVM con regresión lineal simple. Distractor D confunde SVM con algoritmos no supervisados de proyección como PCA.

TAA | Tema 7: Máquinas de Vectores de Soporte (SVM) | Test Oficial · Pregunta 22 | +0.75 pts / -0.25 pts

22. ¿Qué son los vectores de soporte?

A Variables irrelevantes del modelo.

B Puntos de datos alejados del hiperplano.

C Puntos más cercanos al hiperplano que determinan su posición. ✓ RESPUESTA CORRECTA

D Parámetros del kernel.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

Los vectores de soporte (support vectors) son rigurosamente aquellos puntos de datos críticos del conjunto de entrenamiento que se sitúan exactamente sobre los hiperplanos límite del margen ($w^T x_i + b = \pm 1$) o que violan dicho margen en SVM de margen blando (Diapositivas Tema 7, pág. 14). Son los únicos puntos con multiplicadores de Lagrange $\alpha_i > 0$; si se eliminaran los demás puntos del dataset, el hiperplano óptimo no cambiaría en absoluto.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A afirma erróneamente que son variables irrelevantes cuando son las observaciones más críticas. Distractor B afirma que son puntos alejados, cuando por definición son los más cercanos al hiperplano separador. Distractor D los confunde con hiperparámetros.

TAA | Tema 7: Máquinas de Vectores de Soporte (SVM) | Test Oficial · Pregunta 23 | +0.75 pts / -0.25 pts

23. ¿Para qué sirve el kernel trick en SVM?

A Reducir el número de variables.

B Transformar explícitamente los datos a menor dimensión.

C Permitir separaciones no lineales mediante transformaciones implícitas. ✓ RESPUESTA CORRECTA

D Calcular la matriz de confusión.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El 'truco del núcleo' (Kernel Trick) permite a SVM proyectar implícitamente los datos de entrada originales no separables linealmente a un espacio de características de dimensión significativamente mayor o infinita (espacio de Hilbert) donde sí son separables linealmente, calculando únicamente los productos escalares K(x_i, x_j) = sin necesidad de materializar explícitamente las coordenadas transformadas Phi(x) (Diapositivas Tema 7, pág. 22; Boser et al., 1992).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A y B afirman que transforma a menor dimensión o explícitamente, cuando transforma implícitamente a dimensión mayor o infinita. Distractor D confunde el núcleo de Hilbert con el cálculo de métricas de validación.

TAA | Tema 8: Clasificación con Naïve Bayes | Test Oficial · Pregunta 24 | +0.75 pts / -0.25 pts

24. ¿Qué suposición clave realiza el clasificador Naïve Bayes?

A Que las variables son altamente correlacionadas.

B Que las variables son independientes entre sí dado la clase. ✓ RESPUESTA CORRECTA

C Que todas las variables siguen una distribución uniforme.

D Que el modelo es determinista.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

La hipótesis 'ingenua' (naïve) que constituye la base matemática del clasificador Naïve Bayes es la asunción de independencia condicional entre todos los atributos o variables predictoras dado el valor de la clase objetivo: P(X_1, X_2, ..., X_p | C) = Prod P(X_j | C) (Diapositivas Tema 8, pág. 7). Esto permite descomponer el cálculo de la verosimilitud conjunta en el producto de verosimilitudes univariantes.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A sostiene lo contrario (correlación alta destruye la eficiencia de Naïve Bayes). Distractor C confunde la distribución a priori con uniformidad estricta. Distractor D olvida que Naïve Bayes es un modelo probabilístico generativo, no determinista.

TAA | Tema 8: Clasificación con Naïve Bayes | Test Oficial · Pregunta 25 | +0.75 pts / -0.25 pts

25. ¿Qué describe el teorema de Bayes?

A La relación entre error y precisión.

B La probabilidad conjunta de eventos independientes.

C La relación entre probabilidad posterior, previa y verosimilitud. ✓ RESPUESTA CORRECTA

D La distribución normal de los datos.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El Teorema de Bayes establece formalmente la relación probabilística entre la probabilidad a posteriori P(C|X), la probabilidad a priori P(C), la verosimilitud de los datos P(X|C) y la probabilidad marginal de la evidencia P(X): P(C|X) = [P(C) * P(X|C)] / P(X) (Diapositivas Tema 8, pág. 12). Permite actualizar nuestras creencias ante nueva evidencia empírica.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A confunde Bayes con métricas de evaluación empírica. Distractor B describe la probabilidad conjunta bajo independencia mutua marginal. Distractor D confunde el teorema con el supuesto de normalidad en Naïve Bayes Gaussiano.

TAA | Tema 8: Clasificación con Naïve Bayes | Test Oficial · Pregunta 26 | +0.75 pts / -0.25 pts

26. ¿Por qué se utiliza el estimador de Laplace en Naïve Bayes?

A Para eliminar variables irrelevantes.

B Para mejorar la interpretabilidad del modelo.

C Para evitar probabilidades nulas en combinaciones no observadas. ✓ RESPUESTA CORRECTA

D Para reducir la dimensionalidad.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El estimador o suavizado de Laplace (Laplace smoothing / Add-1) suma una pseudocuenta unitaria al numerador y el tamaño del vocabulario V al denominador: P(x|c) = (count(x,c) + 1) / (count(c) + V) (Diapositivas Tema 8, pág. 19). Su función imperativa es evitar el problema de la probabilidad cero (zero frequency problem), donde una sola combinación no observada en entrenamiento anularía por completo el producto final de probabilidades a posteriori.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A se refiere a selección de variables. Distractor B confunde suavizado con interpretabilidad. Distractor D lo confunde con reducción de dimensionalidad.

TAA | Tema 9: Combinación de Clasificadores (Ensembles) | Test Oficial · Pregunta 27 | +0.75 pts / -0.25 pts

27. ¿Cuál es el objetivo principal del bagging?

A Reducir el sesgo del modelo

B Reducir la varianza del modelo ✓ RESPUESTA CORRECTA

C Aumentar la complejidad del modelo

D Eliminar el ruido de los datos

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El objetivo matemático cardinal del Bagging (Bootstrap Aggregating, propuesto por Leo Breiman en 1996) es reducir sustancialmente la varianza del modelo compuesto sin alterar apreciablemente su sesgo (Diapositivas Tema 9, pág. 11). Para ello, entrena múltiples estimadores base de alta varianza (como árboles profundos) sobre subconjuntos generados por remuestreo con reemplazo (bootstrap) y promedia sus predicciones.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A es la trampa clásica: reducir el sesgo es el objetivo del Boosting, NO del Bagging. Distractor C confunde reducir varianza con complejizar el modelo. Distractor D confunde ensamble con técnicas de filtrado de ruido.

TAA | Tema 9: Combinación de Clasificadores (Ensembles) | Test Oficial · Pregunta 28 | +0.75 pts / -0.25 pts

28. En el algoritmo boosting, ¿cómo se construyen los modelos?

A Independientemente en paralelo

B Usando datos sintéticos

C De forma secuencial, teniendo en cuenta errores previos ✓ RESPUESTA CORRECTA

D Eliminando variables irrelevantes

📘 **JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)**

En la familia de algoritmos de Boosting (como AdaBoost y Gradient Boosting), los estimadores base débiles (weak learners) se construyen de manera estrictamente secuencial y adaptativa (Diapositivas Tema 9, pág. 18; Freund & Schapire, 1997). Cada nuevo modelo se enfoca prioritariamente en corregir los errores residuales cometidos por los modelos precedentes, reponderando muestras o ajustando gradientes negativos.

⚠️ **TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO**

Distractor A describe la construcción en paralelo independiente propia del Bagging. Distractor B describe técnicas de sobremuestreo sintético como SMOTE. Distractor D describe selección de características.

TAA | Tema 9: Combinación de Clasificadores (Ensembles) | Test Oficial · Pregunta 29 | +0.75 pts / -0.25 pts

29. ¿Qué caracteriza al método stacking?

A Combina modelos mediante muestreo bootstrap

B Utiliza un metamodelo sobre las salidas de modelos base ✓ RESPUESTA CORRECTA

C Reentrena un único modelo múltiples veces

D Solo se aplica a clasificación

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El método de Stacking (Stacked Generalization, Wolpert 1992) se caracteriza por organizar el aprendizaje en dos niveles jerárquicos: entrena un conjunto de modelos base heterogéneos (Nivel 0) y posteriormente entrena un metamodelo o meta-clasificador (Nivel 1) cuyas variables de entrada son las predicciones probabilísticas generadas por los modelos base (Diapositivas Tema 9, pág. 26).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A describe Bagging. Distractor C describe reentrenamiento iterativo sin meta-aprendizaje. Distractor D es falso: Stacking se aplica idénticamente tanto a problemas de clasificación como de regresión continua.

TAA | Tema 10: Random Forest | Test Oficial · Pregunta 30 | +0.75 pts / -0.25 pts

30. ¿Cuál es el principio fundamental de random forest?

A Entrenar una red neuronal profunda

B Combinar múltiples árboles de decisión ✓ RESPUESTA CORRECTA

C Reducir dimensionalidad

D Optimizar hiperparámetros

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El principio fundacional de Random Forest (Breiman, 2001) es construir un ensamble robusto combinando una multitud de árboles de decisión no podados, introduciendo una doble aleatoriedad: remuestreo con reemplazo de las observaciones (bagging) y selección aleatoria de un subconjunto de características (feature subspace) en cada división de nodo (Diapositivas Tema 10, pág. 7). Esto descorrelaciona los árboles y desploma la varianza.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A se refiere al deep learning. Distractor C se refiere a proyección o extracción de características. Distractor D se refiere a ajuste de hiperparámetros.

TAA | Tema 10: Random Forest | Test Oficial · Pregunta 31 | +0.75 pts / -0.25 pts

31. ¿Cómo se obtiene la predicción final en clasificación en random forest?

A Promedio de probabilidades

B Selección aleatoria

C Voto mayoritario ✓ RESPUESTA CORRECTA

D Regresión lineal

📘 **JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)**

En tareas de clasificación, Random Forest consolida las predicciones individuales de todos los árboles de decisión individuales mediante un mecanismo de agregación por voto mayoritario (hard voting) o promediando las distribuciones de probabilidad predichas por cada árbol (soft voting) y asignando la clase con mayor promedio (Diapositivas Tema 10, pág. 14).

⚠️ **TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO**

Distractor B (selección aleatoria) destruiría el poder predictivo del ensamble. Distractor D confunde clasificación con un modelo lineal continuo.

TAA | Tema 10: Random Forest | Test Oficial · Pregunta 32 | +0.75 pts / -0.25 pts

32. ¿Qué representa el out-of-bag error?

A Error en datos de entrenamiento

B Error en validación cruzada

C Error estimado usando datos no utilizados en el entrenamiento ✓ RESPUESTA CORRECTA

D Error absoluto medio

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El error Out-Of-Bag (OOB Error) es una estimación no sesgada del error de generalización calculada evaluando cada árbol del bosque únicamente sobre aquellas instancias del conjunto de datos original que NO fueron incluidas en su respectiva muestra bootstrap (aproximadamente el 36.8% de los datos queda 'out-of-bag' en cada muestra) (Diapositivas Tema 10, pág. 22; Breiman, 1996). Hace innecesaria una validación cruzada externa independiente.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A confunde OOB con error de entrenamiento empírico. Distractor B confunde OOB con K-fold cross-validation. Distractor D confunde el concepto metodológico con una métrica de regresión específica.

TAA | Tema 11: Parametrización y Optimización de Algoritmos | Test Oficial · Pregunta 33 | +0.75 pts / -0.25 pts

33. ¿Qué son los hiperparámetros?

A Parámetros aprendidos del modelo

B Parámetros definidos antes del entrenamiento ✓ RESPUESTA CORRECTA

C Variables dependientes del dataset

D Métricas de evaluación

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

Los hiperparámetros son configuraciones externas, propiedades estructurales o parámetros de control que son definidos y fijados por el científico de datos antes de iniciar el proceso de entrenamiento del modelo (por ejemplo, el parámetro C en SVM, la profundidad máxima max_depth en un árbol o el número de estimadores en un bosque) (Diapositivas Tema 11, pág. 6). A diferencia de los parámetros internos, no se aprenden directamente optimizando la función de pérdida con los datos.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A describe los parámetros internos del modelo (como los pesos w de una regresión o los umbrales de división del árbol). Distractor C describe variables del dataset. Distractor D describe funciones de evaluación.

TAA | Tema 11: Parametrización y Optimización de Algoritmos | Test Oficial · Pregunta 34 | +0.75 pts / -0.25 pts

34. ¿Cuál es la característica principal del grid search?

A Explora aleatoriamente los parámetros

B Realiza una búsqueda parcial

C Evalúa todas las combinaciones posibles ✓ RESPUESTA CORRECTA

D Usa aprendizaje automático

📘 **JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)**

La característica distintiva y definitoria del método Grid Search (búsqueda en rejilla) es que realiza una evaluación exhaustiva y determinista de todas y cada una de las combinaciones posibles en el producto cartesiano de los valores discretos predefinidos para los hiperparámetros especificados (Diapositivas Tema 11, pág. 14).

⚠️ **TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO**

Distractor A describe Random Search. Distractor B describe métodos heurísticos o de poda. Distractor D confunde un procedimiento de optimización iterativo con un modelo de ML predictivo en sí mismo.

TAA | Tema 11: Parametrización y Optimización de Algoritmos | Test Oficial · Pregunta 35 | +0.75 pts / -0.25 pts

35. ¿Cuál es la ventaja de random search sobre grid search?

A Siempre encuentra la mejor solución

B Reduce el número de hiperparámetros

C Es más eficiente en espacios de alta dimensión ✓ RESPUESTA CORRECTA

D No requiere evaluación

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

La gran ventaja matemática y computacional de Random Search (Bergstra & Bengio, 2012) sobre Grid Search radica en su eficiencia drásticamente superior cuando se optimizan espacios de hiperparámetros de alta dimensión o cuando solo unos pocos hiperparámetros son verdaderamente influyentes (Diapositivas Tema 11, pág. 21). Al muestrear aleatoriamente, explora un número mucho mayor de valores únicos para cada dimensión con el mismo presupuesto de evaluaciones.

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor A es falso: ningún método aleatorio garantiza encontrar siempre el óptimo global exacto en tiempo finito. Distractor B es falso: no reduce el número de hiperparámetros. Distractor D es absurdo, pues Random Search evalúa cada configuración mediante validación cruzada.

TAA | Tema 2: Análisis Descriptivo y Exploratorio de Datos (EDA) | Test Oficial · Pregunta 36 | +0.75 pts / -0.25 pts

36. ¿Cuál es la principal diferencia entre un diagrama de dispersión y una matriz de diagramas de dispersión?

A El diagrama de dispersión permite comparar dos variables, mientras que la matriz de diagramas de dispersión permite comparar varias variables entre sí mediante gráficos por pares. ✓ RESPUESTA CORRECTA

B El diagrama de dispersión muestra la relación entre dos variables, mientras que la matriz de diagramas de dispersión resume esas relaciones usando únicamente coeficientes numéricos.

C El diagrama de dispersión se utiliza cuando hay pocas observaciones, mientras que la matriz de diagramas de dispersión se utiliza solo cuando el conjunto de datos tiene muchas observaciones.

D El diagrama de dispersión representa una relación concreta entre dos variables, mientras que la matriz de diagramas de dispersión representa la evolución temporal de varias variables en paralelo.

📘 JUSTIFICACIÓN TEÓRICO-PRÁCTICA OFICIAL (UNIR)

El diagrama de dispersión clásico (bivariante) enfrenta visualmente dos variables numéricas en los ejes X e Y para identificar correlación o agrupación entre ese par concreto. En contraste, la matriz de diagramas de dispersión (Scatter Plot Matrix o pairplot) organiza una cuadrícula matricial de N x N donde cada celda interior proyecta el diagrama de dispersión bivariante entre todos los pares posibles de variables numéricas multivariantes del conjunto de datos (y las distribuciones univariantes en la diagonal principal) (Diapositivas Tema 2, pág. 28).

⚠️ TRAMPA DE EXAMEN FRECUENTE Y RAZONAMIENTO CRÍTICO

Distractor B afirma falsamente que la matriz usa solo coeficientes numéricos (eso sería una matriz de correlación o heatmap, no una matriz de gráficos). Distractor C es falso porque ambas herramientas se usan en datasets de diversos tamaños. Distractor D confunde la matriz multivariable con gráficos de series temporales.

Matriz de Confusión y Métricas de Rendimiento (Filtro Anti-Spam)

Imaginad que se os presenta la siguiente base de datos con 10 correos electrónicos evaluados por un clasificador binario (Clase Positiva = Spam, Clase Negativa = No spam):

Email	Clase Real	Clase Predicha
Email 1	Spam	Spam
Email 2	Spam	Spam
Email 3	No spam	No spam
Email 4	Spam	No spam
Email 5	No spam	Spam
Email 6	No spam	No spam
Email 7	Spam	Spam
Email 8	No spam	No spam
Email 9	No spam	No spam
Email 10	Spam	No spam

A partir de esta tabla de observaciones:
1. Construya la matriz de confusión detallada identificando TP, TN, FP y FN.
2. Calcule las métricas: Exactitud (Accuracy), Precisión (Precision), Sensibilidad (Recall), Especificidad (Specificity) y Puntuación F1 (F1-Score) para la clase Spam.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Construcción de la Matriz de Confusión: Definimos formalmente: • **Verdaderos Positivos (TP):** Real = Spam, Predicho = Spam -> Emails 1, 2 y 7 -> **TP = 3**. • **Verdaderos Negativos (TN):** Real = No spam, Predicho = No spam -> Emails 3, 6, 8 y 9 -> **TN = 4**. • **Falsos Positivos (FP - Error Tipo I):** Real = No spam, Predicho = Spam -> Email 5 -> **FP = 1**. • **Falsos Negativos (FN - Error Tipo II):** Real = Spam, Predicho = No spam -> Emails 4 y 10 -> **FN = 2**. • Total de observaciones = N = 10 (Total Reales Spam = TP + FN = 5; Total Reales No spam = TN + FP = 5).

Clase Real \ Predicción	Predicho: Spam (Positivo)	Predicho: No spam (Negativo)	Total Real
Real: Spam (Positivo)	**TP = 3**	**FN = 2**	P = 5
Real: No spam (Negativo)	**FP = 1**	**TN = 4**	N = 5
Total Predicho	3 + 1 = 4	2 + 4 = 6	Total = 10

2. Cálculo analítico de métricas de rendimiento: • **Exactitud (Accuracy):** $$Accuracy = \frac{TP + TN}{N} = \frac{3 + 4}{10} = \frac{7}{10} = 0.7000 \quad (70.0\%)$$ • **Precisión (Precision / Positive Predictive Value):** $$Precision = \frac{TP}{TP + FP} = \frac{3}{3 + 1} = \frac{3}{4} = 0.7500 \quad (75.0\%)$$ • **Sensibilidad (Recall / Sensibilidad / True Positive Rate):** $$Recall = \frac{TP}{TP + FN} = \frac{3}{3 + 2} = \frac{3}{5} = 0.6000 \quad (60.0\%)$$ • **Especificidad (Specificity / True Negative Rate):** $$Specificity = \frac{TN}{TN + FP} = \frac{4}{4 + 1} = \frac{4}{5} = 0.8000 \quad (80.0\%)$$ • **Puntuación F1 (F1-Score / Media armónica entre Precisión y Recall):** $$F_1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = 2 \cdot \frac{0.75 \cdot 0.60}{0.75 + 0.60} = 2 \cdot \frac{0.45}{1.35} = \frac{0.90}{1.35} = \frac{2}{3} \approx 0.6667 \quad (66.67\%)$$ • **Exactitud**

Equilibrada (Balanced Accuracy): $$Balanced\;Accuracy = \frac{Recall + Specificity}{2} = \frac{0.60 + 0.80}{2} = 0.7000 \quad (70.0\%)$$

📘 FUNDAMENTACIÓN TEÓRICA Y METODOLÓGICA (UNIR)

Las métricas de evaluación de clasificación se derivan unívocamente de la descomposición formal de aciertos y errores en la matriz de confusión (Diapositivas Tema 5, págs. 11-18; Prof.ª María Flores Ceballos). En tareas de filtrado anti-spam o detección de anomalías, la precisión mide la fiabilidad de las alertas generadas (evitar clasificar un correo legítimo como spam), mientras que el recall mide la cobertura de detección de correos maliciosos reales. La media armónica F1 penaliza desproporcionadamente cuando cualquiera de las dos métricas fundamentales se desploma.

⚠️ CLAVES DE CORRECCIÓN Y TRAMPAS DEL TRIBUNAL EXAMINADOR

Trampa clásica de examen: Confundir el denominador de la Precisión (TP + FP = total de predicciones positivas) con el denominador del Recall (TP + FN = total de casos verdaderamente positivos en la realidad). En este ejercicio, 3/4 = 0.75 vs 3/5 = 0.60. Si se calculan al revés, se pierde la totalidad del puntaje numérico del ejercicio.

TAA | Tema 8: Clasificación con Naïve Bayes | Ejercicio Oficial de Cálculo (Probabilidad y Bayes) | TAA-EJ-02

Inferencia Bayesiana y Probabilidad a Posteriori Clínica

Un hospital está construyendo un modelo para detectar si un paciente tiene una enfermedad respiratoria (E) o no (N) usando dos síntomas: tos y fiebre. Se está desarrollando un modelo de clasificación utilizando Naïve Bayes para predecir si una persona está enferma o no. Se ha calculado la tabla de verosimilitud para los síntomas tos y fiebre sobre una muestra de 100 pacientes (20 enfermos y 80 no enfermos). Los resultados se presentan a continuación:

Diagnóstico	Tos		Fiebre		Total Clase
	Sí	No	Sí	No	
Enfermo (E)	4/20	16/20	10/20	10/20	20
No enfermo (N)	1/80	79/80	1/80	79/80	80

Basándose en esta información y haciendo uso del Teorema de Bayes:
$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}$$
¿Cuál es la probabilidad a posteriori de que una persona esté enferma sabiendo que tiene fiebre, $P(E|\text{fiebre})$?

RESOLUCIÓN OFICIAL PASO A PASO

Resolución paso a paso: 1. Extracción de probabilidades a priori $P(C)$: • Tamaño total de la muestra: $N = 20 + 80 = 100$ pacientes. • Probabilidad a priori de estar enfermo: $$P(E) = \frac{20}{100} = 0.20$$ • Probabilidad a priori de no estar enfermo: $$P(N) = \frac{80}{100} = 0.80$$ **2. Extracción de verosimilitudes condicionales de la tabla:** • Verosimilitud de presentar fiebre dado que está enfermo: $$P(\text{fiebre}|E) = \frac{10}{20} = 0.50$$ • Verosimilitud de presentar fiebre dado que no está enfermo: $$P(\text{fiebre}|N) = \frac{1}{80} = 0.0125$$ **3. Cálculo de la probabilidad marginal de la evidencia $P(\text{fiebre})$ (Teorema de la Probabilidad Total):** $$P(\text{fiebre}) = P(E) \cdot P(\text{fiebre}|E) + P(N) \cdot P(\text{fiebre}|N)$$ $$P(\text{fiebre}) = (0.20 \cdot 0.50) + (0.80 \cdot 0.0125) = 0.10 + 0.01 = 0.11 = \frac{11}{100}$$ **4. Aplicación del Teorema de Bayes para la probabilidad a posteriori:** $$P(E|\text{fiebre}) = \frac{P(E) \cdot P(\text{fiebre}|E)}{P(\text{fiebre})} = \frac{\frac{20}{100} \cdot \frac{10}{20}}{\frac{11}{100}} = \frac{\frac{10}{100}}{\frac{11}{100}} = \frac{10}{11} \approx 0.90909 \quad (90.91\%)$$ **Conclusión clínica:** Aunque la prevalencia a priori de la enfermedad en la población es relativamente baja (20%), la presencia del síntoma

fiebre multiplica drásticamente la probabilidad a posteriori hasta el 90.91%, debido a que la tasa de falsos positivos en personas no enfermas es sumamente reducida ($1/80 = 1.25\%$).

📘 **FUNDAMENTACIÓN TEÓRICA Y METODOLÓGICA (UNIR)**

El clasificador Naïve Bayes aplica formalmente el principio de estimación MAP (Maximum A Posteriori) integrando el conocimiento previo poblacional con la evidencia empírica observada (Diapositivas Tema 8, págs. 9-15; Prof.ª María Flores Ceballos). El denominador normalizador actúa como factor de escala sobre el espacio de hipótesis excluyentes.

⚠️ **CLAVES DE CORRECCIÓN Y TRAMPAS DEL TRIBUNAL EXAMINADOR**

Trampa clásica de examen: Olvidar ponderar la verosimilitud de los no enfermos por su probabilidad a priori $P(N) = 0.80$, sumando directamente $10/20 + 1/80$. Otro error frecuente es omitir el cálculo del denominador total $P(\text{fiebre})$, asumiendo erróneamente que $P(E|\text{fiebre}) = P(\text{fiebre}|E) = 0.50$ (Falacia del fiscal / transposición de la condicional).

TAA | Tema 9: Combinación de Clasificadores | Ejercicio Teórico-Práctico Oficial | TAA-EJ-03

Actualización Analítica de Pesos y Parámetro Alfa en AdaBoost

En el algoritmo de Boosting AdaBoost (Freund & Schapire, 1997):
1. ¿Cuál es la formulación matemática y el significado analítico del parámetro α_m asignado a cada clasificador base $G_m(x)$ en la ronda m?
2. ¿Cómo se actualizan los pesos de las observaciones $w_{m+1, i}$ para la siguiente iteración? Demuestre algebraicamente qué ocurre cuando un clasificador base obtiene un error $\epsilon_m < 0.5$, $\epsilon_m = 0.5$ y $\epsilon_m > 0.5$.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Formulación analítica y significado de α_m: En cada ronda $m = 1, \dots, M$, se evalúa el error ponderado del clasificador base débil: $$\epsilon_m = \frac{\sum_{i=1}^N w_{m, i} \cdot \mathbb{I}(y_i \neq G_m(x_i))}{\sum_{i=1}^N w_{m, i}}$$ El peso o factor de confianza del clasificador α_m se calcula como: $$\alpha_m = \frac{1}{2} \ln\left(\frac{1 - \epsilon_m}{\epsilon_m}\right)$$ **Significado analítico:** α_m representa el poder de voto que tendrá el clasificador $G_m(x)$ en el ensamble final $G(x) = \text{sign}\left(\sum_{m=1}^M \alpha_m G_m(x)\right)$. • Si $\epsilon_m \to 0$ (clasificador casi perfecto): $\frac{1 - \epsilon_m}{\epsilon_m} \to \infty \implies \alpha_m \to +\infty$ (recibe voto prioritario determinante). • Si $\epsilon_m = 0.5$ (clasificador equivalente al azar binario): $\frac{1 - 0.5}{0.5} = 1 \implies \alpha_m = \frac{1}{2} \ln(1) = 0$ (el clasificador es descartado; su voto vale exactamente cero). • Si $\epsilon_m > 0.5$ (clasificador peor que el azar): $\alpha_m < 0$ (su voto es negativo, lo que equivale a invertir todas sus predicciones para aprovechar su capacidad discriminativa). **2. Ecuación de actualización de pesos de las muestras:** Los pesos de cada instancia i para la ronda $m+1$ se actualizan según: $$w_{m+1, i} = w_{m, i} \cdot \exp\left(-\alpha_m \cdot y_i \cdot G_m(x_i) \right) = w_{m, i} \cdot \exp\left(\alpha_m \cdot \mathbb{I}(y_i \neq G_m(x_i)) \right)$$ Posteriormente se normalizan dividiendo por $Z_m = \sum_{i=1}^N w_{m+1, i}$ para que sumen 1. • Para instancias bien clasificadas ($y_i = G_m(x_i)$): el exponente es $-\alpha_m$, por lo que su peso se multiplica por $e^{-\alpha_m} < 1$, reduciendo su importancia relativa. • Para instancias mal clasificadas ($y_i \neq G_m(x_i)$): el exponente es $+\alpha_m$, por lo que su peso se multiplica por $e^{\alpha_m} > 1$, aumentando drásticamente su ponderación y forzando al siguiente estimador G_{m+1} a concentrarse en resolver dichos ejemplos difíciles.

📘 FUNDAMENTACIÓN TEÓRICA Y METODOLÓGICA (UNIR)

AdaBoost optimiza de manera voraz (greedy) por etapas la función de pérdida exponencial $L(y, f(x)) = \exp(-y f(x))$ (Diapositivas Tema 9, págs. 17-23; Hastie et al., 2009; Prof.ª María Flores Ceballos). Se demuestra matemáticamente que el error de entrenamiento decrece exponencialmente con el número de rondas si cada estimador débil supera ligeramente el azar ($\\epsilon_m < 0.5$).

⚠️ CLAVES DE CORRECCIÓN Y TRAMPAS DEL TRIBUNAL EXAMINADOR

Pregunta con trampa de examen: '¿Qué ocurre si un clasificador base tiene un error del 70% ($\\epsilon_m = 0.70$)? ¿Debe eliminarse inmediatamente?'. Respuesta crítica: No necesariamente; con $\\alpha_m = \\frac{1}{2}\\ln(0.3/0.7) < 0$, si se invierte su predicción se convierte en un clasificador con un 30% de error, aportando información útil al ensamble.

TAA | Tema 6: Árboles de Decisión (CART) | Ejercicio Teórico-Práctico Oficial | TAA-EJ-04

Criterios de División: Impureza de Gini vs. Entropía de Shannon

En la construcción de árboles de decisión (algoritmos CART y C4.5):
1. Defina analíticamente el Índice de Impureza de Gini y la Entropía de Shannon para un nodo con K clases.
2. Compare ambos criterios respecto a su rango numérico, coste computacional y comportamiento ante nodos puros y mezclas equitativas.
3. Explique la naturaleza geométrica de las particiones inducidas en el espacio de características.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Definición analítica: Para un nodo t con proporciones empíricas de clase p_k ($k = 1, \dots, K$, donde $\sum_{k=1}^K p_k = 1$): • **Impureza de Gini (CART - Breiman et al., 1984):** $$I_G(t) = 1 - \sum_{k=1}^K p_k^2 = \sum_{k \neq j} p_k p_j$$ • **Entropía de Shannon (ID3 / C4.5 - Quinlan, 1986):** $$H(t) = -\sum_{k=1}^K p_k \log_2(p_k) \quad (\text{asumiendo } 0 \log_2 0 = 0)$$ **2. Tabla comparativa rigurosa:**

Propiedad	Índice de Gini (CART)	Entropía de Shannon (C4.5)
Rango (Caso binario K=2)	$[0, 0.50]$ (Máximo en $p = 0.5$)	$[0, 1.00]$ (Máximo en $p = 0.5$)
Nodo perfectamente puro	$I_G = 1 - (1^2 + 0^2) = 0$	$H = -(1 \log_2 1 + 0) = 0$
Nodo máxima impureza (K=2)	$I_G = 1 - (0.5^2 + 0.5^2) = 0.50$	$H = -(0.5 \log_2 0.5 + 0.5 \log_2 0.5) = 1.00$
Coste computacional	**Muy bajo:** Solo sumas y multiplicaciones polinomiales	**Moderado/Alto:** Requiere cálculo de logaritmos en base 2
Preferencia en la práctica	Es el estándar por defecto en Scikit-Learn (rápido y eficiente)	Útil para fundamentación teórica de Ganancia de Información

3. Geometría de las particiones del espacio: Los árboles de decisión univariantes estándar operan seleccionando una sola variable continua X_j y un umbral c en cada nodo interno ($X_j \le c$). Por consiguiente, cada partición induce un **hiperplano ortogonal (perpendicular) a los ejes de coordenadas**. El espacio de entrada se divide recursivamente en hiperrectángulos alineados con los ejes (axis-aligned boxes). Esto hace que los árboles aproximen fronteras no lineales mediante funciones escalonadas, requiriendo muchas divisiones para modelar fronteras diagonales suaves.

📘 FUNDAMENTACIÓN TEÓRICA Y METODOLÓGICA (UNIR)

Ambos criterios miden la dispersión o impureza de una distribución de probabilidad multinomial y en el 98% de los problemas reales seleccionan divisiones idénticas (Diapositivas Tema 6, págs. 9-16; Prof.ª María Flores Ceballos). La función Gini es una aproximación de Taylor de primer orden de la entropía alrededor de las probabilidades uniformes.

⚠️ CLAVES DE CORRECCIÓN Y TRAMPAS DEL TRIBUNAL EXAMINADOR

Pregunta capciosa de examen: '¿Cuál es el valor máximo del índice de Gini en un problema binario?'. El estudiante suele responder '1.0' por analogía con la entropía, cuando el valor máximo exacto es 0.50.

Regresión Clínica: Predicción de Estancia Hospitalaria COVID-19

Enunciado oficial de examen:
Tarea: Regresión: predecir la duración de la estancia hospitalaria (en días) de pacientes COVID-19 a partir de variables demográficas (edad, sexo), comorbilidades (diabetes, hipertensión) y parámetros clínicos al ingreso (saturación de oxígeno, proteína C reactiva, dímero D).
Se solicita estructurar la resolución en 3 apartados rigurosos:
1. Análisis exploratorio de datos (EDA) y preprocesamiento necesario.
2. Selección fundamentada de algoritmos de aprendizaje automático a comparar.
3. Protocolo de evaluación experimental, métricas clínicas y análisis de residuos.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Análisis Exploratorio de Datos (EDA) y Preprocesamiento: • **Auditoría de la variable objetivo:** Comprobar la no negatividad de 'días de estancia' ($y \ge 0$) y ausencia de incoherencias temporales (fecha de alta previa al ingreso). Tratar los pacientes sin hospitalización según el alcance (exclusión o asignación controlada). • **Distribución y asimetría:** Analizar histogramas y boxplots; la estancia hospitalaria exhibe típicamente asimetría positiva severa (cola derecha larga de pacientes en UCI). Considerar transformación logarítmica $\ln(y + 1)$ si se aplican modelos lineales. • **Tratamiento de valores ausentes sin fuga de información (Data Leakage):** - Identificar mecanismos (MCAR vs MAR). - Imputar variables clínicas con la mediana o KNN dentro de un pipeline ajustado estrictamente sobre el conjunto de entrenamiento (evitando usar estadísticos del conjunto global). • **Detección de multicolinealidad:** Analizar la matriz de correlación de Pearson y factor de inflación de la varianza (VIF) entre biomarcadores inflamatorios. • **Escalado:** Aplicar RobustScaler o StandardScaler para variables con outliers evidentes. **2. Selección fundamentada de algoritmos:** Se propone una comparativa entre dos familias algorítmicas complementarias: • **Modelo de Referencia / Interpretable (Baseline):** Regresión Lineal Regularizada (Ridge / Lasso / ElasticNet). - *Justificación:* Permite inferir el efecto marginal medio y la significancia clínica directa de cada biomarcador (coeficientes β_j). La regularización L1 (Lasso) permite selección automática de biomarcadores irrelevantes. • **Modelo de Alta Capacidad No Lineal:** Ensamble basado en árboles (Random Forest Regressor o Gradient Boosting Regressor / XGBoost). - *Justificación:* Captura interacciones de orden superior (p. ej., el impacto conjunto de edad avanzada + diabetes en la PCR) y relaciones no lineales complejas sin requerir especificación manual de polinomios, siendo el estado del arte en datos tabulares clínicos. **3. Protocolo de evaluación, métricas y residuos:** • **Partición de datos:** Validación cruzada K-fold estratificada (o agrupada si hay múltiples registros por paciente) con split Train/Test (80/20) completamente desacoplado. • **Métricas cuantitativas:** - **MAE (Mean Absolute Error):** Expresa el error medio directamente en días reales ($|y - \hat{y}|$), facilitando la comunicación intuitiva al personal médico. - **RMSE (Root Mean Squared Error):** Penaliza severamente los errores grandes en pacientes con estancias muy prolongadas. - **R^2 (Coeficiente de Determinación):** Cuantifica la proporción de varianza de la estancia explicada por los predictores clínicos. • **Análisis diagnóstico de residuos:** Graficar residuos ($y - \hat{y}$) frente a predicciones para verificar homocedasticidad, normalidad y ausencia de patrones sistemáticos de infraestimación en casos graves.

📘 FUNDAMENTACIÓN TEÓRICA Y METODOLÓGICA (UNIR)

La estructura de respuesta satisface con máxima calificación la rúbrica oficial de la UNIR para el apartado de Análisis (4 puntos sobre 10) establecida por la Prof.ª María Flores Ceballos, combinando rigor metodológico, prevención de data leakage y justificación clínica de algoritmos.

⚠️ CLAVES DE CORRECCIÓN Y TRAMPAS DEL TRIBUNAL EXAMINADOR

Errores fatales sancionados en examen: 1) Escalar o imputar datos antes de hacer el train_test_split (fuga de datos); 2) Proponer clasificación para predecir 'días de estancia' (es una variable numérica continua, por ende es regresión); 3) Proponer únicamente redes neuronales complejas sin un modelo baseline interpretable.

TAA | Tema 5 / Tema 10: Metodología de Clasificación | Caso Práctico Oficial de Análisis (Agrícola) | TAA-EJ-06

Clasificación Agrícola: Detección Temprana de Riesgo de Plaga

Enunciado oficial de examen:
Tarea: Clasificación binaria: predecir si una parcela agrícola está en alto riesgo de plaga (1) o riesgo normal (0) en la próxima semana, usando datos históricos de clima (temperatura, humedad acumulada), propiedades del suelo, manejo del cultivo y observaciones agronómicas.
Indique detalladamente:
1. Análisis exploratorio y tratamiento del desbalanceo de clases.
2. Algoritmos propuestos con su debida justificación técnico-agronómica.
3. Estrategia de partición temporal y métricas idóneas.

✅ **RESOLUCIÓN OFICIAL PASO A PASO**

1. Análisis Exploratorio y Desbalanceo de Clases: • **Desbalanceo severo de clases:** Los brotes de plagas representan eventos minoritarios (típicamente $< 5\%$ de las observaciones). La Exactitud (Accuracy) queda completamente invalidada como métrica de éxito (un clasificador trivial que prediga siempre 0 obtendría un engañoso 95% de acierto sin detectar ninguna plaga). • **Estrategias de mitigación:** - Ponderación de pesos de clase inversamente proporcionales a su frecuencia (`class_weight='balanced'`). - Técnicas de remuestreo aplicadas exclusivamente sobre el conjunto de entrenamiento (SMOTE o submuestreo de la clase mayoritaria). • **Estudio de relaciones no lineales y retardos:** Creación de variables rezagadas (lag features de temperatura y humedad en los últimos 7 y 14 días), cruciales para la incubación biológica de patógenos. **2. Algoritmos propuestos y justificación:** • **Modelo Base:** Regresión Logística con regularización ElasticNet (`penalty='elasticnet'`). - *Justificación:* Modelo lineal calibrado probabilísticamente que proporciona odds-ratios interpretables para los agrónomos. • **Modelo Ensamble Avanzado:** Random Forest Classifier o LightGBM Classifier. - *Justificación:* Excelente capacidad para modelar efectos umbral biológicos (p. ej. las esporas proliferan solo si la humedad excede el 85% y la temperatura supera los 20°C de forma simultánea). Resistente al sobreajuste mediante selección aleatoria de atributos y remuestreo bootstrap. **3. Estrategia de partición y métricas idóneas:** • **Validación Temporal (Time-Series Split / Rolling Window):** Prohibido usar K-fold aleatorio convencional, dado que los datos agronómicos presentan una fuerte autocorrelación temporal y espacial. La partición debe entrenar con semanas pasadas y evaluar en semanas futuras. • **Métricas prioritarias:** - **Recall / Sensibilidad de la clase Plaga (1):** Máxima prioridad para el agricultor, pues un falso negativo (no detectar la plaga a tiempo) provoca la pérdida total de la cosecha. - **Precision-Recall AUC (PR-AUC):** Métrica estándar de referencia en clasificación desbalanceada, infinitamente superior a ROC-AUC cuando la clase positiva es escasa.

📘 **FUNDAMENTACIÓN TEÓRICA Y METODOLÓGICA (UNIR)**

Alineado con los estándares del aprendizaje supervisado aplicado y las directrices docentes del Máster UNIR en modelado predictivo de eventos raros (Diapositivas Temas 2, 5 y 10).

⚠️ **CLAVES DE CORRECCIÓN Y TRAMPAS DEL TRIBUNAL EXAMINADOR**

El error más grave en este problema es reportar el 'Accuracy' como métrica principal o realizar una división de datos aleatoria que mezcle semanas contiguas, introduciendo una enorme fuga temporal (data leakage temporal).

2. Procesamiento del Lenguaje Natural (PLN)

Contenidos evaluados: Modelado Estadístico del Lenguaje, HMM y Algoritmo de Viterbi, Parsing CKY, Desambiguación Léxica (Lesk, Schütze, Yarowsky) y Modelos Transformers.

PLN | Tema 3: Modelos Ocultos de Markov (HMM) | Ejercicio Oficial de Examen | PLN-EJ-01

Algoritmo de Viterbi para Etiquetado Morfosintáctico (POS Tagging)

Dado un modelo oculto de Markov (HMM) para etiquetado morfosintáctico con dos estados ocultos: S (Sustantivo) y V (Verbo), y los siguientes parámetros probabilísticos:

• **Probabilidades iniciales π:**
$$\pi(S) = 0.60, \quad \pi(V) = 0.40$$
• **Matriz de transiciones A ($P(t_i|t_{i-1})$):**
$$P(S|S) = 0.30, \quad P(V|S) = 0.70$$
$$P(S|V) = 0.80, \quad P(V|V) = 0.20$$
• **Matriz de emisiones B ($P(palabra|etiqueta)$):**
$$P(\text{"come"}|S) = 0.10, \quad P(\text{"come"}|V) = 0.60$$
$$P(\text{"pan"}|S) = 0.80, \quad P(\text{"pan"}|V) = 0.05$$

Aplique el **Algoritmo de Viterbi** para determinar la secuencia de etiquetas morfosintácticas más probable para la frase de dos palabras:

"come pan"

Muestre la formulación matemática de cada celda del Trellis, los valores numéricos calculados, los punteros de retroceso (backpointers) y el camino óptimo decodificado.

✅ **RESOLUCIÓN OFICIAL PASO A PASO**

1. Formulación matemática fundamental del algoritmo de Viterbi: La probabilidad máxima acumulada en el paso temporal t para el estado oculto j se define como: $$v_t(j) = \max_{i} \left[v_{t-1}(i) \cdot a_{ij} \right] \cdot b_j(o_t)$$ donde el puntero de retroceso que almacena el estado predecesor óptimo es: $$bp_t(j) = \arg\max_{i} \left[v_{t-1}(i) \cdot a_{ij} \right]$$ **2. Paso 1: Palabra 1 = "come" ($t = 1$):** Se calcula el producto de la probabilidad inicial por la probabilidad de emisión de la primera observación: • Para el estado S: $$v_1(S) = \pi(S) \cdot P(\text{"come"}|S) = 0.60 \cdot 0.10 = 0.0600 \quad (bp_1(S) = \emptyset)$$ • Para el estado V: $$v_1(V) = \pi(V) \cdot P(\text{"come"}|V) = 0.40 \cdot 0.60 = 0.2400 \quad (bp_1(V) = \emptyset)$$ **3. Paso 2: Palabra 2 = "pan" ($t = 2$):** Se calcula la transición desde cada posible estado previo multiplicada por la probabilidad de emisión de "pan": • Para el estado S: $$\text{Candidato desde } S: v_1(S) \cdot P(S|S) = 0.0600 \cdot 0.30 = 0.0180$$ $$\text{Candidato desde } V: v_1(V) \cdot P(S|V) = 0.2400 \cdot 0.80 = 0.1920$$ $$v_2(S) = \max(0.0180, 0.1920) \cdot P(\text{"pan"}|S) = 0.1920 \cdot 0.80 = \mathbf{0.1536}$$ Puntero de retroceso: Provino de $V \implies bp_2(S) = V$. • Para el estado V: $$\text{Candidato desde } S: v_1(S) \cdot P(V|S) = 0.0600 \cdot 0.70 = 0.0420$$ $$\text{Candidato desde } V: v_1(V) \cdot P(V|V) = 0.2400 \cdot 0.20 = 0.0480$$ $$v_2(V) = \max(0.0420, 0.0480) \cdot P(\text{"pan"}|V) = 0.0480 \cdot 0.05 = \mathbf{0.0024}$$ Puntero de retroceso: Provino de $V \implies bp_2(V) = V$. **4. Terminación y Decodificación Óptima (Backtracking):** • Probabilidad de la secuencia más probable: $$P^* = \max(v_2(S), v_2(V)) = \max(0.1536, 0.0024) = \mathbf{0.1536}$$ • Estado final óptimo en $t = 2$: $$t_2^* = \arg\max(v_2(S), v_2(V)) = \mathbf{S} \quad (\text{Sustantivo})$$ • Recuperación del estado en $t = 1$ mediante el backpointer: $$t_1^* = bp_2(S) = \mathbf{V} \quad (\text{Verbo})$$ **Secuencia óptima de etiquetado:**

"come" $\to$ V (Verbo) + **"pan" $\to$ S (Sustantivo)**

La secuencia de etiquetas gramaticales más probable para "come pan" es unívocamente **[V, S]** con una verosimilitud conjunta máxima de **0.1536**.

📘 FUNDAMENTACIÓN TEÓRICA Y LINGÜÍSTICA (UNIR)

El Algoritmo de Viterbi es una técnica canónica de programación dinámica con complejidad temporal $O(T \cdot |S|^2)$ que encuentra la secuencia globalmente óptima de estados ocultos (máximo a posteriori) sin necesidad de evaluar exhaustivamente las $|S|^T$ combinaciones posibles (Diapositivas PLN Tema 3, págs. 14-22; Jurafsky & Martin, 2023).

⚠️ ERRORES TÍPICOS Y TRAMPAS DE EXAMEN

Trampa clásica de examen: Asignar etiquetas de forma voraz e independiente en cada palabra (asumiendo que en $t=1$ 'come' es V y en $t=2$ 'pan' es S solo por emisión), sin computar formalmente la transición $P(S|V) = 0.80$. Aunque el resultado final coincida en este caso simple, en el examen oficial de la UNIR se evalúa con 0 puntos si no se plasma el producto matricial completo del Trellis y los backpointers.

PLN | Tema 7: Modelos Estadísticos del Lenguaje y N-Gramas | Ejercicio Oficial de Examen | PLN-EJ-02

Suavizado de Laplace, Estimación de N-Gramas y Perplejidad

1. Explique por qué el estimador de máxima verosimilitud (MLE) estándar para modelos de lenguaje basados en bigramas falla en la práctica ante corpus reales.
2. Desarrolle la formulación matemática del Suavizado de Laplace (Add-1) y del Suavizado Add-k para bigramas.
3. Defina analíticamente la **Perplejidad (PP)** de un modelo de lenguaje sobre una secuencia de prueba $W = w_1, w_2, \dots, w_N$ y explique su relación matemática con la entropía cruzada del modelo.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Fallo del Estimador de Máxima Verosimilitud (MLE): Bajo el estimador MLE para bigramas, la probabilidad condicional se estima por conteos brutos: $$P_{MLE}(w_i | w_{i-1}) = \frac{C(w_{i-1}, w_i)}{C(w_{i-1})}$$ En un texto real no visto en entrenamiento, inevitablemente aparecerán pares de palabras legítimas cuyo conteo conjunto sea $C(w_{i-1}, w_i) = 0$. Como la probabilidad de una frase completa es el producto de probabilidades encadenadas ($P(W) = \prod_{i=1}^N P(w_i | w_{i-1})$), **un solo bigrama no observado asigna probabilidad cero a todo el texto ($P(W) = 0$)**. Esto se conoce como el *problema de la frecuencia cero* y genera una perplejidad infinita ($PP = \infty$). **2. Formulación matemática del Suavizado de Laplace:** Para garantizar que ninguna transición tenga probabilidad nula, se añade una pseudocuenta a todos los eventos posibles. Si V denota el tamaño del vocabulario: • **Suavizado Add-1 (Laplace estándar):** $$P_{\text{Laplace}}(w_i | w_{i-1}) = \frac{C(w_{i-1}, w_i) + 1}{C(w_{i-1}) + |V|}$$ Se suma $|V|$ en el denominador para asegurar que $\sum_{w_i \in V} P(w_i | w_{i-1}) = 1$. • **Suavizado Add-$k$ (Lidstone / Jeffreys):** Como Add-1 transfiere demasiada masa probabilística a bigramas inexistentes cuando $|V|$ es inmenso ($|V| > 100,000$), se utiliza un valor fraccionario $k \in (0, 1)$ (típicamente $k = 0.05$): $$P_{\text{Add-}k}(w_i | w_{i-1}) = \frac{C(w_{i-1}, w_i) + k}{C(w_{i-1}) + k \cdot |V|}$$ **3. Formulación matemática de la Perplejidad (PP):** La Perplejidad cuantifica qué tan 'sorprendido' queda el modelo ante el texto de test. Se define como la inversa de la probabilidad geométrica media asignada a las palabras de la secuencia normalizada por la longitud N: $$PP(W) = P(w_1, w_2, \dots, w_N)^{-\frac{1}{N}} = \sqrt[N]{\frac{1}{P(w_1, w_2, \dots, w_N)}} = \sqrt[N]{\prod_{i=1}^N \frac{1}{P(w_i | w_{i-1})}}$$ Aplicando logaritmos en base 2, se demuestra su equivalencia directa con la **Entropía Cruzada empírica $H(W)$**: $$H(W) = -\frac{1}{N} \sum_{i=1}^N \log_2 P(w_i | w_{i-1}) \implies PP(W) = 2^{H(W)}$$ **Interpretación:** Un valor menor de perplejidad indica un modelo de lenguaje de mayor calidad predictiva (un modelo con $PP = 64$ equivale a dudar equitativamente entre 64 palabras en cada paso).

📘 FUNDAMENTACIÓN TEÓRICA Y LINGÜÍSTICA (UNIR)

Constituye la base teórica de la evaluación intrínseca de modelos de lenguaje probabilísticos (Diapositivas PLN Tema 7, págs. 8-19; Jurafsky & Martin, 2023).

⚠️ ERRORES TÍPICOS Y TRAMPAS DE EXAMEN

En examen: olvidar sumar $k \cdot |V|$ en el denominador (sumar solo k), violando el axioma de Kolmogórov de que la suma de probabilidades sobre el espacio muestral debe ser igual a 1.

PLN | Tema 2: Preprocesamiento y Representación Vectorial | Ejercicio Oficial de Examen | PLN-EJ-03

Pipeline spaCy, Lematización vs. Stemming y Ponderación TF-IDF

1. Describa la secuencia de componentes del pipeline estándar de procesamiento de texto en spaCy (`nlp(texto)`).
2. Justifique formalmente las diferencias lingüísticas y computacionales entre **Lematización** y **Stemming**, indicando en qué casos de uso en PLN es preferible cada técnica.
3. Calcule paso a paso la matriz de ponderación TF-IDF para un término t que aparece 4 veces en un documento de 100 palabras, sabiendo que el corpus total consta de $N = 10,000$ documentos y dicho término aparece en $DF(t) = 100$ documentos (utilice logaritmo decimal o natural).

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Componentes del Pipeline estándar de spaCy: El objeto `Doc` se procesa secuencialmente mediante una cadena de transformadores: 1. `Tokenizer` (Segmentación léxica): Divide el texto bruto en tokens individuales (no destructivo, preserva índices). 2. `Tagger` (Etiquetado POS): Asigna categorías morfosintácticas finas (Penn Treebank) y universales (Universal POS). 3. `Morphologizer`: Extrae rasgos flexivos (tiempo verbal, género, número, caso). 4. `Parser` (Análisis de dependencias sintácticas): Construye el árbol de dependencias que conecta cabezas sintácticas y modificadores. 5. `Lemmatizer`: Resuelve la forma canónica de diccionario basada en el análisis morfosintáctico del tagger. 6. `NER (Named Entity Recognizer)`: Identifica entidades nombradas (PERSON, ORG, GPE, DATE). 7. `AttributeRuler / TextCategorizer`: Reglas de atributos específicos y clasificación documental final. **2. Lematización vs. Stemming:**

Criterio	Lematización (spaCy / WordNet)	Stemming (Algoritmo de Porter / Snowball)
Fundamento	Morfológico y lexicográfico formal (requiere diccionario y POS tag previo).	Algoritmo heurístico de recorte de sufijos mediante reglas empíricas en cascada.
Resultado	Retorna una palabra válida y existente en el diccionario (el lema: p. ej., *mejor* $\to$ *bueno*; *estuvimos* $\to$ *estar*).	Retorna una raíz o pseudopalabra que puede no existir en el idioma (p. ej., *universal* $\to$ *univers*; *ciencias* $\to$ *cienc*).
Coste computacional	Mayor coste: Requiere etiquetado sintáctico previo y consulta a lexicones.	Extremadamente rápido: Opera en tiempo lineal sin cargar modelos ni recursos lingüísticos.
Caso de uso idóneo	Extracción de información médica, sistemas de preguntas y respuestas (QA) y análisis semántico.	Motores de búsqueda de información masiva (IR) y motores de indexación web a gran escala.

3. Cálculo analítico de TF-IDF: • **Frecuencia del término (TF):** $$TF(t, d) = \frac{\text{Frecuencia de } t \text{ en } d}{\text{Total de palabras en } d} = \frac{4}{100} = 0.04$$ • **Frecuencia inversa de documento (IDF) con logaritmo decimal:** $$IDF(t, D) = \log_{10}\left(\frac{N}{DF(t)}\right) = \log_{10}\left(\frac{10,000}{100}\right) = \log_{10}(100) = 2.0$$ • **Ponderación TF-IDF:** $$TF\text{-}IDF(t, d, D) = TF(t, d) \cdot IDF(t, D) = 0.04 \cdot 2.0 = \mathbf{0.0800}$$

📘 FUNDAMENTACIÓN TEÓRICA Y LINGÜÍSTICA (UNIR)

Tema 2 PLN UNIR; Salton & Buckley (1988). TF-IDF equilibra la saliencia local de un término dentro de un documento frente a su carácter discriminativo global en el corpus.

⚠️ **ERRORES TÍPICOS Y TRAMPAS DE EXAMEN**

Confundir $DF(t)$ (número de documentos donde aparece) con el conteo total de apariciones del término en todo el corpus. El denominador de IDF siempre es el número de documentos, no el total de palabras.

PLN | Tema 5: Desambiguación Léxica (WSD) | Ejercicio Oficial de Examen | PLN-EJ-04

Algoritmo de Lesk Original vs. Lesk Simplificado

Explique el funcionamiento del **Algoritmo de Lesk (1986)** para la desambiguación del sentido de las palabras (WSD). Contraste formalmente el algoritmo de Lesk original frente al algoritmo de Lesk simplificado y resuelva el ejemplo clásico de desambiguación de la palabra polisémica 'banco' (entidad financiera vs. asiento de parque).

✅ **RESOLUCIÓN OFICIAL PASO A PASO**

1. Fundamento conceptual del Algoritmo de Lesk: Propuesto por Michael E. Lesk en 1986, el algoritmo opera bajo la hipótesis de que las palabras que coocurren en una misma oración o contexto discursivo tienden a compartir un dominio semántico coherente. Por lo tanto, el sentido correcto de una palabra ambigua es aquel cuya definición o glosa en un diccionario formal (como WordNet) presenta el **mayor solapamiento léxico (overlap de palabras compartidas)** con las definiciones o palabras del contexto circundante. **2. Lesk Original vs. Lesk Simplificado (Kilgarriff & Rosenzweig, 2000):** • **Lesk Original (1986):** Calcula el solapamiento entre las *glosas de todas las palabras* que aparecen en la ventana de contexto de forma combinatoria simultánea. Si hay k palabras con s sentidos cada una, el espacio de búsqueda combinatorio es $O(s^k)$, lo cual es computacionalmente prohibitivo para oraciones largas. • **Lesk Simplificado:** Desambigua una palabra objetivo w a la vez. Compara la glosa de cada sentido posible de w en WordNet directamente contra **las palabras presentes en la propia frase u oración de contexto**, eliminando palabras vacías (stop words): $$\hat{s} = \arg\max_{s \in \text{Sentidos}(w)} \left| \text{Palabras}(\text{Glosa}(s)) \cap \text{Palabras}(\text{Contexto}) \right|$$ La complejidad se reduce a $O(s)$, siendo sumamente rápido y eficiente. **3. Ejemplo práctico resuelto: Desambiguación de 'banco':** • Oración de prueba: *"El cliente fue al banco a depositar dinero e invertir en fondos de inversión."* • Sentidos en WordNet: - **Sentido 1 (Financiero):** Glosa = *"Entidad o institución financiera de crédito que recibe dinero de clientes para préstamos e inversión."* - **Sentido 2 (Mobiliario):** Glosa = *"Asiento de madera o piedra en el que pueden sentarse varias personas en una plaza o parque."* • Palabras de contexto (sin stop words): {cliente, depositar, dinero, invertir, fondos, inversión}. • Cálculo de intersección: - Intersección con Sentido 1: {dinero, cliente, inversión} $\to$ **Solapamiento = 3 palabras**. - Intersección con Sentido 2: $\emptyset$ $\to$ **Solapamiento = 0 palabras**. • **Asignación:** El algoritmo selecciona unívocamente el **Sentido 1 (Institución financiera)**.

📘 **FUNDAMENTACIÓN TEÓRICA Y LINGÜÍSTICA (UNIR)**

Constituye el algoritmo canónico basado en conocimiento para WSD en el temario oficial de PLN UNIR (Tema 5).

⚠️ **ERRORES TÍPICOS Y TRAMPAS DE EXAMEN**

No eliminar las stop words ('el', 'de', 'en', 'a') antes de calcular la intersección. Si no se eliminan, las glosas coincidirán artificialmente en palabras gramaticales vacías, arruinando la desambiguación.

PLN | Tema 5: Desambiguación Léxica Vectorial | Ejercicio Oficial de Examen | PLN-EJ-05

Enfoque Vectorial de Hinrich Schütze (Word Space Model)

Describa detalladamente el método no supervisado de discriminación del sentido de las palabras propuesto por **Hinrich Schütze (1998)** mediante clustering en espacios vectoriales (Word Space). Explique la construcción de vectores de contexto, reducción de dimensionalidad con SVD y asignación de nuevas instancias.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Fundamento del Enfoque de Schütze (1998): A diferencia de Lesk, Schütze propuso un enfoque estrictamente no supervisado y puramente cuantitativo que no depende de diccionarios preexistentes como WordNet. Su método no busca asignar una etiqueta predefinida a un sentido, sino *discriminar o agrupar* las ocurrencias de una palabra en clusters semánticos homogéneos basados en la distribución empírica de sus contextos. **2. Fases del Algoritmo de Schütze:** 1. **Construcción de la Matriz de Coocurrencia Palabra-Palabra:** Se seleccionan las M palabras de contenido más frecuentes del corpus. Se construye una matriz C de tamaño $M \times M$, donde cada celda C_{ij} registra la frecuencia con la que la palabra i coocurre con la palabra j dentro de una ventana de texto fija (p. ej., ± 5 palabras). 2. **Reducción de Dimensionalidad (Espacio Semántico Latente):** Se aplica **Descomposición en Valores Singulares (SVD)** sobre la matriz normalizada (mediante PPMI o TF-IDF): $$C \approx U \Sigma V^T$$ Se conservan los primeros k factores latentes (p. ej., $k = 100$), obteniendo para cada palabra de contexto un vector denso $\vec{v}_w \in \mathbb{R}^k$. 3. **Construcción de Vectores de Contexto:** Para cada instancia i de la palabra ambigua en un texto, se calcula su vector de contexto $\vec{c}_i$ como el **centroide o promedio normalizado** de los vectores densos de todas las palabras que la rodean: $$\vec{c}_i = \frac{1}{|Contexto|} \sum_{w \in Contexto} \vec{v}_w$$ 4. **Clustering No Supervisado de Sentidos:** Se aplican algoritmos de agrupamiento como **K-Means** o mezclas de gaussianas sobre el conjunto de todos los vectores de contexto $\{\vec{c}_1, \vec{c}_2, \dots, \vec{c}_N\}$. Si se fijan $K = 2$ clusters para la palabra 'banco', se obtendrán dos centroides $\vec{\mu}_1$ y $\vec{\mu}_2$. 5. **Desambiguación de Nuevas Instancias:** Para desambiguar una nueva aparición de la palabra, se calcula su vector de contexto y se asigna al cluster cuyo centroide presente la **mayor similitud coseno**: $$\hat{k} = \arg\max_{k} \frac{\vec{c}_{nuevo} \cdot \vec{\mu}_k}{\|\vec{c}_{nuevo}\| \|\vec{\mu}_k\|}$$

📘 FUNDAMENTACIÓN TEÓRICA Y LINGÜÍSTICA (UNIR)

Tema 5 PLN UNIR; Schütze (1998). Es el precursor conceptual directo de los modernos embeddings contextuales de transformers (BERT/RoBERTa).

⚠️ ERRORES TÍPICOS Y TRAMPAS DE EXAMEN

Confundir el vector de una palabra con el vector de un contexto. El vector de contexto es el promedio de los vectores de las palabras que rodean a la instancia ambigua.

PLN | Tema 5: Desambiguación Léxica Semisupervisada | Ejercicio Oficial de Examen | PLN-EJ-06

Algoritmo de Bootstrapping de David Yarowsky (1995)

Explique el **Algoritmo de Yarowsky (1995)** para la desambiguación léxica no supervisada/semisupervisada. Detalle los dos principios cognitivo-lingüísticos fundamentales en los que se sustenta, el proceso iterativo de bootstrapping y el criterio de parada.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Los Dos Principios Fundamentales de Yarowsky: El algoritmo de David Yarowsky se sustenta en dos hipótesis ecolingüísticas sumamente potentes: 1. **Un sentido por colocación (One sense per collocation):** Las palabras que aparecen inmediatamente adyacentes o en una relación sintáctica local fija con la palabra ambigua son predictores casi infalibles de su sentido. (P. ej., 'pesca de *banco*' $\to$ banco de peces; '*banco* central' $\to$ financiero). 2. **Un sentido por discurso (One sense per discourse):** La naturaleza o sentido de una palabra polisémica es monótona y consistente a lo largo de un mismo documento o discurso. Si un documento trata de finanzas, el 99.8% de las veces que aparezca 'banco' en ese mismo documento, se referirá al sentido financiero. **2. Proceso Iterativo de Bootstrapping:** 1. **Fase de Semillas (Seeds Initialization):** A partir de un corpus masivo sin anotar, el usuario define 1 o 2 colocaciones semilla triviales para cada sentido (p. ej., Semilla Sentido A: 'crédito'; Semilla Sentido B: 'pez'). 2. **Entrenamiento del Clasificador Inicial:** Se etiquetan automáticamente únicamente los ejemplos del corpus que contienen las palabras semilla. Con este conjunto inicial pequeño se entrena un clasificador basado en **listas de decisión** ponderadas por log-likelihood ratio: $$Score = \left| \log\left(\frac{P(\text{Sentido } A | \text{colocación})}{P(\text{Sentido } B | \text{colocación})}\right) \right|$$ 3. **Propagación y Reetiquetado Iterativo:** El clasificador evalúa el resto del corpus sin anotar. Los ejemplos clasificados con alta probabilidad se incorporan al conjunto de entrenamiento. 4. **Aplicación del principio 'Un sentido por discurso':** Si la mayoría de las ocurrencias de 'banco' en un documento fueron asignadas al Sentido A, se fuerza que todas las demás instancias dudosas de ese mismo documento se reclasifiquen como Sentido A. 5. **Convergencia / Criterio de Parada:** El proceso se repite iterativamente hasta que el conjunto de etiquetas asignadas a las colocaciones del corpus se estabiliza (convergencia estricta, no hay cambios en la lista de decisión).

📘 FUNDAMENTACIÓN TEÓRICA Y LINGÜÍSTICA (UNIR)

Tema 5 PLN UNIR; Yarowsky (1995). Alcanza precisiones superiores al 95% con mínima supervisión inicial humana.

⚠️ ERRORES TÍPICOS Y TRAMPAS DE EXAMEN

Olvidar que Yarowsky entrena una Lista de Decisión ordenada por fiabilidad probabilística decreciente, no un simple clasificador Naïve Bayes plano.

PLN | Tema 4: Análisis Sintáctico (Parsing) | Ejercicio Oficial de Examen | PLN-EJ-07

Algoritmo CKY (Cocke-Younger-Kasami) y Gramáticas en FNC

1. Defina formalmente los requisitos estructurales de una **Gramática Libre de Contexto en Forma Normal de Chomsky (FNC)** para su uso con el algoritmo CKY.
2. Explique la estructura de la tabla de programación dinámica triangular del algoritmo CKY y su complejidad temporal teórica.
3. ¿Cómo resuelve el algoritmo la ambigüedad sintáctica en oraciones con sintagmas preposicionales adjuntos (PP-attachment)?

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Forma Normal de Chomsky (FNC): Una Gramática Libre de Contexto $G = (V_N, V_T, P, S)$ está en Forma Normal de Chomsky si todas sus reglas de producción adoptan exclusivamente una de las dos formas siguientes: 1. $A \to B \; C$ (Un no-terminal produce exactamente dos no-terminales, donde $B, C \in V_N$). 2. $A \to a$ (Un no-terminal produce exactamente un símbolo terminal del léxico, donde $a \in V_T$). (Se permite $S \to \epsilon$ si la cadena vacía pertenece al lenguaje, en cuyo caso S no puede aparecer en el lado derecho de ninguna producción). Toda gramática libre de contexto puede transformarse a FNC mediante 4 pasos: eliminación de producciones ϵ, eliminación de reglas unitarias ($A \to B$), reemplazo de terminales aislados y factorización de reglas largas ($A \to B C D$). **2. Estructura de la Tabla CKY y Complejidad:** Para una oración de N palabras $w_1, w_2, \dots, w_N$, CKY construye una tabla triangular superior T de tamaño $(N+1) \times (N+1)$ indexada por posiciones de delimitación entre palabras $[i, j]$ (con $0 \le i < j \le N$): • **Inicialización (Longitud 1):** Las celdas de la diagonal principal $T[i-1, i]$ contienen todos los no-terminales A tales que existe una regla $A \to w_i$ en el léxico. • **Paso inductivo (Longitudes $l = 2, \dots, N$):** Para abarcar la subsecuencia de la palabra i a la j, se prueba todo punto de división intermedio k ($i < k < j$): $$T[i, j] = \{ A \mid A \to B \; C \in P, \; B \in T[i, k], \; C \in T[k, j] \}$$ • **Complejidad algorítmica:** Existen 3 bucles anidados: longitud de la subsecuencia ($O(N)$), posición inicial ($O(N)$) y punto de división intermedio ($O(N)$), multiplicado por el número de producciones de la gramática $|P|$. Por ende, la complejidad temporal es exactamente **$O(N^3 \cdot |P|)$**, infinitamente más eficiente que el parsing ingenuo exponencial $O(|P|^N)$. **3. Resolución de la Ambigüedad Sintáctica (PP-Attachment):** En oraciones ambiguas como *"Vi al hombre con el telescopio"*, la celda superior $T[0, N]$ contendrá múltiples árboles de derivación válidos (el sintagma preposicional 'con el telescopio' puede modificar al verbo 'Vi' o al sintagma nominal 'el hombre'). El algoritmo CKY estándar almacena punteros a ambas derivaciones; si se utiliza **CKY Probabilístico (PCFG)**, cada celda almacena la probabilidad máxima $P(A \to B C) \cdot P(B) \cdot P(C)$, seleccionando deterministamente el árbol con mayor probabilidad conjunta.

📘 FUNDAMENTACIÓN TEÓRICA Y LINGÜÍSTICA (UNIR)

Tema 4 PLN UNIR; Younger (1967). Algoritmo fundacional de análisis sintáctico formal.

⚠️ ERRORES TÍPICOS Y TRAMPAS DE EXAMEN

Olvidar que CKY exige OBLIGATORIAMENTE que la gramática esté en FNC. Si se introduce una gramática con reglas de 3 o más símbolos a la derecha ($S \to NP \; VP \; PP$), el algoritmo CKY es inaplicable sin binarización previa.

PLN | Tema 6: Redes Neuronales y Transformers | Ejercicio Oficial de Examen | PLN-EJ-08

Arquitectura Transformer y Mecanismo de Autoatención Escalada

1. Desarrolle la formulación matemática de la **Autoatención por Producto Escalar Escalado (Scaled Dot-Product Attention)** introducida en 'Attention is All You Need' (Vaswani et al., 2017).
2. Justifique analíticamente la inclusión del factor de escala $\frac{1}{\sqrt{d_k}}$ en el denominador de la función softmax.
3. Explique la arquitectura de la **Atención Multicabeza (Multi-Head Attention)** y por qué es necesaria la codificación posicional (Positional Encoding).

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Formulación de la Autoatención por Producto Escalar Escalado: Dado un conjunto de vectores de entrada proyectados linealmente mediante matrices de pesos entrenables $W_Q, W_K, W_V \in \mathbb{R}^{d_{model} \times d_k}$ para generar las matrices de Consultas (Q), Claves (K) y Valores (V): $$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{Q \cdot K^T}{\sqrt{d_k}} \right) \cdot V$$ donde: • $Q \cdot K^T$ calcula la similitud por producto escalar entre cada consulta y todas las claves. • La función softmax normaliza las puntuaciones por fila, generando una distribución de pesos de atención que suman 1. • La multiplicación final por V produce una suma ponderada de los vectores de valores según su relevancia contextual. **2. Justificación matemática del factor de escala $\frac{1}{\sqrt{d_k}}$:** Asumamos que las componentes de los vectores q y k son variables aleatorias independientes e idénticamente distribuidas con media 0 y varianza 1: $$\mathbb{E}[q_i] = 0, \quad \text{Var}(q_i) = 1, \quad \mathbb{E}[k_i] = 0, \quad \text{Var}(k_i) = 1$$ El producto escalar es la suma de d_k términos: $q \cdot k = \sum_{i=1}^{d_k} q_i k_i$. La esperanza del producto escalar es 0, pero su varianza es la suma de varianzas: $$\text{Var}(q \cdot k) = \sum_{i=1}^{d_k} \text{Var}(q_i k_i) = \sum_{i=1}^{d_k} \text{Var}(q_i) \cdot \text{Var}(k_i) = d_k$$ Por consiguiente, la desviación típica del producto escalar crece como $\sqrt{d_k}$. Para dimensiones grandes (p. ej., $d_k = 64$ o $d_k = 128$), la magnitud de $Q K^T$ alcanza valores extremadamente grandes. Al aplicar la función softmax, los valores muy altos empujan a la función exponencial hacia regiones con **gradientes extremadamente pequeños y cercanos a cero (saturación de softmax)**, provocando el colapso del aprendizaje por desvanecimiento del gradiente (vanishing gradient). Al dividir por $\sqrt{d_k}$, la varianza se reescala exactamente a 1, preservando gradientes saludables durante el backpropagation. **3. Atención Multicabeza y Codificación Posicional: • Multi-Head Attention:** En lugar de calcular una sola atención sobre d_{model}, se proyectan Q, K, V en h subespacios independientes de menor dimensión ($d_k = d_{model}/h$). Esto permite al modelo **atender simultáneamente a diferentes aspectos sintácticos y semánticos** en distintas posiciones (p. ej., una cabeza atiende a relaciones sujeto-verbo, otra a correferencias y otra a dependencias preposicionales): $$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \cdot W^O$$ • **Necesidad de la Codificación Posicional (Positional Encoding):** Dado que la operación de atención es completamente **invariante ante permutaciones** (es un conjunto de operaciones matriciales sin noción inherente del orden temporal o secuencial de las palabras), es imprescindible inyectar explícitamente información de posición sumando vectores sinusoidales a las representaciones iniciales de las palabras: $$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}} \right), \quad PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{\frac{2i}{d_{model}}}} \right)$$

📘 FUNDAMENTACIÓN TEÓRICA Y LINGÜÍSTICA (UNIR)

Tema 6 PLN UNIR; Vaswani et al. (2017). Es la arquitectura nuclear de los Large Language Models modernos (GPT-4, Claude, Gemini, LLaMA).

⚠️ ERRORES TÍPICOS Y TRAMPAS DE EXAMEN

> Afirmar que el factor de escala es $\frac{1}{d_k}$ en vez de $\frac{1}{\sqrt{d_k}}$, o asumir que la autoatención es recursiva como una RNN (en un Transformer todos los tokens atienden a todos los demás en paralelo $O(1)$ en pasos de tiempo).

3. Razonamiento y Planificación Automática (RPA)

Contenidos evaluados: Lógica Proposicional, Planificación de Orden Parcial (POP), Búsqueda Heurística A*, Minimax y Poda Alfa-Beta, Planificación PDDL 1.2.

Tabla de Verdad y Clasificación Semántica (Contingencia)

Enunciado oficial de examen:
Genere la tabla de verdad exhaustiva de la siguiente fórmula lógica proposicional e indique de manera razonada y justificada si se trata de una **tautología**, una **contingencia** o una **contradicción**:

$$(p \to \neg q) \to (\neg q \to p)$$

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Determinación de dimensiones y variables atómicas: La fórmula involucra 2 variables proposicionales atómicas (p y q). Por lo tanto, el número total de interpretaciones posibles en el espacio de verdad es: $$2^N = 2^2 = 4 \text{ interpretaciones}$$ **2. Construcción paso a paso de la Tabla de Verdad:** Evaluamos secuencialmente los operadores de menor a mayor jerarquía sintáctica: 1. Negación: $\neg q$. 2. Antecedente global: $\alpha = (p \to \neg q)$ (falsa únicamente si $p = V$ y $\neg q = F$). 3. Consecuente global: $\beta = (\neg q \to p)$ (falsa únicamente si $\neg q = V$ y $p = F$). 4. Implicación principal: $\alpha \to \beta$ (falsa únicamente si $\alpha = V$ y $\beta = F$).

Interpretación	p	q	¬q	Antecedente: (p → ¬q)	Consecuente: (¬q → p)	Fórmula Completa: (p → ¬q) → (¬q → p)
I_1	V	V	F	F *(V → F es F)*	V *(F → V es V)*	**V (F → V es V)**
I_2	V	F	V	V *(V → V es V)*	V *(V → V es V)*	**V (V → V es V)**
I_3	F	V	F	V *(F → F es V)*	V *(F → F es V)*	**V (V → V es V)**
I_4	F	F	V	V *(F → V es V)*	F *(V → F es F)*	**F (V → F es F)**

3. Diagnóstico Semántico Oficial y Justificación: • **Resultado de las interpretaciones:** La fórmula resulta Verdadera (V) en 3 interpretaciones (I_1, I_2, I_3) y resulta Falsa (F) en 1 interpretación (I_4, cuando $p = \text{Falso}$ y $q = \text{Falso}$). • **Clasificación formal:** Es una **CONTINGENCIA** (fórmula sintáctica satisfacible pero no válida / no tautológica). • **Contraste teórico exigido por UNIR:** - No es una *Tautología* porque no es verdadera en todos los modelos posibles (falla en I_4). - No es una *Contradicción* porque no es falsa en todos los modelos (es satisfacible en I_1, I_2, I_3).

📘 FUNDAMENTACIÓN LÓGICA Y ALGORÍTMICA (UNIR)

Tema 2 RPA UNIR (Lógica Proposicional); Russell & Norvig (2020). En la lógica clásica bivalente, el condicional material $A \to B$ es verdadero por vaciedad siempre que el antecedente A sea falso.

⚠️ TRAMPA FRECUENTE Y ADVERTENCIA DEL CLAUSTRO DOCENTE

El error más habitual de los alumnos en examen radica en la fila 4 ($p=F, q=F$): evaluar mentalmente la implicación como una equivalencia o creer erróneamente que $F \to V$ es falso. Recordar: $F \to V$ siempre es VERDADERO.

Enlaces Causales, Amenazas y Operadores de Resolución en POP

Enunciado oficial de examen:
En la planificación de orden parcial (POP / POCL) se definen dos tipos de arcos que relacionan las acciones de un plan:
1. Explique qué significa un **enlace causal (Causal Link)** entre dos acciones A_1 y A_2 en cuanto a los fluents que aparecen en los antecedentes (precondiciones) y consecuentes (efectos) de dichas acciones.
2. Defina formalmente la **condición de amenaza (Threat / Causal Clobbering)** provocada por una tercera acción A_k.
3. Indique y justifique los dos métodos formales que utiliza el planificador POP para resolver dicha amenaza. Ilustre con un ejemplo práctico.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Definición y Significado de los Enlaces Causales: En Planificación de Orden Parcial (POP), un **enlace causal** se denota formalmente como: $$A_1 \xrightarrow{\;p\;} A_2$$ e indica que: • La acción productora A_1 incluye el literal o fluent positivo p dentro de sus efectos o consecuentes ($p \in \text{Efectos}^+(A_1)$). • La acción consumidora A_2 exige dicho fluent p como precondición obligatoria para su ejecución ($p \in \text{Precondiciones}(A_2)$). • El arco impone una restricción de orden temporal $A_1 \prec A_2$ y establece un *compromiso de protección*: el estado de verdad del fluent p debe mantenerse inmutable entre la ejecución de A_1 y A_2. **2. Condición de Amenaza (Threat / Clobbering):** Existe una amenaza sobre el enlace causal $A_1 \xrightarrow{p} A_2$ si existe en el plan una acción A_k (distinta de A_1 y A_2) tal que: 1. A_k tiene como efecto negar el fluent protegido: $\neg p \in \text{Efectos}^-(A_k)$. 2. El ordenamiento actual del plan no impide que A_k se ejecute entre A_1 y A_2 (es decir, el orden $(A_1 \prec A_k \prec A_2)$ es temporalmente admisible y compatible con las restricciones del plan). **3. Métodos Formales de Resolución de la Amenaza:** El planificador POP restaura la consistencia del plan aplicando una de dos restricciones temporales estrictas: • **Promoción (Promotion):** Se fuerza que la acción destructora A_k se ejecute ANTES de la acción productora A_1: $$\text{Se añade la restricción: } A_k \prec A_1$$ De este modo, cuando A_1 se ejecute, volverá a establecer p, quedando protegido para A_2. • **Democión (Demotion):** Se fuerza que la acción destructora A_k se ejecute DESPUÉS de la acción consumidora A_2: $$\text{Se añade la restricción: } A_2 \prec A_k$$ Así, cuando A_k destruya el recurso, A_2 ya habrá consumido p con éxito. **Ejemplo práctico ilustrativo:** • A_1: `ComprarPintura(bote1)` $\implies$ Efecto: `TienePintura(bote1)`. • A_2: `PintarPared(pared1, bote1)` $\implies$ Precondición: `TienePintura(bote1)`. • Enlace causal: $A_1 \xrightarrow{\text{TienePintura(bote1)}} A_2$. • Acción amenazante A_k: `VenderPintura(bote1)` $\implies$ Efecto: $\neg\text{TienePintura(bote1)}$. • **Resolución:** - Promoción ($A_k \prec A_1$): Vender la pintura antes de comprarla (posiblemente inviable si vender exige tenerla). - Democión ($A_2 \prec A_k$): Pintar la pared primero y vender el sobrante después. La democión resuelve el conflicto elegantemente.

📘 FUNDAMENTACIÓN LÓGICA Y ALGORÍTMICA (UNIR)

Tema 6 RPA UNIR; Weld (1994), Russell & Norvig (2020). POP sigue el principio de 'compromiso mínimo' (least commitment), no ordenando pasos hasta que sea estrictamente indispensable.

⚠️ TRAMPA FRECUENTE Y ADVERTENCIA DEL CLAUSTRO DOCENTE

Confundir un enlace causal ($A_1 \xrightarrow{p} A_2$) con un simple enlace de orden temporal ($A_1 \prec A_2$). Un enlace de orden solo dice 'haz esto antes'; un enlace causal explica *por qué* se hace antes y qué recurso biyectivo se protege.

Búsqueda Heurística A*: Admisibilidad, Consistencia y Expansión

1. Defina analíticamente la función de evaluación $f(n) = g(n) + h(n)$ del algoritmo A^*.
2. Defina con rigor formal las propiedades de **Admisibilidad** y **Consistencia (o Monotonía)** de una función heurística $h(n)$ y explique qué garantías teóricas aporta cada una en la búsqueda en árboles y en grafos.
3. Demuestre matemáticamente que toda heurística consistente es necesariamente admisible.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Función de evaluación de A*: Para cualquier nodo n en el espacio de estados: $$f(n) = g(n) + h(n)$$ donde: • $g(n)$ es el coste real exacto acumulado del camino desde el estado inicial hasta el nodo n. • $h(n)$ es la estimación heurística del coste mínimo para alcanzar un estado objetivo desde n. • $f(n)$ estima el coste total del camino óptimo más económico que pasa por el nodo n. **2. Admisibilidad vs. Consistencia:** • **Heurística Admisible:** Una heurística $h(n)$ es admisible si **nunca sobreestima** el coste real óptimo $h^*(n)$ para alcanzar la meta más cercana desde el nodo n: $$\forall n, \quad 0 \le h(n) \le h^*(n) \quad (\text{con } h(\text{meta}) = 0)$$ *Garantía teórica:* Garantiza que la búsqueda en **árboles** encuentra siempre la solución óptima (de coste mínimo). • **Heurística Consistente (o Monótona):** Una heurística $h(n)$ es consistente si satisface la desigualdad triangular para cada nodo n y cada sucesor n' generado mediante una acción de coste $c(n, a, n')$: $$h(n) \le c(n, a, n') + h(n')$$ *Garantía teórica:* Garantiza que la búsqueda en **grafos** (con lista de cerrados) es óptima **sin necesidad de reabrir nodos ya expandidos**. Cuando A^* expande un nodo n, el coste $g(n)$ es ya demostradamente óptimo. **3. Demostración analítica: Consistencia $\implies$ Admisibilidad:** Sea $n = n_0, n_1, n_2, \dots, n_k = \text{meta}$ la secuencia óptima de nodos desde n hasta el objetivo. Por la propiedad de consistencia aplicada sucesivamente en cada arista del camino: $$h(n_0) \le c(n_0, a_0, n_1) + h(n_1)$$ $$h(n_1) \le c(n_1, a_1, n_2) + h(n_2)$$ $$\vdots$$ $$h(n_{k-1}) \le c(n_{k-1}, a_{k-1}, n_k) + h(n_k)$$ Sumando telescópicamente todas las desigualdades: $$h(n_0) + \sum_{i=1}^{k-1} h(n_i) \le \sum_{i=0}^{k-1} c(n_i, a_i, n_{i+1}) + \sum_{i=1}^k h(n_i)$$ Cancelando los términos idénticos en ambos miembros y sabiendo que $h(n_k) = h(\text{meta}) = 0$: $$h(n_0) \le \sum_{i=0}^{k-1} c(n_i, a_i, n_{i+1}) = h^*(n_0)$$ $$\therefore h(n) \le h^*(n) \quad \blacksquare$$ Por tanto, toda heurística consistente es formalmente admisible.

📘 FUNDAMENTACIÓN LÓGICA Y ALGORÍTMICA (UNIR)

Tema 3 RPA UNIR; Pearl (1984), Russell & Norvig (2020). Teorema fundamental de la búsqueda heurística.

⚠️ TRAMPA FRECUENTE Y ADVERTENCIA DEL CLAUSTRO DOCENTE

Creer que la implicación es bidireccional. FALSO: No toda heurística admisible es consistente (pueden construirse heurísticas admisibles pero no monótonas en grafos dirigidos).

RPA | Tema 4: Teoría de Juegos y Búsqueda Adversaria | Ejercicio Oficial de Examen | RPA-EJ-04

Algoritmo Minimax y Poda Alfa-Beta en Árboles de Juego

Explique el funcionamiento del algoritmo **Minimax** para juegos bi-personales de suma cero con información perfecta. Desarrolle el mecanismo de **Poda Alfa-Beta**, definiendo el significado de los parámetros α y β, la condición matemática de poda y su impacto en el factor de ramificación efectivo.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Fundamento del Algoritmo Minimax: En un juego secuencial bi-personal de información perfecta (como ajedrez o damas) intervienen dos agentes racionales con objetivos diametralmente opuestos: • **MAX:** Pretende maximizar la función de utilidad terminal del juego ($V(n) = \max_{s \in Suc(n)} V(s)$). • **MIN:** Pretende minimizar la utilidad obtenida por MAX ($V(n) = \min_{s \in Suc(n)} V(s)$). El algoritmo expande recursivamente el árbol de juego hasta una profundidad límite y propaga los valores de abajo hacia arriba (backtracking). **2. Mecanismo de Poda Alfa-Beta (Alpha-Beta Pruning):** La poda alfa-beta devuelve exactamente el mismo valor de decisión que Minimax completo, pero podando sistemáticamente ramas del árbol que se demuestre matemáticamente que no pueden influir en la decisión final. Mantiene dos límites dinámicos durante la búsqueda en profundidad: • α (Alfa): La **mejor opción (valor más alto) encontrada hasta el momento para el jugador MAX** a lo largo de cualquier camino de la raíz al nodo actual. Inicialmente $\alpha = -\infty$. • β (Beta): La **mejor opción (valor más bajo) encontrada hasta el momento para el jugador MIN** a lo largo de cualquier camino de la raíz al nodo actual. Inicialmente $\beta = +\infty$. **3. Condición matemática de poda:** En cualquier nodo, si se cumple la condición: $$\alpha \ge \beta$$ **Se detiene de inmediato la evaluación de los sucesores restantes de ese nodo (corte o poda)**. • *Poda Alfa (en nodo MIN):* MIN ha encontrado una alternativa cuyo valor es $\le \alpha$. Como MAX ya tiene garantizado obtener al menos α en un nivel superior, jamás permitirá llegar a este nodo. • *Poda Beta (en nodo MAX):* MAX ha encontrado un valor $\ge \beta$. Como MIN ya tiene garantizado limitar a MAX a un valor $\le \beta$ en un nivel superior, MIN jamás elegirá la rama que conduce a este estado. **4. Eficiencia computacional:** En un árbol estándar con factor de ramificación b y profundidad d, Minimax evalúa $O(b^d)$ hojas. Con poda Alfa-Beta y ordenación óptima de movimientos (los mejores primero), la complejidad temporal se desploma a: $$O(b^{d/2})$$ Esto equivale a duplicar la profundidad alcanzable con el mismo tiempo computacional (factor de ramificación efectivo reducido de b a $\sqrt{b}$).

📘 FUNDAMENTACIÓN LÓGICA Y ALGORÍTMICA (UNIR)

Tema 4 RPA UNIR; Knuth & Moore (1975). Técnica reina en teoría de juegos computacional.

⚠️ TRAMPA FRECUENTE Y ADVERTENCIA DEL CLAUSTRO DOCENTE

En examen: olvidar que α solo lo actualiza el nodo MAX y β solo lo actualiza el nodo MIN. Los valores se heredan hacia los hijos y la poda se activa cuando se cruzan $\alpha \ge \beta$.

Dominio y Problema PDDL: Restaurante y Satisfacibilidad

Analice el siguiente extracto oficial de un dominio PDDL 1.2 de reparto de comida en un restaurante infantil:

```lisp
(:action servir_comida
:parameters (?nc - noceliaco ?p - persona ?t - bandeja ?l - lugar ?nr - receta)
:precondition (and (esperando ?p ?l ?nr) (pedido ?nc ?nr)
(en-bandeja ?nc ?t) (en ?t ?l))
:effect (and (not (en-bandeja ?nc ?t)) (servido ?p))
)
```

En el estado inicial `:init` se dispone de:
• `(esperando persona2 mesa2 receta1)`
• `(pedido piz2 receta1)`
• `(en-bandeja piz2 bandeja2)`
• `(en bandeja2 cocina)` (la bandeja está en la cocina, NO en mesa2).

Demuestre formalmente por qué la acción `(servir_comida piz2 persona2 bandeja2 mesa2 receta1)` **NO es ejecutable** en el estado inicial y deduzca qué secuencia de acciones previas debe ejecutar el planificador para alcanzar la meta `(servido persona2)`.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Evaluación formal de precondiciones en el estado inicial: Para que la acción instanciada `servir_comida(piz2, persona2, bandeja2, mesa2, receta1)` pueda dispararse, deben cumplirse simultáneamente las 4 proposiciones de su precondición: 1. `(esperando persona2 mesa2 receta1)` $\implies$ **CUMPLE** (figura explícitamente en `:init`). 2. `(pedido piz2 receta1)` $\implies$ **CUMPLE** (figura explícitamente en `:init`). 3. `(en-bandeja piz2 bandeja2)` $\implies$ **CUMPLE** (figura explícitamente en `:init`). 4. `(en bandeja2 mesa2)` $\implies$ **NO CUMPLE**: En el estado inicial figura unívocamente `(en bandeja2 cocina)`. Bajo el supuesto de mundo cerrado (Closed World Assumption - CWA), como el predicado `(en bandeja2 mesa2)` no pertenece al estado actual, se evalúa formalmente como FALSO. Por consiguiente, **la precondición general es FALSA y la acción es inejecutable**. **2. Secuencia deductiva del plan resolutor:** Para habilitar la precondición fallida `(en bandeja2 mesa2)`, el planificador debe localizar un operador que contenga dicho literal en su lista de efectos positivos: • Operador identificado: `mover_bandeja(?t - bandeja, ?desde - lugar, ?hacia - lugar)`. - Parámetros: `?t = bandeja2, ?desde = cocina, ?hacia = mesa2`. - Precondiciones de mover: `(en bandeja2 cocina)` $\to$ **CUMPLE en :init**. - Efectos de mover: `(and (en bandeja2 mesa2) (not (en bandeja2 cocina)))`. **3. Plan lineal ordenado completo:** 1. `Paso 1: (mover_bandeja bandeja2 cocina mesa2)` $\implies$ Hace verdadero `(en bandeja2 mesa2)`. 2. `Paso 2: (servir_comida piz2 persona2 bandeja2 mesa2 receta1)` $\implies$ Ahora todas sus precondiciones son válidas; produce `(servido persona2)`, alcanzando con éxito el estado objetivo `:goal`.

📘 FUNDAMENTACIÓN LÓGICA Y ALGORÍTMICA (UNIR)

Tema 7 RPA UNIR; Ghallab, Nau & Traverso (2004). Semántica formal de PDDL basada en la lógica de estados de STRIPS.

⚠️ TRAMPA FRECUENTE Y ADVERTENCIA DEL CLAUSTRO DOCENTE

> En examen: olvidar la hipótesis de mundo cerrado (CWA) o asumir erróneamente que las precondiciones pueden satisfacerse mágicamente sin una acción previa de desplazamiento de la bandeja.

4. Visión Artificial (VA)

Contenidos evaluados: Convolución y Correlación 2D, Filtros de Gradiente y Bordes (Sobel), Morfología Matemática Binaria (Apertura y Cierre), Puntos de Interés (Harris y SIFT).

VA | Tema 2: Filtrado Espacial y Detección de Bordes | Ejercicio Oficial de Examen | VA-EJ-01

Convolución 2D vs. Correlación Cruzada y Simetría de Kernels

1. Escriba la formulación matemática discreta 2D de la **Correlación Cruzada** y de la **Convolución** entre una imagen $I(x, y)$ y una máscara o kernel K de tamaño $(2k+1) \times (2k+1)$.
2. Explique qué diferencia geométrica existe entre ambas operaciones y en qué condiciones analíticas ambas conducen a resultados numéricamente idénticos.
3. Justifique por qué la convolución es matemáticamente asociativa y conmutativa mientras que la correlación cruzada no lo es.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Formulación matemática discreta 2D: • **Correlación Cruzada Discreta ($I \otimes K$):** $$(I \otimes K)(x, y) = \sum_{m=-k}^k \sum_{n=-k}^k I(x + m, y + n) \cdot K(m, n)$$ • **Convolución Discreta ($I * K$):** $$(I * K)(x, y) = \sum_{m=-k}^k \sum_{n=-k}^k I(x - m, y - n) \cdot K(m, n) = \sum_{m=-k}^k \sum_{n=-k}^k I(x + m, y + n) \cdot K(-m, -n)$$ **2. Diferencia geométrica y condición de coincidencia:** • **Diferencia geométrica:** La convolución equivale a rotar espacialmente el kernel **180 grados (volteo horizontal y volteo vertical)** antes de calcular la suma de productos con el vecindario de la imagen. La correlación, en cambio, desliza el filtro de manera directa sin ninguna rotación previa. • **Condición de equivalencia:** Ambas operaciones producen exactamente el mismo resultado numérico si y solo si el kernel K es **centro-simétrico (simétrico respecto a su origen)**, esto es, $K(m, n) = K(-m, -n)$ (como ocurre con el filtro de la media o el filtro gaussiano). **3. Justificación de las propiedades algebraicas:** • La convolución es un operador lineal algebraicamente bien definido que cumple: - **Conmutatividad:** $I * K = K * I$. - **Asociatividad:** $(I * K_1) * K_2 = I * (K_1 * K_2)$. Esta propiedad asociativa es crucial en Visión Artificial porque permite pre-combinar dos filtros sucesivos (p. ej. precomputar un filtro Gaussiano y un Laplaciano como un solo filtro LoG - Laplaciano del Gaussiano) antes de procesar las imágenes, reduciendo el coste computacional a la mitad. • La correlación cruzada **carece de conmutatividad y asociatividad** debido al signo positivo en los índices de desplazamiento temporal/espacial.

📘 FUNDAMENTACIÓN GEOMÉTRICA Y ESPACIAL (UNIR)

Tema 2 VA UNIR; Gonzalez & Woods (2018), Szeliski (2022). Fundamento matemático esencial de las redes convolucionales (CNN).

⚠️ TRAMPAS CLÁSICAS DE EXAMEN EN VISIÓN ARTIFICIAL

En deep learning (TensorFlow / PyTorch), la capa llamada 'Conv2D' en realidad implementa correlación cruzada por razones de optimización interna, pero aprende los kernels volteados de forma equivalente. En un examen de visión clásica UNIR, confundir los signos $(-m, -n)$ con $(+m, +n)$ invalida la respuesta.

Máscaras de Sobel Horizontal y Vertical: Magnitud y Orientación

Dadas las máscaras de gradiente clásicas de Sobel 3×3:
$$h_1 = \begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix}, \quad h_2 = \begin{pmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{pmatrix}$$

1. ¿Qué derivada aproximan cada una de ellas y qué tipo de bordes detectan espacialmente?
2. Indique cómo se combinan sus salidas para calcular la **magnitud del gradiente** y la **orientación angular del borde** en cada píxel.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Derivada aproximada y orientación de bordes: • **Máscara h_1 (Derivada parcial en X, $G_x = \frac{\partial I}{\partial x}$):** - Aproxima la derivada horizontal mediante diferencias finitas centrales ponderadas. - Al restar la columna izquierda de la columna derecha, produce valores máximos donde hay una rápida transición de intensidad a lo largo del eje X. - **Tipo de borde detectado:** Detecta **BORDES VERTICALES** (líneas verticales que separan regiones claras y oscuras horizontales). • **Máscara h_2 (Derivada parcial en Y, $G_y = \frac{\partial I}{\partial y}$):** - Aproxima la derivada vertical restando la fila superior de la fila inferior. - Produce valores máximos ante cambios bruscos de intensidad a lo largo del eje Y. - **Tipo de borde detectado:** Detecta **BORDES HORIZONTALES** (líneas horizontales que separan regiones claras y oscuras verticales). **2. Combinación analítica: Magnitud y Orientación del Gradiente:** Para cada píxel (x, y), se define el vector gradiente espacial: $$\nabla I = \begin{pmatrix} G_x \\ G_y \end{pmatrix} = \begin{pmatrix} (I * h_1)(x, y) \\ (I * h_2)(x, y) \end{pmatrix}$$ • **Magnitud del Gradiente (Fuerza del borde):** Cuantifica la tasa máxima de cambio de intensidad local: $$M(x, y) = \|\nabla I\| = \sqrt{G_x^2 + G_y^2} \approx |G_x| + |G_y| \quad (\text{aproximación rápida L1})$$ • **Orientación o Dirección del Gradiente:** Ángulo perpendicular a la tangente del borde (apunta hacia la dirección de máximo crecimiento de brillo): $$\theta(x, y) = \arctan2(G_y, G_x)$$ La orientación geométrica de la línea del borde físico es ortogonal al vector gradiente: $\theta_{borde} = \theta \pm 90^\circ$.

📘 FUNDAMENTACIÓN GEOMÉTRICA Y ESPACIAL (UNIR)

Tema 2 VA UNIR; Sobel & Feldman (1968). Es el bloque constitutivo del detector de bordes de Canny (1986).

⚠️ TRAMPAS CLÁSICAS DE EXAMEN EN VISIÓN ARTIFICIAL

Trampa clásica de examen: Asumir que la máscara h_1 (que diferencia en horizontal X) detecta bordes horizontales. ¡ES AL REVÉS! Un cambio horizontal en X es producido por una frontera vertical. h_1 detecta bordes VERTICALES y h_2 detecta bordes HORIZONTALES.

VA | Tema 3: Morfología Matemática | Ejercicio Oficial de Examen | VA-EJ-03

Morfología Matemática Binaria: Discriminación de Objetos por Tamaño

Enunciado oficial de examen:
Se dispone de una imagen binaria que contiene monedas circulares de dos tamaños claramente diferenciados:
• Monedas pequeñas: radio $r_1 = 10\text{ píxeles}$.
• Monedas grandes: radio $r_2 = 50\text{ píxeles}$.
Se desea diseñar un procedimiento de **morfología matemática** para eliminar completamente todas las monedas pequeñas conservando las monedas grandes exactamente con su radio original (50 px) sin distorsionar su forma circular.
Indique detalladamente qué operación morfológica debe emplearse, la forma y dimensiones exactas del elemento estructurante, y justifique geométricamente cada paso.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Operación morfológica requerida: La operación adecuada es la **APERTURA MORFOLÓGICA (Opening)**, denotada formalmente como: $$A \circ B = (A \ominus B) \oplus B$$ consistente en una **Erosión** seguida inmediatamente de una **Dilatación** utilizando el mismo elemento estructurante B. **2. Diseño del Elemento Estructurante B:** • **Forma geométrica:** Disco euclídeo circular (para no alterar la curvatura ni introducir vértices artificiales en las monedas circulares). • **Radio del elemento estructurante (R_B):** Debe elegirse un radio estrictamente mayor que el de las monedas pequeñas y estrictamente menor que el de las grandes: $$r_1 < R_B < r_2 \implies 10\text{ px} < R_B < 50\text{ px}$$ **Valor óptimo de diseño:** Un disco circular de **radio $R_B = 15\text{ píxeles}$** (o cualquier valor entre 12 y 25 px). **3. Justificación geométrica paso a paso:** 1. **Fase 1: Erosión ($A \ominus B$):** La erosión encoge los límites de todos los objetos en una distancia igual a $R_B = 15\text{ px}$: - Para las monedas pequeñas ($r_1 = 10\text{ px}$): Como su radio es estrictamente menor que el radio de erosión ($10 < 15$), el elemento estructurante no cabe en ningún punto interior del objeto. **Las monedas pequeñas desaparecen por completo de la imagen (quedan erradicadas con valor 0)**. - Para las monedas grandes ($r_2 = 50\text{ px}$): Como su radio es mayor, sobreviven como núcleos circulares de radio reducido: $$r_{intermedio} = 50 - 15 = 35\text{ píxeles}$$ 2. **Fase 2: Dilatación reconstructiva ($(A \ominus B) \oplus B$):** Se dilata el resultado anterior con el mismo disco de radio $R_B = 15\text{ px}$: - Como las monedas pequeñas ya no existen, no se regeneran en absoluto. - Para los núcleos de las monedas grandes, la dilatación expande sus fronteras en 15 px, recuperando exactamente su dimensión geométrica original: $$r_{final} = 35 + 15 = \mathbf{50\text{ píxeles}}$$ **Resultado final:** Eliminación absoluta y limpia de las monedas pequeñas, conservando el área, perímetro y circularidad original de las monedas grandes.

📘 FUNDAMENTACIÓN GEOMÉTRICA Y ESPACIAL (UNIR)

Tema 3 VA UNIR; Serra (1982), Haralick et al. (1987). La apertura es una transformación morfológica antiextensiva e idempotente.

⚠️ TRAMPAS CLÁSICAS DE EXAMEN EN VISIÓN ARTIFICIAL

Proponer solo 'Erosión': si solo se erosiona, se eliminan las pequeñas pero las grandes quedan enanas (radio 35 en vez de 50). Otra trampa es proponer 'Cierre' ($A \bullet B$): el cierre rellena huecos y agrandaría las monedas pequeñas en vez de eliminarlas.

VA | Tema 4: Extracción de Características y Puntos de Interés | Ejercicio Oficial de Examen | VA-EJ-04

Detector de Esquinas de Harris: Matriz de Estructura e Invariancias

1. Formule la matriz de estructura o autocorrelación M en el **Detector de Esquinas de Harris (Harris & Stephens, 1988)**.
2. Explique cómo se calcula la función de respuesta R y qué criterio analítico distingue entre una esquina, un borde plano y una región homogénea según los autovalores λ_1 y λ_2 de M.
3. Indique qué invariancias (rotación, traslación, escala, iluminación) posee el detector de Harris y justifique por qué SIFT supera sus limitaciones ante cambios de escala.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Matriz de Autocorrelación de Harris (M): Se calcula a partir de los gradientes espaciales de la imagen suavizados por una ventana gaussiana $w(x, y)$: $$M = \sum_{(x, y) \in W} w(x, y) \begin{pmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{pmatrix} = \begin{pmatrix} \langle I_x^2 \rangle & \langle I_x I_y \rangle \\ \langle I_x I_y \rangle & \langle I_y^2 \rangle \end{pmatrix}$$ **2. Función de respuesta R y autovalores λ_1, λ_2:** Para evitar el costoso cálculo explícito de la descomposición espectral (autovalores), Harris propuso la función de respuesta: $$R = \det(M) - k \cdot (\text{traza}(M))^2$$ donde $\det(M) = \lambda_1 \lambda_2$, $\text{traza}(M) = \lambda_1 + \lambda_2$, y $k \in [0.04, 0.06]$ es una constante empírica. • **Región Homogénea (Plana):** $\lambda_1 \approx 0$ y $\lambda_2 \approx 0 \implies R \approx 0$. No hay cambio de intensidad en ninguna dirección. • **Borde (Edge):** Un autovalor es grande y el otro es casi nulo (p. ej., $\lambda_1 \gg \lambda_2 \approx 0$) $\implies \det(M) \approx 0$ pero $(\text{traza})^2$ es grande $\implies R < 0$ (fuertemente negativo). • **Esquina (Corner):** Ambos autovalores son simultáneamente grandes ($\lambda_1, \lambda_2 \gg 0$) $\implies \det(M)$ domina ampliamente sobre $k(\text{traza})^2 \implies \mathbf{R > 0}$ (fuertemente positivo, por encima de un umbral). **3. Análisis de Invariancias:** • **Invariante ante rotación:** La matriz M es simétrica y sus autovalores λ_1, λ_2 son escalares invariantes ante rotaciones del sistema de coordenadas. • **Invariante ante traslación:** El cálculo de derivadas locales y ventanas se desplaza de forma isomórfica. • **Parcialmente invariante ante cambios afines de intensidad:** $I \to a I + b$ altera la magnitud pero se compensa mediante el umbralizado adaptativo. • **NO es invariante ante cambios de escala:** Un punto clasificado como esquina a escala fina puede transformarse en un borde curvo suave a escala gruesa. • **Superación con SIFT (Lowe, 2004):** SIFT soluciona esta limitación construyendo un espacio de escalas continuo mediante la pirámide de Diferencia de Gaussianas (DoG), detectando extremos en una representación $3D$ (x, y, σ) que asegura invarianza estricta de escala.

📘 FUNDAMENTACIÓN GEOMÉTRICA Y ESPACIAL (UNIR)

Tema 4 VA UNIR; Harris & Stephens (1988), Lowe (2004). Bloque angular de la visión geométrica y odometría visual.

⚠️ TRAMPAS CLÁSICAS DE EXAMEN EN VISIÓN ARTIFICIAL

Afirmar que Harris es invariante a escala. Es una de las trampas más recurrentes en exámenes de Visión Artificial de la UNIR. Harris es invariante a rotación y traslación, PERO NO A ESCALA.

5. Investigación y Gestión de Proyectos en IA (IGP)

Contenidos evaluados: Paradigmas Científicos (Bioinspirada vs Biología Computacional), Diseño Experimental (Variables Independientes, Dependientes y Control), Memoria de Proyecto I+D+i.

IGP | Tema 1: Paradigmas de Investigación en IA | Pregunta Corta Oficial de Examen | IGP-EJ-01

Computación Bioinspirada vs. Biología Computacional

Enunciado oficial de examen:
Explica la diferencia entre la **computación bioinspirada (o biológica)** y la **biología computacional**, y pon un ejemplo canónico de cada una. (Espacio máx. 16 líneas).

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Computación Bioinspirada (Biologically Inspired Computing): • **Definición y Objetivo:** Toma principios, dinámicas, leyes y mecanismos observados en los sistemas biológicos naturales (la evolución darwiniana, la inteligencia colectiva de enjambres, el sistema inmunitario o la sinapsis neuronal) para **diseñar nuevos modelos algorítmicos y resolver problemas complejos de optimización, búsqueda y aprendizaje en ciencias de la computación**. Su fin último es *mejorar la informática*. • **Ejemplo canónico:** Los **Algoritmos Genéticos (GA)** o la Optimización por Enjambre de Partículas (PSO), que emulan la selección natural y el comportamiento de bandadas de aves para optimizar funciones multiobjetivo no convexas de ingeniería o rutas de vehículos. **2. Biología Computacional (Computational Biology / Bioinformática):** • **Definición y Objetivo:** Es una rama aplicada multidisciplinar que **utiliza herramientas, algoritmos, software y capacidad de cálculo informático para modelar, simular, procesar, comprender y resolver problemas específicos de la biología y la medicina**. Su fin último es *comprender la biología*. • **Ejemplo canónico:** La predicción del plegamiento tridimensional de proteínas mediante redes profundas (como **AlphaFold**) o el alineamiento de secuencias genómicas masivas de ADN mediante algoritmos dinámicos (como BLAST o Smith-Waterman) para identificar mutaciones patológicas del cáncer.

Dimensión	Computación Bioinspirada	Biología Computacional
Inspiración / Origen	De la Biología hacia la Informática	De la Informática hacia la Biología
Objetivo Primordial	Desarrollar algoritmos más eficientes y robustos	Comprender fenómenos y sistemas biológicos reales
Campo de Aplicación	Optimización de rutas, diseño industrial, ML	Genómica, farmacología, medicina personalizada

📘 FUNDAMENTACIÓN EPISTEMOLÓGICA Y DE GESTIÓN (UNIR)

Tema 1 IGP UNIR. Diferenciación epistemológica elemental entre ambos paradigmas científicos.

⚠️ ERRORES CRÍTICOS DE PLANTEAMIENTO METODOLÓGICO

En examen: invertirlos (decir que la bioinspirada modela genes y la computacional crea algoritmos). La bioinspirada *se inspira* en la vida para hacer código; la computacional *usa* el código para estudiar la vida.

IGP | Tema 2: Metodología Científica y Diseño Experimental | Pregunta Corta Oficial de Examen | IGP-EJ-02

Identificación de Variables en Diseño Experimental de IA

Enunciado oficial de examen:
Un equipo de investigación desea evaluar el impacto de una nueva técnica de poda dinámica frente a la poda estándar en redes neuronales profundas para visión artificial en edge computing.
Defina con rigor epistemológico los tres tipos de variables presentes en el diseño experimental:
1. Variable(s) Independiente(s).
2. Variable(s) Dependiente(s).
3. Variable(s) de Control / Factores Fijos.
Explique qué condiciones metodológicas aseguran la validez interna del experimento.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Identificación rigurosa de variables: • **Variable Independiente (Causa / Factor manipulado activamente):** - El **método de poda aplicado a la red neuronal** (variable categórica con dos niveles o tratamientos: *Técnica de Poda Dinámica Propuesta* vs. *Poda Estándar Magnitud L1 / Baseline*). • **Variable(s) Dependiente(s) (Efecto / Respuestas cuantitativas medidas):** - **Tasa de acierto / F1-score:** Métrica de rendimiento predictivo sobre el conjunto de test independiente. - **Latencia de inferencia:** Tiempo medio de ejecución por imagen (en milisegundos) en el dispositivo edge. - **Huella de memoria:** Tamaño final del modelo cuantizado en megabytes (MB). • **Variables de Control (Factores fijos para evitar variables de confusión):** - Misma arquitectura de red troncal (backbone idéntico: p. ej., MobileNetV3). - Mismo conjunto de datos con idéntico split de entrenamiento, validación y test (`random_state` prefijado). - Mismo hardware físico de evaluación (dispositivo edge idéntico: Raspberry Pi 4 con la misma versión de runtime ONNX / TensorRT, misma temperatura ambiente para evitar throttling térmico). - Mismo hiperparámetro de optimización previo (optimizador AdamW, learning rate, número de épocas). **2. Garantía de Validez Interna y Reproducibilidad:** Para garantizar que cualquier mejora en las variables dependientes se deba *única y exclusivamente* a la variable independiente manipulada: 1. **Repetición experimental con semillas múltiples:** Ejecutar $N \ge 10$ repeticiones aleatorias con diferentes semillas pseudoaleatorias para calcular medias e intervalos de confianza. 2. **Contraste de Hipótesis Estadístico:** Aplicar un test no paramétrico de rangos con signo de **Wilcoxon** (o t-Student si se verifica normalidad con Shapiro-Wilk) verificando significancia estadística con $p\text{-valor} < 0.05$.

📘 FUNDAMENTACIÓN EPISTEMOLÓGICA Y DE GESTIÓN (UNIR)

Tema 2 IGP UNIR; Montgomery (2017). El diseño experimental riguroso es la piedra angular del método científico en Inteligencia Artificial.

⚠️ ERRORES CRÍTICOS DE PLANTEAMIENTO METODOLÓGICO

Confundir la variable independiente con la dependiente (p. ej., decir que la latencia es independiente), o no fijar el hardware de prueba, lo que invalidaría el experimento por ruido de confounders externos.

IGP | Tema 3: Gestión y Redacción de Proyectos I+D+i | Caso Práctico Oficial de Desarrollo | IGP-EJ-03

Memoria de Propuesta I+D+i: Estructura Formal y Paquetes de Trabajo

Enunciado oficial de examen:
Estructure una propuesta de proyecto de investigación aplicada en IA para convocatorias oficiales (Horizonte Europa / Plan Estatal) con un presupuesto simulado de 250.000 € y 24 meses de duración, centrada en 'Detección Temprana de Fugas en Redes de Distribución de Agua mediante Aprendizaje Profundo y Gemelos Digitales'.
Detalle:
1. Resumen, hipótesis científica y objetivos SMART.
2. Metodología basada en MLOps / CRISP-DM.
3. Desglose en Paquetes de Trabajo (WP1 a WP5) con entregables e hitos.
4. Matriz de gestión de riesgos y plan de contingencia.

✅ RESOLUCIÓN OFICIAL PASO A PASO

1. Resumen, Hipótesis y Objetivos SMART: • **Acrónimo y Título:** *AQUA-TWIN: Gemelo Digital y Redes Neuronales de Grafos para la Detección y Localización de Fugas Hídricas en Tiempo Real*. • **Hipótesis Científica Falsable:** «La integración de Redes Neuronales de Grafos Espacio-Temporales (ST-GNN) con modelos hidráulicos de simulación física permite detectar y geolocalizar anomalías de presión correspondientes a fugas hídricas con una precisión métrica $\le 25\text{ metros}$ y una anticipación $\ge 48\text{ horas}$ frente a los métodos de telemetría acústica convencionales». • **Objetivos SMART:** - *O1:* Desarrollar una canalización de ingesta continua de series temporales de 500 sensores de caudal y presión con latencia $< 5\text{ segundos}$ (Mes 6). - *O2:* Entrenar un modelo híbrido GNN-Física alcanzando un $F_1\text{-score} \ge 0.92$ en validación cruzada temporal (Mes 14). - *O3:* Reducir el volumen de agua no registrada en un 18% en un piloto real de 100 km de red (Mes 24). **2. Metodología de Desarrollo:** Se adopta el ciclo de vida **CRISP-ML(Q)** adaptado a MLOps: 1. Comprensión del negocio hidráulico y formulación del problema. 2. Ingeniería de datos, detección de derivas (Data Drift) y validación de calidad. 3. Modelado algorítmico, reproducibilidad con DVC y MLflow. 4. Pruebas de integración, verificación de seguridad y empaquetado en contenedores Docker. 5. Despliegue en producción con monitorización continua de Concept Drift. **3. Estructura de Paquetes de Trabajo (Work Packages):**

WP	Título del Paquete de Trabajo	Meses	Líder	Entregables Principales (Deliverables)
WP1	Gestión del Proyecto, Coordinación y Ética	M1-M24	IP	D1.1 Plan de Gestión de Datos (M3); D1.2 Informe Final (M24).
WP2	Ingesta de Telemetría e Infraestructura Big Data	M1-M8	Data Eng	D2.1 Pipeline de Ingesta Kafka/Spark y Limpieza (M6).
WP3	Investigación y Desarrollo del Modelo ST-GNN	M6-M16	IA Lead	D3.1 Arquitectura del Modelo y Pesos de Entrenamiento (M14).
WP4	Piloto de Validación en Entorno Operativo Real	M14-M22	Ops Lead	D4.1 Informe de Pruebas de Campo en Red Hidráulica (M20).
WP5	Transferencia Tecnológica, Difusión y Explotación	M12-M24	Transfer	D5.1 Publicación científica Q1 y D5.2 Plan de Patente (M24).

4. Matriz de Gestión de Riesgos y Plan de Contingencia: • **Riesgo 1 (Técnico - Probabilidad Media, Impacto Alto):** Caída masiva o ruido severo en sensores IoT de presión. - *Plan de Contingencia:* Implementación en WP2

de un módulo de imputación basado en matrices de covarianza espacial de Kriging hidráulico. • **Riesgo 2 (Científico - Probabilidad Baja, Impacto Alto):** Rendimiento insuficiente de las ST-GNN por grafos dinámicos de válvulas cerradas. - *Plan de Contingencia:* Transición al plan alternativo en WP3 con un ensamble de Isolation Forest y modelos de simulación hidráulica EPANET multivariable. • **Riesgo 3 (Operativo - Probabilidad Media, Impacto Medio):** Demora en la instalación de caudalímetros por la empresa concesionaria. - *Plan de Contingencia:* Calibración temporal con datasets históricos de benchmark internacional (Battle of the Water Networks) durante los primeros 4 meses.

📘 FUNDAMENTACIÓN EPISTEMOLÓGICA Y DE GESTIÓN (UNIR)

Tema 3 IGP UNIR; Guías oficiales de Horizonte Europa y estándares UNE 166002 de Gestión de la I+D+i.

⚠️ ERRORES CRÍTICOS DE PLANTEAMIENTO METODOLÓGICO

En examen: olvidar la hipótesis científica, proponer un cronograma irreal sin holguras o no estructurar los paquetes de trabajo con entregables claros e indicadores SMART.