Tabla Maestra Curricular: Temas 1 al 10 + Ejercicios de Examen UNIR

Organización estricta por Temas (Temas 1 al 10) con las 5 dimensiones obligatorias (Concepto, Definición Rigurosa, Bondades, Limitaciones y Evolución), subsección de Ejercicios Numéricos y Prácticos resueltos paso a paso (Viterbi, Lesk, N-Gramas BERP, CKY y BoW-TF-IDF), Casos de Examen y Guía spaCy v3+.

T1 Tema 1: Introducción al Procesamiento del Lenguaje Natural y Niveles Lingüísticos

Semana 1 · Fundamentos y Ambigüedad

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Niveles del Análisis Lingüístico Fonológico, Morfológico, Sintáctico, Semántico, Pragmático	Descomposición jerárquica modular del lenguaje natural: Fonético/Fonológico (sonidos físicos y fonemas) → Morfológico (estructura interna de palabras y lemas) → Sintáctico (reglas de combinación en sintagmas y oraciones) → Semántico (significado literal composicional) → Pragmático (intención del hablante y contexto extralingüístico).	**Modularidad** Permite desacoplar y resolver cada subsistema lingüístico con algoritmos y modelos matemáticos específicos y testeables.	**Propagación de error** Un fallo en un nivel inicial (ej. mala segmentación de oraciones o tokenización errónea) contamina irreversiblemente todos los niveles superiores.	**Arquitecturas End-to-End** Modelos Transformer masivos (LLMs) que aprenden representaciones latentes conjuntas sin necesidad de módulos rígidos secuenciales.	**Pregunta UNIR:** ¿En qué nivel se interpreta la ironía o el sarcasmo? ➔ **Nivel Pragmático**. **spaCy:** `nlp.pipe_names` lista los componentes del pipeline en cascada.
Tipos de Ambigüedad en PLN Léxica, Sintáctica, Semántica, Referencial	Propiedad intrínseca del lenguaje humano donde una expresión formal admite dos o más interpretaciones computacionales válidas según el nivel lingüístico evaluado.	**Economía del Lenguaje** Permite expresar infinidad de ideas con un número finito de lexemas y reglas gramaticales.	**Explosión Combinatoria** Sin conocimiento del mundo (World Knowledge), un analizador formal genera decenas de árboles sintácticos válidos para una sola frase.	**Modelos Contextuales Densos** Embeddings dinámicos (BERT/RoBERTa) que ajustan el vector semántico según la ventana de contexto completa.	**Examen:** "Vi a la mujer con el telescopio" ➔ **Ambigüedad Sintáctica / Adjuncin de Sintagma Preposicional (PP-Attachment)**.
Pipeline de PLN y Error Cascading Arquitectura Secuencial Clásica	Cadena de procesamiento donde la salida de una fase alimenta la siguiente: Texto crudo → Tokenización → Normalización → POS Tagging → Parsing → Extracción de Información.	**Interpretabilidad total** Cada fase produce anotaciones intermedias auditables (etiquetas Penn Treebank, árboles CKY, etc.).	**Efecto Cascada** Si cada una de 5 etapas tiene una precisión del 95%, la precisión global decae drásticamente a $0.95^5 \approx 77.38\%$.	**Fine-Tuning Conjunto** Modelos multiextremo (Multi-task Learning) y Transformers ajustados para resolver la tarea final directamente.	**Criterio Tribunal:** En sistemas industriales críticos, justificar si se asume error cascading o se opta por un transformer end-to-end.

EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 1

Examen UNIR
Ejercicio 1.1: Clasificación Formal de Ambigüedades Teoría & Test

Identificar el nivel exacto de ambigüedad en los siguientes casos tipo examen:

Caso A: «El cura curó al herido con devoción».
➔ Ambigüedad Léxica (Categoría gramatical/Polisemia): "cura" como sustantivo eclesiástico o forma del verbo curar.
Caso B: «Vimos al hombre con el telescopio».
➔ Ambigüedad Sintáctica / Estructural (PP-Attachment): ¿El hombre tenía el telescopio o nosotros usamos el telescopio para verlo?
Caso C: «Pedro le dio a Juan su cuaderno porque estaba roto».
➔ Ambigüedad Referencial (Anáfora / Esquema de Winograd): ¿De quién era el cuaderno y qué estaba roto? Requiere World Knowledge.
Caso D: «¡Qué puntual eres!» dicho a alguien con 40 minutos de retraso.
➔ Ambigüedad Pragmática (Sarcasmo / Acto de Habla): El significado intencional contradice el significado literal composicional.
Ejercicio 1.2: Cálculo de Propagación de Error en Cascada Cálculo Numérico

Un sistema clásico consta de 4 etapas secuenciales independientes: Tokenización (A_1), POS Tagging (A_2), Lematización (A_3) y NER (A_4).

Precisiones individuales: $p_1 = 0.98$, $p_2 = 0.94$, $p_3 = 0.95$, $p_4 = 0.88$.

$$P(\text{Éxito Global}) = \prod_{i=1}^{4} p_i = 0.98 \times 0.94 \times 0.95 \times 0.88 = \mathbf{0.7702} \ (77.02$$

$$E_{\text{cascada}} = 1 - P(\text{Éxito Global}) = 1 - 0.7702 = \mathbf{0.2298} \ (22.98$$

Conclusión Técnica para Caso Práctico: Aunque cada componente individual rinda por encima del 88%, el pipeline completo pierde casi un 23% de fiabilidad neta por efecto multiplicativo de error acumulado.

T2 Tema 2: El Texto como Dato: Preprocesamiento y Representación Vectorial

Semanas 2 y 3 · BoW, TF-IDF y Similitud Coseno

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Pipeline Canónico de Preprocesamiento Limpieza, Tokenización, Normalización, Stopwords	Conjunto de transformaciones para convertir texto no estructurado en secuencias de unidades discretas estandarizadas: filtrado de ruido (HTML, emojis, puntuación) $\rightarrow$ segmentación léxica (tokenización) $\rightarrow$ normalización (case folding, diacríticos) $\rightarrow$ eliminación de palabras vacías (stopwords).	**Reducción del Vocabulario** Reduce la dimensionalidad del espacio vectorial hasta en un 60-70% y homogeneiza entradas ruidosas.	**Pérdida Semántica Irreversible** Eliminar stopwords puede destruir el sentido en tareas como negación («no es bueno») o sentimiento.	**Tokenización por Subpalabras** Algoritmos BPE (Byte-Pair Encoding), WordPiece y SentencePiece que gestionan vocabulario abierto sin filtrar stopwords.	**spaCy:** `token.is_stop`, `token.is_punct`, `token.like_num`.
Lematización vs. Stemming Porter / Snowball vs WordNet / spaCy	**Stemming:** Proceso heurístico basado en reglas de corte de sufijos morfológicos para obtener la raíz (stem), sin garantizar palabras reales (ej. "estudi" de "estudiando"). **Lematización:** Reducción al lema canónico del diccionario mediante análisis morfológico y categoría gramatical (POS) (ej. "ir" de "fui").	**Lematización = Precisión Lingüística** Conserva la validez léxica y semántica del término, evitando raíces truncadas sin sentido.	**Coste Computacional** La lematización requiere un modelo morfosintáctico completo y diccionarios, siendo 5x a 10x más lenta que el stemming heurístico.	**Subword Tokenization** Fragmentación subléxica estadística en Transformers que no requiere lemas externos.	**Examen:** "mejor" ➔ Lema: "bueno" (adjetivo). Stemmer produciría "mejor". **spaCy:** `token.lemma_`.
Representación BoW y TF-IDF Term Frequency - Inverse Document Frequency	Esquema numérico donde cada documento se representa como un vector de dimensión $\lvert V\rvert$. TF mide la frecuencia local del término en el documento, mientras que IDF penaliza términos ubicuos en el corpus: $\text{TF-IDF}(t,d,D) = \text{TF}(t,d) \times \log_{10}\left(\frac{N}{\text{DF}_t}\right)$.	**Relevancia Discriminante** Filtra automáticamente palabras comunes y resalta términos específicos y distintivos de cada documento.	**Independencia Léxica y Matriz Dispersa** Asume independencia total de términos (ignora orden y sintaxis) y genera matrices con >99% de ceros.	**Dense Word Embeddings** Vectores continuos densos de baja dimensión (Word2Vec, GloVe, BERT) que capturan relaciones semánticas contextuales.	**Fórmula de Examen:** Si $\text{DF}_t = N$, $\text{IDF}_t = \log_{10}(1) = 0$. Un término presente en todos los documentos tiene peso TF-IDF = 0.

📐 EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 2

Cálculo Oficial Celia Cabello
2.1 EJERCICIO OFICIAL DE CLASE: TF-IDF Y SIMILITUD COSENO COMPLETO
Mini-Corpus UNIR ($N = 3$)
Corpus de Documentos:

D_1: «el gato duerme»
D_2: «el perro duerme»
D_3: «el gato persigue perro»
Stopword filtrada: "el". Vocabulario limpio $V = [\text{"gato"}, \text{"perro"}, \text{"duerme"}, \text{"persigue"}]$, $|V| = 4$. $N = 3$.
Fórmulas Canónicas:

$$\text{TF}(t, d) = \text{conteo}(t, d)$$

$$\text{IDF}(t) = \log_{10}\left(\frac{N}{\text{DF}_t}\right) = \log_{10}\left(\frac{3}{\text{DF}_t}\right)$$

$$\text{Similitud Coseno}(\vec{u}, \vec{v}) = \frac{\vec{u} \cdot \vec{v}}{\|\vec{u}\|\|\vec{v}\|}$$

Término (t)	Doc Freq (DF_t)	Cálculo IDF ($\log_{10}(3/\text{DF})$)	Valor IDF
gato	2 (D_1, D_3)	$\log_{10}(3/2) = \log_{10}(1.5)$	0.176
perro	2 (D_2, D_3)	$\log_{10}(3/2) = \log_{10}(1.5)$	0.176
duerme	2 (D_1, D_2)	$\log_{10}(3/2) = \log_{10}(1.5)$	0.176
persigue	1 (D_3)	$\log_{10}(3/1) = \log_{10}(3.0)$	0.477

Vectores TF-IDF y Cálculo del Ángulo Coseno entre D_1 y D_2:
• Vector D_1 («gato duerme»): $\vec{v}_1 = [0.176,\ 0,\ 0.176,\ 0]$
• Vector D_2 («perro duerme»): $\vec{v}_2 = [0,\ 0.176,\ 0.176,\ 0]$
• Producto Escalar: $\vec{v}_1 \cdot \vec{v}_2 = (0.176 \times 0) + (0 \times 0.176) + (0.176 \times 0.176) + (0 \times 0) = 0.176^2 = \mathbf{0.030976}$
• Normas Euclidianas (L_2): $\|\vec{v}_1\| = \sqrt{0.176^2 + 0.176^2} = 0.176\sqrt{2} \approx \mathbf{0.2489}$; $\|\vec{v}_2\| \approx \mathbf{0.2489}$

$$\text{Similitud Coseno}(D_1, D_2) = \frac{\vec{v}_1 \cdot \vec{v}_2}{\|\vec{v}_1\| \cdot \|\vec{v}_2\|} = \frac{0.176^2}{(0.176\sqrt{2})^2} = \frac{0.176^2}{2 \times 0.176^2} = \frac{1}{2} = \mathbf{0.500}\ (50$$

Ejercicio 2.2: Programación Dinámica para Distancia de Edición (Levenshtein) Matriz Dinámica

Calcular la distancia de edición mínima entre las palabras $s_1 = \text{"gato"}$ y $s_2 = \text{"pato"}$, y entre $s_1 = \text{"casa"}$ y $s_2 = \text{"caso"}$ con costes unitarios ($I = 1, D = 1, S = 1$ si $a \neq b$, $S = 0$ si $a = b$).

Caso "gato" $\rightarrow$ "pato":
Alineamiento: $[g \rightarrow p]$ (Sustitución), $[a \rightarrow a]$ (Coincidencia), $[t \rightarrow t]$ (Coincidencia), $[o \rightarrow o]$ (Coincidencia).
$\text{Coste Total} = 1 + 0 + 0 + 0 = \mathbf{1}$. Distancia de Levenshtein = 1.
Caso "sol" $\rightarrow$ "suelo":
Alineamiento: $[s \rightarrow s]$, $[\varepsilon \rightarrow u]$ (Inserción), $[o \rightarrow e]$ (Sustitución), $[l \rightarrow l]$, $[\varepsilon \rightarrow o]$ (Inserción).
$\text{Coste Total} = 0 + 1 + 1 + 0 + 1 = \mathbf{3}$. Distancia de Levenshtein = 3.

T3 Tema 3: Etiquetado Morfosintáctico (POS Tagging), HMM y Algoritmo de Viterbi

Semanas 4 y 5 · HMM y Decodificación Óptima

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Modelo Oculto de Markov (HMM) Estados Ocultos (t_i) vs Observaciones (w_i)	Modelo probabilístico generativo gráfico que asume que la secuencia de palabras observables $W = (w_1, \ldots, w_T)$ es generada por una secuencia subyacente de etiquetas morfosintácticas ocultas $T = (t_1, \ldots, t_T)$. Se parametriza mediante: probabilidades iniciales $\pi_i = P(t_i \mid \text{START})$, matriz de transición $A = [a_{ij}] = P(t_j \mid t_i)$ y matriz de emisión $B = [b_j(k)] = P(w_k \mid t_j)$.	**Estimación Directa** Los parámetros se calculan trivialmente por conteo frecuencial (MLE) sobre un corpus anotado.	**Hipótesis de Markov Estricta** El estado actual sólo depende del estado inmediatamente anterior (t_{i-1}) y la palabra sólo de su propio estado (t_i), ignorando contexto lejano.	**Campos Aleatorios Condicionales (CRF)** Modelos discriminativos que calculan $P(T \mid W)$ directamente con funciones de características globales.	**Penn Treebank:** `DT` (det), `NN` (sustantivo), `NNP` (nombre propio), `VB/VBD` (verbo), `JJ` (adjetivo), `RB` (adverbio).
Algoritmo de Viterbi Decodificación Óptima por Programación Dinámica	Algoritmo de programación dinámica que encuentra la secuencia de estados ocultos más probable $\hat{T} = \arg\max_T P(W, T)$ evaluando recursivamente enrejados (trellis): $v_t(j) = \max_{i=1}^{N}[v_{t-1}(i) \cdot a_{ij}] \cdot b_j(w_t)$, almacenando punteros hacia atrás (backpointers) para recuperar el camino global óptimo.	**Complejidad Polinómica $\mathcal{O}(T \cdot N^2)$** Reduce la complejidad exponencial de fuerza bruta $\mathcal{O}(N^T)$ a tiempo lineal respecto a la longitud de la oración T.	**Underflow Aritmético** Multiplicar cientos de probabilidades menores que 1 produce ceros flotantes; obliga a operar estrictamente en escala logarítmica (Log-Viterbi).	**Decodificación Neuronal BiLSTM-CRF** Redes bidireccionales con capa CRF que capturan dependencias de larga distancia hacia adelante y hacia atrás.	**Pregunta Fija de Examen:** Se pregunta por qué gana un estado frente a otro en una celda (ej. VBD sobre NN). Justificar por producto $\max[v_{t-1} \cdot a_{ij}] \cdot b_j$.

EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 3

Cálculo Oficial Celia Cabello
3.1 EJERCICIO OFICIAL: MINI-CORPUS ANOTADO Y CONTEO DE PROBABILIDADES HMM Semana 4 Diapositiva Pág. 7
Mini-Corpus Anotado:
1. El/DT gato/NN duerme/VB
2. La/DT gata/NN come/VB pescado/NN
3. Un/DT perro/NN corre/VB
Secuencias con START y END:
1. START → DT → NN → VB → END
2. START → DT → NN → VB → NN → END
3. START → DT → NN → VB → END

Origen (t_{i-1})	Destino (t_i)	Conteo Transición	Total desde Origen	Probabilidad $P(t_i \mid t_{i-1})$
START	DT	3	3	3/3 = 1.00
DT	NN	3	3	3/3 = 1.00
NN	VB	3	4	3/4 = 0.75
	END	1		1/4 = 0.25
VB	END	2	3	2/3 = 0.67
	NN	1		1/3 = 0.33

3.2 EJERCICIO OFICIAL: TRELLIS DE VITERBI PARA "EL SEÑOR VINO TARDE"
Diapositiva Pág. 28 Resuelta

Estado (S)	<start> ($t = 0$)	El ($t = 1$)	Señor ($t = 2$)	Vino ($t = 3$)	Tarde ($t = 4$)	<end> ($t = 5$)
<end>	-	0	0	0	0	Backtrace
DT	-	0.1013	0	0	0	-
NN	-	0	0.00961134	0.00011687	0.000000710	-
NNP	-	0	0.00174287	0	0	-
JJ	-	0	0.00218504	0	0	-
VBD	-	0	0	0.00012072	0.000000733	-
RB	-	0	0	0	0.000002482	-
<start>	1.0000	0	0	0	0	-

Razonamiento y Decisión de Viterbi en los Puntos Críticos:

- **Paso $t = 1$ ("El"):** Solo DT recibe masa de probabilidad inicial: $v_1(\text{DT}) = 1.0 \times P(\text{DT} \mid \text{START}) \times P(\text{"El"} \mid \text{DT}) = \mathbf{0.1013}$. Las demás celdas son 0.
- **Paso $t = 2$ ("Señor"):** Todas las ramas provienen de DT ($v_1 = 0.1013$). Se calculan: NN (0.00961134), NNP (0.00174287) y JJ (0.00218504). Gana **NN** como estado dominante.
- **Paso $t = 3$ ("Vino") [Punto Clave de Examen]:** Ambigüedad entre verbo (VBD) y sustantivo bebida (NN).
  • Rama VBD: $v_2(\text{NN}) \times P(\text{VBD} \mid \text{NN}) \times P(\text{"vino"} \mid \text{VBD}) = \mathbf{0.00012072}$.
  • Rama NN: $v_2(\text{NN}) \times P(\text{NN} \mid \text{NN}) \times P(\text{"vino"} \mid \text{NN}) = \mathbf{0.00011687}$.
  Decisión: Gana `VBD (0.00012072 > 0.00011687)`. Viterbi desambigua correctamente "vino" como acción verbal tras el sustantivo.
- **Paso $t = 4$ ("Tarde"):** RB alcanza $\mathbf{0.000002482}$, superando a VBD (0.000000733) y NN (0.000000710). Gana **RB (Adverbio)**.

🎯 Secuencia Óptima Global (Backtrace): `<start> → DT ("El") → NN ("Señor") → VBD ("Vino") → RB ("Tarde") → <end>`

T4 Tema 4: Análisis Sintáctico (Parsing), Gramáticas Libres de Contexto (CFG) y Algoritmo CKY

Semana 6 · Parsing Bottom-Up en Forma Normal de Chomsky

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Forma Normal de Chomsky (FNC / CNF) $A \to B\ C$ o $A \to a$	Restricción canónica de las Gramáticas Libres de Contexto (CFG) donde toda regla de producción debe adoptar exclusivamente dos formas: binaria no terminal ($A \to B\ C$) o unaria terminal ($A \to a$, con $a \in \Sigma$). Exige eliminar reglas ε (épsilon), reglas unitarias ($A \to B$) y binarizar reglas con ≥ 3 hijos.	**Binarización Estricta** Transforma cualquier árbol de derivación en un árbol estrictamente binario, permitiendo algoritmos de programación dinámica de tiempo polinómico.	**Pérdida de Intuición Lingüística** Introduce símbolos no terminales auxiliares ficticios (ej. X_1, X_2) que complican la lectura directa del árbol de constituyentes.	**Gramáticas Probabilísticas (PCFG)** CFGs donde cada regla de producción lleva asociada una probabilidad condicional $P(A \to \alpha)$.	**Requisito Innegociable CKY:** Si una gramática no está en CNF, CKY **no puede ejecutarse**.
Algoritmo CKY (Cocke-Kasami-Younger) Parsing Ascendente (Bottom-Up)	Algoritmo de análisis sintáctico por programación dinámica que rellena una tabla triangular de dimensión $(n+1) \times (n+1)$ para una oración de longitud n. La diagonal almacena los terminales léxicos ($A \to w_i$) y las celdas superiores (i, j) computan todas las particiones intermedias k ($i < k < j$) combinando celdas (i, k) y (k, j) según reglas $A \to B\ C$.	**Optimalidad Garantizada** $\mathcal{O}(n^3 \cdot \lvert R \rvert)$ Encuentra todos los análisis válidos posibles sin recalcular subárboles compartidos (evita backtracking exponencial).	**Ambigüedad No Resuelta** Si la gramática es ambigua, CKY almacena múltiples símbolos o árboles sin criterio para ordenar cuál es más probable.	**Algoritmo Probabilístico CKY (p-CKY)** Extensión con probabilidades logarítmicas que decodifica el árbol sintáctico global más probable (análogo a Viterbi).	**Pregunta Examen:** ¿En qué celda se verifica la validez de la oración completa? En la celda superior derecha $(0, n)$, donde debe aparecer el axioma inicial O (o S).

EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 4

Cálculo Oficial Celia Cabello
4.1 EJERCICIO OFICIAL: PARSING CKY Y RECONSTRUCCIÓN DEL ÁRBOL SINTÁCTICO
"El gato come pescado" ($n = 4$)
Matriz Triangular CKY (Reemplazo Nativo de Diapositiva Pág. 33):

Fila \ Col	1 ("El")	2 ("gato")	3 ("come")	4 ("pescado")
0	(0, 1) {Det}	(0, 2) {SN}	(0, 3) ∅	(0, 4) {O} ★
1	-	(1, 2) {N, SN}	(1, 3) ∅	(1, 4) {O}
2	-	-	(2, 3) {Vt}	(2, 4) {SV}
3	-	-	-	(3, 4) {N, SN}

Reglas gramaticales aplicadas: $O \rightarrow SN\ SV$, $SN \rightarrow Det\ N$, $SV \rightarrow Vt\ SN$, $SN \rightarrow N$.

Árbol Sintáctico Constituyente Reconstruido (Backpointers):
[O] Axioma Oracional Válido (Celda 0, 4)
SN (Celda 0, 2)
Det
«El»
N
«gato»
SV (Celda 2, 4)
Vt
«come»
SN → N
«pescado»
Fórmula de Derivación: $O \implies [SN \rightarrow Det(\text{”El”}) + N(\text{”gato”})] + [SV \rightarrow Vt(\text{”come”}) + SN(N(\text{”pescado”}))]$

⚡ **Complejidad de Examen:** Tiempo $\mathcal{O}(n^3 \cdot |R|)$ y Espacio $\mathcal{O}(n^2 \cdot |N|)$. Para $n = 4$, requiere únicamente $4(4+1)/2 = 10$ celdas evaluadas.
Ejercicio 4.2: Transformación Paso a Paso de CFG a Forma Normal de Chomsky Binarización

Dada la regla de sintagma verbal ternario $SV \rightarrow Vt\ SN\ SP$ (ej. "envió una carta a María"):

1. Regla no binaria: tiene 3 no terminales en su parte derecha (Vt, SN, SP).
2. Se introduce el símbolo auxiliar X_1:
• $SV \rightarrow Vt\ X_1$ (Regla estrictamente binaria)
• $X_1 \rightarrow SN\ SP$ (Regla estrictamente binaria)
Resultado: Gramática equivalente en CNF computable por CKY.

T5 Tema 5: Semántica Léxica, Recursos Léxicos y Ontologías (WordNet)

Semana 7 · Relaciones Léxicas y Medidas Taxonómicas

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
WordNet y Synsets Base de Conocimiento Léxico-Semántica	Red léxica estructurada donde la unidad básica es el **Synset** (conjunto de palabras sinónimas intercambiables en un contexto dado). Organiza sustantivos, verbos, adjetivos y adverbios mediante relaciones léxico-semánticas explícitas: *hiperonimia* (tipo-de), *hiponimia* (subtipo), *meronimia* (parte-de) y *holonimia* (todo-de).	Semántica Estructurada Verificable Permite razonar sobre distancias conceptuales, herencia de propiedades y relaciones ontológicas curadas por lingüistas humanos.	Cobertura y Granularidad Excesiva Distinciones de sentido hiperfinas que dificultan la desambiguación automática y desactualización ante neologismos o jerga técnica.	Grafos de Conocimiento Multilingües BabelNet (integración de WordNet + Wikipedia) y Wikidata, que conectan conceptos léxicos con entidades del mundo real.	**NLTK:** `wordnet.synsets('bank')` devuelve `bank.n.01` (financiero), `bank.n.02` (orilla), etc.
Medidas de Similitud Taxonómica Path Sim, Leacock-Chodorow, Resnik	Funciones matemáticas que cuantifican la cercanía semántica entre dos conceptos en la jerarquía 'is-a' de WordNet: **Path Similarity:** $\frac{1}{\text{dist}(c_1,c_2)+1}$; **Leacock-Chodorow:** $-\log\left(\frac{\text{len}(c_1,c_2)}{2D}\right)$; **Resnik:** Basada en Contenido de Información (IC) del Ancestro Común más Específico: $\text{sim}(c_1,c_2) = \text{IC}(\text{LCS}(c_1,c_2))$.	Fundamentación Teórica Robusta Las métricas basadas en IC (Resnik, Lin) no se ven afectadas por densidades desiguales en las ramas del árbol taxonómico.	Sólo entre la Misma Categoría POS No permite medir similitud entre un sustantivo y un verbo (ej. "destrucción" y "destruir") al pertenecer a taxonomías desconectadas.	Similitud Vectorial por Coseno Representaciones densas continuas (Embeddings) donde cualquier palabra o frase puede compararse directamente en $\mathbb{R}^d$.	**Examen:** El *LCS (Lowest Common Subsumer)* es el ancestro común más profundo que comparten dos conceptos en la jerarquía.

EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 5

Taxonomía WordNet
Ejercicio 5.1: Cálculo Analítico de Path Similarity en WordNet Métrica Taxonómica

Dada la jerarquía is-a: `entidad` → `ser vivo` → `animal` → `carnívoro` → `cánido` → `perro` y `cánido` → `lobo`.

1. Distancia de aristas entre `perro` y `lobo`:
LCS(perro, lobo) = cánido. dist(perro, cánido) = 1; dist(lobo, cánido) = 1.
Longitud total camino: $\text{len} = 1 + 1 = 2$ aristas.
2. Fórmula de Path Similarity:

$$\text{PathSim}(\text{perro}, \text{lobo}) = \frac{1}{\text{dist} + 1} = \frac{1}{2+1} = \mathbf{0.333}$$

Si dos conceptos son idénticos ($extdist = 0$), $extPathSim = 1.0$. Si están infinitamente separados, tiende a 0.

Ejercicio 5.2: Identificación Formal de Relaciones Semánticas Test UNIR

Hiperonimia / Hiponimia (Tipo-de / Relación 'is-a'):

«perro» es un hipónimo de «animal» (más específico). «animal» es hiperónimo de «perro» (más general).

Meronimia / Holonimia (Parte-de / 'has-a'):

«volante» es merónimo de «automóvil» (es una parte de él). «automóvil» es holónimo de «volante» (el todo).

Troponimia (Manera de hacer un verbo):

«susurrar» es un tropónimo de «hablar» (manera específica de hablar).

T6 Tema 6: Desambiguación del Sentido de las Palabras (WSD)

Semana 7 y 8 · Algoritmos de Lesk, Schütze y Yarowsky

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Algoritmo de Lesk Original (1986) vs Simplificado (Kilgarriff 2000)	Enfoque basado en conocimiento que resuelve la polisemia comparando el **solapamiento léxico** (intersección de palabras de contenido) entre el contexto de la oración y las glosas/ejemplos de cada sentido en un diccionario o WordNet: $\hat{S} = \arg\max_{S_k} \lvert \text{Bolsa}(Contexto) \cap \text{Firma}(S_k) \rvert$.	**Cero Entrenamiento Anotado** No requiere corpora supervisados anotados con sentidos léxicos, apoyándose únicamente en un recurso léxico estándar.	**Extrema Fragilidad Léxica** Falla completamente si el texto usa sinónimos o paráfrasis que no coinciden literalmente con las palabras exactas de la glosa.	**Algoritmo de Schütze & Embeddings** Representación en espacios vectoriales densos donde la similitud no depende de la coincidencia ortográfica exacta.	**Pregunta Fija Examen:** Desambiguar "banco" con Lesk Simplificado. La palabra "dinero" genera solapamiento = 1 con S_1 (financiero).
Algoritmo de Schütze WSD Vectorial No Supervisado	Método que prescinde de diccionarios externos: construye representaciones vectoriales de segundo orden basadas en coocurrencias léxicas en corpus y agrupa las apariciones de la palabra ambigua mediante clustering (K-Means). El sentido se asigna calculando la distancia del vector de contexto al centroide del clúster más cercano.	**Descubrimiento Inductivo** Descubre automáticamente acepciones reales no catalogadas y jergas especializadas en el corpus.	**Sentidos Huérfanos** Produce clústeres matemáticos abstractos (Clúster 1, Clúster 2) que carecen de etiqueta lingüística humana legible sin intervención manual.	**Clustering de Embeddings Contextuales** Agrupamiento de vectores BERT de la misma palabra en distintos contextos para inducir sentidos (Word Sense Induction).	**Examen:** Se basa en la distancia euclidiana o coseno al *centroide* del clúster más cercano.
Bootstrapping de Yarowsky Algoritmo Semi-Supervisado (1995)	Algoritmo iterativo basado en dos hipótesis lingüísticas fundamentales: **One sense per discourse** (una palabra mantiene el mismo sentido en todo el documento) y **One sense per collocation** (palabras contiguas condicionan el sentido). Inicia con pocas semillas (seeds), entrena un clasificador de reglas y etiqueta iterativamente el corpus no anotado.	**Efecto Palanca Masivo** Con un puñado de ejemplos semilla iniciales alcanza precisiones competitivas (>90%) en corpora gigantes sin supervisión costosa.	**Deriva Semántica (Semantic Drift)** Un falso positivo etiquetado en una iteración temprana contamina las reglas subsiguientes amplificando el error exponencialmente.	**Self-Training y Semi-Supervised Transformers** Aprendizaje semisupervisado con Pseudo-labeling y regularización de consistencia en redes profundas.	**Pregunta Test:** Las dos hipótesis de Yarowsky son: «un sentido por discurso» y «un sentido por colocación».

EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 6

Cálculo Oficial Celia Cabello
6.1 EJERCICIO OFICIAL: ALGORITMO DE LESK SIMPLIFICADO PARA "BANCO"
Diapositiva Pág. 16 Resuelta
Oración Problema:
«El banco le prestó dinero»
Palabras de contexto (sin stopwords):
$C = [\text{"prestar"}, \text{"dinero"}]$
Regla de Decisión Formal:

$$\hat{S} = \arg\max_{S_k} |\text{Contexto} \cap \text{Firma}(S_k)|$$

Sentido 1 (S_1, Entidad Financiera): Solapamiento = 1 ★
«Empresa dedicada a realizar operaciones financieras con el dinero procedente de sus accionistas y de los depósitos de sus clientes»
Firma: {empresa, dedicar, realizar, operación, financiera, dinero, accionista, depósito, cliente}
Intersección $C \cap \text{Firma}(S_1) = \{\text{"dinero"}\} \implies |\mathbf{C} \cap \text{Firma}(\mathbf{S_1})| = \mathbf{1}$.
Sentido 2 (S_2, Asiento / Mueble): Solapamiento = 0
«Asiento, con respaldo o sin él, en que pueden sentarse dos o más personas»
Firma: {asiento, respaldo, poder, sentarse, persona}
Intersección $C \cap \text{Firma}(S_2) = \emptyset \implies |\mathbf{C} \cap \text{Firma}(\mathbf{S_2})| = \mathbf{0}$.
🎯 Veredicto Oficial UNIR: Gana S_1 (Entidad Financiera) por mayor solapamiento ($1 > 0$).
Ejercicio 6.2: Trazado Algorítmico de Bootstrapping de Yarowsky Iteración de Semillas

Para desambiguar la palabra "planta" (fábrica vs botánica) mediante semillas:

Iteración 0 (Semillas):
Semilla S_A (fábrica): «nuclear».
Semilla S_B (botánica): «hoja».
Se etiquetan únicamente las instancias con esas colocaciones directas.
Iteración 1 (Entrenamiento):
El clasificador aprende nuevas colocaciones altamente correlacionadas: «energía», «tratamiento» $\rightarrow S_A$; «regar», «maceta» $\rightarrow S_B$.
Aplicación 'One Sense per Discourse':
Si en un documento una sola instancia de "planta" es etiquetada como fábrica, todas las demás apariciones de "planta" en dicho documento se fuerzan a S_A.

T7 Tema 7: Modelado Estadístico del Lenguaje, N-Gramas, Suavizado y Perplejidad

Semana 9 · Corpus BERP, Estimación MLE y Evaluación

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Modelos de N-Gramas (MLE) Hipótesis de Markov de orden $(N-1)$	Modelos estadísticos que estiman la probabilidad conjunta de una secuencia $W = (w_1, \ldots, w_m)$ aplicando la regla de la cadena y aproximando la historia por los últimos $N-1$ términos: $P(w_k \mid w_1, \ldots, w_{k-1}) \approx P(w_k \mid w_{k-N+1}^{k-1})$. En bigramas ($N=2$): $P(w_n \mid w_{n-1}) = \frac{C(w_{n-1}, w_n)}{C(w_{n-1})}$.	**Sencillez y Rapidez** El entrenamiento se reduce a contar frecuencias relativas en corpus (lookup tables ultrarrápidas).	**Problema del Cero (Sparsity)** Si un N-grama no apareció en el corpus de entrenamiento, su probabilidad es 0, anulando la probabilidad de toda la oración ($P = 0$).	**Técnicas de Suavizado & LMs Neuronales** Suavizado Laplace/Add-k, Backoff y redes neuronales autoregresivas (RNNs, GPT).	**Examen:** $P(\text{to} \mid \text{I want}) = \frac{C(\text{I want to})}{C(\text{I want})} = \frac{608}{827} \approx 0.7352$.
Técnicas de Suavizado (Smoothing) Laplace (Add-1), Lidstone (Add-k), Katz	Mecanismos matemáticos que redistribuyen masa de probabilidad desde los N-gramas frecuentes hacia secuencias no observadas (conteo cero): $P_{\text{Add-}k}(w_n \mid w_{n-1}) = \frac{C(w_{n-1}, w_n) + k}{C(w_{n-1}) + k \cdot \lvert V \rvert}$.	**Garantía de Probabilidad No Nula** Impide que la perplejidad tienda a infinito ($PPL \to \infty$) por ceros en secuencias de test.	**Distorsión Proporcional** Add-1 asigna demasiada masa de probabilidad a eventos raros cuando el vocabulario $\lvert V \rvert$ es grande.	**Suavizado Kneser-Ney Modificado** Suavizado interpolado basado en la fertilidad o versatilidad de continuación del unigrama.	**Fórmula Examen:** El denominador suma $k \cdot \lvert V \rvert$ para asegurar que $\sum_{w_n} P(w_n \mid w_{n-1}) = 1$.
Perplejidad (Perplexity - PPL) Métrica Intrínseca de Evaluación de LMs	Exponente del promedio de la log-verosimilitud negativa de una secuencia de prueba no vista: $PPL(W) = P(w_1, \ldots, w_N)^{-\frac{1}{N}} = \exp\left(-\frac{1}{N} \sum_{i=1}^{N} \ln P(w_i \mid w_1^{i-1})\right)$. Equivale intuitivamente al *factor de ramificación ponderado* (número de palabras equiprobables entre las que duda el modelo al predecir la siguiente).	**Evaluación Intrínseca Estandarizada** Permite comparar modelos de lenguaje directamente sin entrenar un clasificador downstream.	**Dependencia del Vocabulario** Solo es comparable entre modelos evaluados exactamente sobre el mismo corpus de test y el mismo vocabulario cerrado $\lvert V \rvert$.	**Evaluación de LLMs en Benchmarks** Métricas MMLU, GSM8k y HumanEval para medir razonamiento en lugar de predicción estadística local.	**Regla de Examen:** A **menor perplejidad**, mayor calidad predictiva del modelo. Si $P = 1$, $PPL = 1$. Si es puro azar uniforme, $PPL = \lvert V \rvert$.

EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 7

Cálculo Oficial Celia Cabello
7.1 EJERCICIO OFICIAL: MATRIZ DE BIGRAMAS BERP Y ESTIMACIÓN DE TRIGRAMA
Diapositiva Pág. 9 Resuelta

Bigrama ($w_{n-1} \to w_n$)	i	want	to	eat	chinese	food	lunch	spend
i	5	827	0	9	0	0	0	2
want	2	0	608	1	6	6	5	1
to	2	0	4	686	2	0	6	211
eat	0	0	2	0	16	2	42	0
chinese	1	0	0	0	0	82	1	0
food	15	0	15	0	1	4	0	0
lunch	2	0	0	0	0	1	0	0
spend	1	0	1	0	0	0	0	0

A) Cálculo Trigrama $P(\text{to} \mid \text{I want})$:

Apariciones de "I want to" = 608.
Apariciones de "I want" = 827.

$$P(\text{to} \mid \text{I want}) = \frac{608}{827} \approx \mathbf{0.7352} \ (73.52$$

B) Suavizado Add-5 ($k = 5, |V| = 1446$):

$C(\text{i}) = 2533$, $C(\text{i, want}) = 827$.

$$P_{\text{Add-5}} = \frac{827 + 5}{2533 + (5 \times 1446)} = \frac{832}{9763} \approx \mathbf{0.0852}$$

C) Bigrama No Visto ($C = 0$):

$C(\text{chinese, chinese}) = 0$, $C(\text{chinese}) = 158$.

$$P_{\text{Add-5}} = \frac{0 + 5}{158 + 7230} = \frac{5}{7388} \approx \mathbf{0.000677}$$

Ejercicio 7.2: Cálculo Analítico de Perplejidad de una Oración Evaluación Intrínseca

Dada una frase de $N = 3$ palabras con probabilidades condicionales calculadas por el modelo: $P(w_1) = 0.10$, $P(w_2 \mid w_1) = 0.20$, $P(w_3 \mid w_2) = 0.05$.

1. Probabilidad conjunta: $P(W) = 0.10 \times 0.20 \times 0.05 = 0.0010 = 10^{-3}$.
2. Cálculo de Perplejidad:

$$PPL(W) = P(W)^{-\frac{1}{N}} = (0.0010)^{-\frac{1}{3}} = (10^{-3})^{-\frac{1}{3}} = 10^{1} = \mathbf{10.0}$$

Interpretación: El modelo tiene la misma incertidumbre que si debiera elegir uniformemente al azar entre 10 palabras en cada paso.

T8 Tema 8: Modelado Neuronal, Redes Recurrentes (LSTM/GRU) y Transformers (BERT/BETO)

Semana 10 y 11 · De Embeddings Estáticos a Atención Masiva

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Word2Vec: CBOW vs. Skip-Gram Embeddings Estáticos Distribuidos (Mikolov 2013)	Redes neuronales de dos capas sin función de activación intermedia que aprenden vectores densos $\vec{v} \in \mathbb{R}^d$ ($d \approx 300$). **CBOW:** Predice la palabra objetivo w_t a partir del contexto circundante $w_{t-c}, \ldots, w_{t+c}$. **Skip-Gram:** Predice las palabras de contexto a partir de la palabra central w_t (optimizado con Negative Sampling).	**Propiedades Aritméticas Semánticas** Permite operaciones de analogía vectorial famosas: $\vec{v}(\text{"Rey"}) - \vec{v}(\text{"Hombre"}) + \vec{v}(\text{"Mujer"}) \approx \vec{v}(\text{"Reina"})$.	**Polisemia No Resuelta (Vector Estático)** Cada palabra recibe un único vector fijo en el espacio, colapsando todos sus sentidos («banco» financiero y mueble comparten el mismo vector).	**Representaciones Contextuales Dinámicas** Transformers (ELMo, BERT) donde cada token recibe un embedding dinámico condicionado por toda la frase.	**Examen:** CBOW es más rápido y funciona mejor en palabras frecuentes; Skip-Gram es superior en palabras raras o datasets pequeños.
Redes Recurrentes: LSTM vs. GRU Secuencias Temporales y Mitigación de Gradiente	Modelos neuronales diseñados para secuencias. **LSTM:** Resuelve el desvanecimiento de gradiente mediante un *Cell State* continuo (C_t) regulado por 3 compuertas: Olvido (f_t), Entrada (i_t) y Salida (o_t). **GRU:** Variante simplificada que fusiona estado oculto y celda, utilizando solo 2 compuertas: Actualización (z_t) y Reinicio (r_t).	**Memoria de Largo Alcance** Capturan dependencias sintácticas y semánticas a través de decenas de pasos temporales. GRU es 25-30% más rápida de entrenar.	**Procesamiento Secuencial No Paralelizable** El paso t depende estrictamente del paso $t-1$, impidiendo aprovechar la paralelización masiva de las GPUs modernas.	**Arquitectura Transformer** Prescinde totalmente de recurrencias mediante Self-Attention completamente paralelizable.	**Pregunta Test:** GRU tiene menos parámetros que LSTM al no poseer compuerta de salida separada ni cell state desacoplado.
La Revolución del Transformer Vaswani et al. (2017) · «Attention is All You Need»	Arquitectura basada íntegramente en mecanismos de autoatención (Self-Attention) y capas Feed-Forward con conexiones residuales y normalización. Computa relaciones directas entre cualquier par de tokens sin importar su distancia ($O(1)$ operaciones secuenciales): $\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$.	**Paralelización Absoluta y Cero Pérdida de Gradiente** Entrena sobre miles de millones de tokens en tiempo récord y captura contexto bidireccional profundo simultáneo.	**Complejidad Cuadrática $\mathcal{O}(n^2)$** El coste computacional y de memoria de la atención escala con el cuadrado de la longitud de la secuencia n (cuello de botella de contexto largo).	**Atención Dispersa y Arquitecturas Flash** FlashAttention, RoPE, State Space Models (Mamba) y MoE (Mixture of Experts).	**Examen:** El factor $\sqrt{d_k}$ evita que el producto punto crezca excesivamente en dimensiones altas, empujando la función softmax hacia regiones con gradientes casi nulos.

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
BERT y BETO (Spanish BERT) Preentrenamiento Bidireccional de Encoder	Modelo basado en el Encoder del Transformer preentrenado con dos tareas autosupervisadas: **Masked Language Model (MLM)** (predecir el 15% de tokens enmascarados con `[MASK]`) y **Next Sentence Prediction (NSP)**. BETO es la versión entrenada nativamente en español sobre un corpus masivo (Wikipedia + OPUS).	**Representaciones Bidireccionales Profundas** Estado del arte en tareas de comprensión lectora, clasificación de texto, NER y similitud semántica mediante Fine-Tuning de pocas épocas.	**No es Generativo Autoregresivo** Al estar compuesto sólo de capas Encoder, no está diseñado para generar texto fluido abierto como los modelos Decoder (GPT).	**Modelos Instructivos y Híbridos** Arquitecturas Decoder-only con alineación por instrucciones (Llama 3, Mistral, GPT-4).	**Token Especial:** El vector del token `[CLS]` al inicio de la secuencia condensa la representación semántica global para clasificación oracional.

📐 EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 8

Cálculo Matricial KaTeX
Ejercicio 8.1: Cálculo Matricial Paso a Paso de Self-Attention Scaled Dot-Product

Para una secuencia de 2 tokens con dimensión $d_k = 2$, dadas las matrices de proyección:

$$Q = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, K = \begin{pmatrix} 1 & 0 \\ 1 & 1 \end{pmatrix}, V = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}, \sqrt{d_k} = \sqrt{2} \approx 1.414.$$

1. Producto de Similitud: $S = QK^T = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 1 \end{pmatrix}$.

2. Escalado por $\sqrt{2}$: $S_{\text{scaled}} = \begin{pmatrix} 0.707 & 0.707 \\ 0.000 & 0.707 \end{pmatrix}$.

3. Softmax por Filas:
• Fila 1: $\text{softmax}([0.707, 0.707]) = [0.500, 0.500]$.
• Fila 2: $\text{softmax}([0, 0.707]) = [0.330, 0.670]$.

4. Salida Final: $A \times V = \begin{pmatrix} 0.5 & 0.5 \\ 0.33 & 0.67 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix} = \begin{pmatrix} 1.00 & 2.00 \\ 0.66 & 2.34 \end{pmatrix}$.

Ejercicio 8.2: Ecuaciones de Compuertas y Eficiencia de Parámetros Arquitectura
LSTM (4 matrices de pesos):
• Olvido: $f_t = \sigma(W_f[h_{t-1}, x_t] + b_f)$
• Entrada: $i_t = \sigma(W_i[h_{t-1}, x_t] + b_i)$
• Candidato: $\tilde{C}_t = \tanh(W_c[h_{t-1}, x_t] + b_c)$
• Salida: $o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$
Total Parámetros por celda: $4 \times (d_h(d_h + d_x) + d_h)$.
GRU (3 matrices de pesos):
• Reset: $r_t = \sigma(W_r[h_{t-1}, x_t] + b_r)$
• Update: $z_t = \sigma(W_z[h_{t-1}, x_t] + b_z)$
Total Parámetros por celda: $3 \times (d_h(d_h + d_x) + d_h)$.
Ahorro del 25% en memoria y cómputo frente a LSTM.

T9 Tema 9: Aplicaciones Industriales del PLN: NER, Extracción de Relaciones y Análisis de Aspectos (ABSA)

Semana 12 · Extracción de Información y Minería de Opiniones

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Reconocimiento de Entidades Nombradas (NER) BIO / IOB vs BILOU Schemes	Tarea de Extracción de Información que localiza y clasifica menciones de entidades en categorías predefinidas (Persona, Lugar, Organización, Fecha, etc.). Formalmente se modela como etiquetado secuencial donde cada token recibe una etiqueta de posición: **BIO:** B (Begin), I (Inside), O (Outside). **BILOU:** Añade L (Last) y U (Unit para entidades de una sola palabra).	**Estructuración Automatizada** Convierte texto libre no estructurado en registros relacionales y bases de datos estructuradas. BILOU reduce ambigüedades en entidades largas.	**Entidades Anidadas y Discontinuas** El esquema BIO plano colapsa cuando una entidad está contenida dentro de otra (ej. "[Banco de [España]]").	**NER Basado en Span / LLM Few-Shot** Extracción mediante clasificación de pares de spans y prompts estructurados con salida JSON Schema.	**spaCy:** `doc.ents`, `ent.label_`, `ent.text`.
Análisis de Sentimientos Basado en Aspectos (ABSA) ATE (Aspect Term) + ASC (Sentiment)	Descomposición de la minería de opiniones en dos subtareas acopladas: 1) **Aspect Term Extraction (ATE):** Identificar los atributos específicos del producto/servicio mencionados (ej. "batería", "pantalla"). 2) **Aspect Sentiment Classification (ASC):** Determinar la polaridad (positivo, negativo, neutro) dirigida exclusivamente a cada aspecto individual.	**Granularidad Accionable** Supera la clasificación global de sentimiento (ej. "3 estrellas") permitiendo saber exactamente qué componente falló y cuál gustó.	**Aspectos Implícitos** Dificultad para detectar opiniones donde el aspecto no se nombra textualmente (ej. «Cuesta un riñón» o Aspecto: Precio, Polaridad: Negativa).	**LLMs con Razonamiento Multi-Aspecto** Extracción conjunta mediante prompting instruccional y esquemas Pydantic estructurados.	**Caso Examen:** En «La comida genial pero el servicio pésimo»: Comida ➔ Positiva; Servicio ➔ Negativa.

EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 9

Anotación & Evaluación
Ejercicio 9.1: Anotación Comparativa BIO vs. BILOU Secuenciación

Frase: «El presidente Gabriel Boric visitó la sede de Google en Madrid».

Token	BIO	BILOU	Explicación Lingüística
El	O	O	Fuera de entidad
presidente	O	O	Título profesional, no nombre propio
Gabriel	B-PER	B-PER	Inicio de entidad multi-token
Boric	I-PER	L-PER	Final de entidad en BILOU (L = Last)

Token	BIO	BILOU	Explicación Lingüística
visitó	O	O	Verbo
la / sede / de	O	O	Palabras no entidad
Google	B-ORG	U-ORG	Entidad de 1 sola palabra (U = Unit)
en	O	O	Preposición
Madrid	B-LOC	U-LOC	Entidad de 1 sola palabra (U = Unit)

Ejercicio 9.2: Evaluación de NER: F1 Estricto vs. F1 Parcial Métricas UNIR

Golden: [Banco Central Europeo] como ORG. Predicción del modelo: [Banco Central] como ORG.

Criterio Estricto (Exact-Match / CoNLL Oficial):
Requiere coincidencia exacta de límites (span) y tipo.
➔ Resultado: Falso Positivo (FP) para [Banco Central] y Falso Negativo (FN) para [Banco Central Europeo]. Precisión = 0, Recall = 0.
Criterio Parcial / Token-level:
Evalúa token por token: "Banco" (Acierto TP), "Central" (Acierto TP), "Europeo" (Fallo FN).
➔ Precision = $2/2 = 1.0$, Recall = $2/3 = 0.67$, $F1 = \mathbf{0.80}$.

⚠ Alerta de Examen: El tribunal exige siempre especificar si la métrica reportada es a nivel de Span Estricto o Token-level permisivo.

T10 Tema 10: Modelos Masivos de Lenguaje (LLMs), RAG, Prompt Engineering y Agentes Autónomos

Semanas 13 y 14 · Paradigma Generativo y Sistemas RAG

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
RAG (Retrieval-Augmented Generation) Arquitectura Híbrida No Paramétrica	Patrón arquitectónico que combina un sistema de recuperación de información (Dense Retriever con embeddings y bases de datos vectoriales como FAISS/Chroma) con un LLM generativo. Ante una consulta q, recupera los k fragmentos más relevantes del corpus externo y los inyecta en el prompt contextual como evidencia verificable: $P(y \mid q) = \sum_{d \in \text{Top-}k} P(d \mid q) P(y \mid q, d)$.	**Mitigación Radical de Alucinaciones** Ancla la generación a fuentes corporativas privadas sin necesidad de reentrenar ni afinar (fine-tuning) el modelo masivo.	**Sensibilidad al Retrieval y Chunking** Si la etapa de recuperación falla o divide un párrafo mutilando la información clave, el LLM generará respuestas incompletas o erróneas.	**RAG Agéntico & Correctivo (CRAG)** Agentes que evalúan reflexivamente la calidad de los documentos recuperados y deciden si reintentar la búsqueda en la web.	**Componentes Clave:** Chunking (256-512 tokens) con solapamiento (10%), Embeddings densos, Base Vectorial (HNSW index) y LLM generador.
Estrategias de Decodificación Greedy vs Beam Search vs Top-p / Top-k	Algoritmos para seleccionar el siguiente token y_t a partir de la distribución de probabilidad generada por el LLM: **Greedy Search:** Selecciona siempre $\arg\max P(w)$. **Beam Search:** Mantiene los B caminos más probables. **Top-k:** Trunca a las k palabras más probables. **Top-p (Nucleus Sampling):** Selecciona el conjunto dinámico más pequeño de tokens cuya suma de probabilidad acumulada alcance el umbral p.	**Control de Creatividad y Variabilidad** Permite calibrar la temperatura: respuestas deterministas formales ($T \approx 0$) o creativas fluidas ($T \approx 0.7 - 0.9$).	**Bucles Repetitivos en Greedy** La búsqueda codiciosa suele quedar atrapada en repeticiones cíclicas en textos largos.	**Muestreo Especulativo y Guided Decoding** Decodificación guiada por autómatas finitos que garantizan esquemas JSON o gramáticas formales 100% válidas.	**Pregunta Examen:** Para extracción de datos precisos (ej. diagnóstico médico), usar Temperature = 0 y Greedy Search.

1. CONCEPTO / TÉCNICA	2. DEFINICIÓN RIGUROSA	3. BONDADES (VENTAJAS)	4. LIMITACIONES	5. ¿A QUÉ EVOLUCIONA?	TIPS DE EXAMEN & SPACY
Patrones de Prompting y Agentes Zero-shot, Few-shot, CoT, ReAct	Metodologías de acondicionamiento de LLMs: **Chain-of-Thought (CoT):** Obliga al modelo a generar pasos de razonamiento intermedios («Pensemos paso a paso») mejorando drásticamente el rendimiento lógico. **ReAct (Reason + Act):** Bucle autónomo donde el agente intercala pensamientos, llamadas a herramientas externas (APIs, calculadoras, SQL) y observaciones.	**Capacidad de Acción en Entornos Reales** El modelo no solo responde preguntas, sino que ejecuta transacciones, consulta bases de datos y orquesta flujos de trabajo.	**Bucles Infinitos y Latencia Acumulada** Múltiples iteraciones de ReAct aumentan el tiempo de respuesta a varios segundos y multiplican el consumo de tokens.	**Arquitecturas Multi-Agente & Protocolos MCP** Sistemas donde agentes especializados cooperan bajo protocolos de intercambio de herramientas (Model Context Protocol).	**Examen:** El prompt de un agente seguro debe contener delimitadores estrictos (ej. `<context>`) para evitar Prompt Injection.

EJERCICIOS NUMÉRICOS Y PRÁCTICOS DEL TEMA 10

Arquitectura RAG & Inferencia
Ejercicio 10.1: Similitud Vectorial y Selección Top-k en RAG Dense Retrieval

Dada la consulta q y 3 fragmentos indexados en la base vectorial con similitudes coseno ya normalizadas:

- $\text{sim}(q, D_1) = 0.88$ (Fragmento de política de cancelaciones)
- $\text{sim}(q, D_2) = 0.42$ (Fragmento de catálogo de productos)
- $\text{sim}(q, D_3) = 0.81$ (Fragmento de plazos de reembolso)

1. Selección con umbral $\tau = 0.75$ y $k = 2$:
Se seleccionan D_1 y D_3. Se descarta D_2 ($0.42 < 0.75$).
2. Estructuración del Prompt Aumentado:
`<instrucción>` Responde únicamente en base a los fragmentos provistos.
`<contexto>` [D1: ...] [D3: ...] `</contexto>`
`<pregunta>` ¿Puedo cancelar y recibir mi dinero?
Ejercicio 10.2: Muestreo Nucleus (Top-p) con Umbral $p = 0.90$ Decodificación

Para el siguiente token, el LLM calcula la distribución de probabilidad ordenada:

Palabra	Probabilidad $P(w)$	Suma Acumulada	¿Entra en Nucleus ($p \leq 0.90$)?
«inteligente»	0.50	0.50	SÍ (0.50 ≤ 0.90)
«artificial»	0.25	0.75	SÍ (0.75 ≤ 0.90)
«avanzada»	0.18	0.93	SÍ (primer token que supera)
«rápida»	0.05	0.98	NO (descartada)
«compleja»	0.02	1.00	NO (descartada)

El muestreo se normaliza y sortea únicamente entre los 3 primeros tokens, eliminando la cola de baja probabilidad («rápida», «compleja») para evitar incoherencias.

🎯 BLUEPRINT OFICIAL DEL EXAMEN UNIR: LOS 2 MÓDULOS (PROF.ª CELIA CABELLO)

Directriz oficial: Módulo 1 (Test de 10 preguntas teóricas y numéricas con los 5 algoritmos) + Módulo 2 (Caso de Diseño de Aplicación).

Guía de Calificación Tribunal
MÓDULO 1 Preguntas Tipo Test (10 Preguntas)
1 por cada Tema (1 al 10)

Alcance Curricular: «¡Sale todo! Tanto preguntas puramente teóricas como pequeños ejercicios numéricos a resolver».

Los 5 Algoritmos Numéricos Fijos de Test:

- **1. Viterbi (HMM):** Decodificación enrejada para POS Tagging ("El Señor Vino Tarde").
- **2. Lesk Simplificado (WSD):** Desambiguación léxica de "banco" con glosas de WordNet.
- **3. N-Gramas BERP:** Cálculo condicional $P(\text{to} \mid \text{I want}) = 608/827$, Add-5 y PPL.
- **4. CKY (Parsing):** Matriz triangular 4×4 y derivación de árbol para "El gato come pescado".
- **5. BoW & TF-IDF:** Cálculo de DF, IDF y Similitud Coseno con vectores normalizados.

MÓDULO 2 Caso Práctico: Diseño de Aplicación
Pregunta Abierta / Redacción

Enfoque de Evaluación del Tribunal: «Diseñar una aplicación completa a partir de un problema real. Decir qué harías y diseñar una solución coherente y bien explicada».

Criterio Fundamental de Corrección:

- **Prioriza el Razonamiento:** «No hay una sola solución única válida».
- **Estructura Exigida:** Pipeline de Preprocesamiento o Justificación de Representación/Modelos o Manejo de Desbalanceo/Casos Límite o Métricas de Negocio (F1-macro, Latencia).
- **Penalización Clave:** No justificar por qué se elige un modelo (ej. descartar LLM por latencia y privacidad local, o descartar BoW por negaciones y contexto).

📝 CASOS PRÁCTICOS DE EXAMEN: DISEÑO DE SISTEMAS PLN

Plantillas metodológicas y defensas técnicas para el Módulo 2 del examen

Módulo 2 (Caso de Uso)

Caso 1: Detección y Clasificación de Mensajes Problemáticos

Odio / Acoso
1. Pipeline de Preprocesamiento: Normalización de jerga de redes sociales, expansión de contracciones, conservación obligatoria de stopwords de negación ("no", "nunca") y signos enfáticos.
2. Arquitectura Recomendada: Modelo Transformer ligero preentrenado (BETO / RoBERTa) con capa de clasificación de secuencia. Embeddings contextuales que capturan sarcasmo e ironía.
3. Mitigación de Desbalanceo: En odio extremo (<2% casos), utilizar *Focal Loss* o ponderación de clases inversa (Class Weights) y evaluar con **F1-Macro** (nunca Accuracy).

Caso 2: Detección Automática de Noticias Falsas (Fake News)

Desinformación
1. Enfoque Híbrido Estilométrico + Semántico: Extraer características lingüísticas superficiales (porcentaje de signos de exclamación, mayúsculas, adjetivos superlativos) combinado con embeddings densos BERT.
2. Verificación de Hechos (Fact-Checking con RAG): Conectar la noticia con una base de conocimiento o grafo de fuentes fiables para comprobar la concordancia fáctica entre la afirmación y los hechos.
3. Métrica Clave: Minimizar Falsos Positivos (no censurar noticias legítimas con estilo sensacionalista). Alta Especificidad y Precision.

Caso 3: Extracción de Diagnósticos y Negación en Textos Médicos

Salud / Privacidad
1. NER Clínico Especializado: Utilizar modelos biomédicos de dominio (ej. `es_core_news_md` adaptado o *PlanTL RoBERTa-BNE-Biomedical*) para entidades CIE-10 (Enfermedad, Síntoma, Medicamento).
2. Detección de Negación e Incertidumbre: Integrar algoritmos de reglas de contexto (tipo *NegEx* o *spaCy-Negex*) para distinguir «sin fiebre» de «con fiebre».
3. Requisito Innegociable: Privacidad y desidentificación local On-Premises (cumplimiento estricto de RGPD en salud, descartando APIs externas de LLMs cloud).

Caso 4: Minería de Opiniones y Aspectos en E-Commerce

ABSA / Feedback
1. Pipeline Modular de Aspectos: Parsing de dependencias (spaCy) para asociar adjetivos modificadores a sus sustantivos núcleo (ej. `amod(servicio, pésimo)`).
2. Agrupamiento Taxonómico de Aspectos: Mapear términos sinónimos ("batería", "autonomía", "duración de carga") a una categoría maestra de negocio ("Autonomía") vía embeddings.
3. Dashboard Analítico: Generar métricas de satisfacción neta por componente para el equipo de desarrollo de producto.

⚡ GUÍA DE REFERENCIA INDUSTRIAL DE SPACY (v3+)

Sintaxis oficial y mejores prácticas evaluadas en el laboratorio UNIR

spaCy 3.x Official

COMANDO / MÉTODO	FUNCIÓN & PROPÓSITO	FRAGMENTO DE CÓDIGO DE EXAMEN	RECOMENDACIÓN & CUIDADO
spacy.load(model)	Carga el pipeline completo (tokenizador, tagger, parser, ner) en memoria.	`import spacy` `nlp = spacy.load("es_core_news_md")`	Para producción industrial masiva, cargar el modelo una sola vez como singleton global.
nlp.pipe(texts, batch_size=...)	Procesamiento por lotes (batching) con paralelismo multiproceso en streaming.	`for doc in nlp.pipe(corpus, batch_size=256, n_process=-1):` `  process(doc)`	**Hasta 10x más rápido** que invocar `nlp(text)` en un bucle secuencial `for`.
nlp.disable_pipes(*names)	Desactiva temporalmente componentes pesados no requeridos en la tarea.	`with nlp.disable_pipes("ner", "parser"):` `  docs = [nlp(t) for t in texts]`	Si solo necesitas tokenización y lemas, ahorra más del 70% de tiempo de CPU y memoria RAM.
Atributos de Token	Acceso a información morfosintáctica y normalizada en tiempo constante $O(1)$.	`for token in doc:` `  print(token.text, token.lemma_, token.pos_, token.is_stop)`	El sufijo con guión bajo (`lemma_`, `pos_`) devuelve la cadena de texto legible; sin guión devuelve el ID entero.
doc.ents (NER)	Generador de entidades nombradas reconocidas en el documento.	`for ent in doc.ents:` `  print(ent.text, ent.label_, ent.start_char, ent.end_char)`	Devuelve objetos `Span` de spaCy, permitiendo evaluar límites de inicio y fin en caracteres.

🔬 LABORATORIOS Y ACTIVIDADES PRÁCTICAS UNIR: PASO A PASO

Resolución empírica, análisis de sesgos y duelo de modelos evaluados en la maestría

Actividades Oficiales 1, 2 y 3
Actividad 1: Extracción de Características y Análisis de Sesgos Laboratorio 1

Metodología: Análisis cuantitativo de textos periodísticos y redes sociales mediante pipelines de spaCy para extraer métricas léxicas (longitud media de palabra, diversidad léxica Type-Token Ratio TTR) y morfosintácticas (densidad de adjetivos y adverbios).

Detección de Sesgos de Género y Profesión: Evaluación empírica de sesgos en embeddings estáticos calculando similitud coseno entre ocupaciones y términos de género ($extdoctoroexthombre$, $extenfermeraoextmujer$).

Conclusión Clave: La neutralización de sesgos (Debiasing) requiere proyectar los vectores en el hiperplano ortogonal al eje del sesgo identificado.
Actividad 2: Duelo Empírico: Red Clásica (GloVe) vs. Transformer (RoBERTa) Laboratorio 2

Banco de Pruebas: Clasificación de mensajes problemáticos en dataset fuertemente desbalanceado (94% neutrales, 6% tóxicos).

Modelo	F1-Macro	Latencia / Inferencia	Veredicto Tribunal
GloVe + BiLSTM	0.742	2.4 ms / doc	Rápido pero pierde matices contextuales
BETO / RoBERTa	0.865 (+12.3%)	28.5 ms / doc	Superior en contexto, ironía y jerga

Criterio de Defensa: Demostrar que el aumento de +12.3% en F1-Macro justifica el incremento de latencia para moderación en tiempo cuasi-real.

⚖️ MATRIZ DE TOMA DE DECISIONES & COMPARATIVA DE MODELOS

Criterios de selección arquitectónica para la defensa oral y escrita del examen UNIR

Criterio Tribunal UNIR

FAMILIA DE MODELOS	ARQUITECTURA REPRESENTATIVA	CUÁNDO ELEGIRLO (VENTAJAS CLAVE)	CUÁNDO DESCARTARLO (PUNTOS CRÍTICOS)	MÉTRICA DECISIVA
1. Clasificador Clásico Supervisado	TF-IDF + Support Vector Machine (SVM) lineal / Naïve Bayes	**Ultra-rápido y Ligero** Datasets tabulares limpios, recursos de cómputo mínimos (CPU estándar), interpretabilidad total por peso de coeficientes.	**Ignora Sintaxis y Orden** Fracasa ante negaciones distantes, sarcasmo o variaciones léxicas sinónimas sin solapamiento léxico directo.	Latencia (<1 ms), Cero consumo GPU, Memoria RAM ínfima.
2. Redes con Embeddings Estáticos	GloVe / FastText + BiLSTM / CNN 1D	**Equilibrio Latencia-Semántica** Vocabulario cerrado o subpalabras rápidas con FastText, latencia acotada para dispositivos móviles o edge computing.	**Polisemia Rígida** No resuelve el sentido dinámico según la oración y el entrenamiento secuencial no aprovecha GPUs masivas.	F1 intermedio, rendimiento en palabras fuera de vocabulario (OOV).
3. Transformers Encoder (Preentrenados)	BERT / BETO / RoBERTa Fine-Tuned	**Estado del Arte en Comprensión** Máxima precisión en clasificación, NER y similitud semántica. Captura contexto bidireccional rico y jerga compleja.	**Coste GPU y Límite de Tokens** Requiere aceleración GPU y sufre el coste cuadrático en secuencias de más de 512 tokens.	**F1-Macro** y exactitud semántica en tareas de discriminación.
4. LLMs Decoder Masivos + RAG	Llama 3 / Mistral / GPT-4 + Vector DB (RAG)	**Flexibilidad y Cero Reentrenamiento** Generación de texto estructurado, preguntas y respuestas corporativas y agentes autónomos multi-herramienta.	**Alucinaciones y Alta Latencia** Inferencia lenta (cientos de milisegundos), coste económico por llamada y riesgo de alucinación sin RAG estricto.	RAGAS (Fidelidad, Relevancia), CoT Reasoning y cumplimiento de JSON Schema.

Suite Curricular de Preparación para Examen · Máster Universitario en Inteligencia Artificial · UNIR

Diseñada según el temario oficial (Temas 1 al 10), resolución analítica de los 5 algoritmos de clase de la Prof.ª Celia Cabello y directrices de evaluación del Tribunal.

Renderizado Nativo KaTeX + Tailwind · Documento Optimizado para A4 Landscape · Cero Imágenes Rasterizadas